

自监督与对比学习练习详解

第059单元 从算术到实验判断

请先完成讲义末尾十题。以下解答把最终数值、推理过程和结论边界分别写清；与程序一致是必要条件，解释为何一致更重要。所有实验数字对应随包outputs/results.json，四舍五入可能造成最后一位差异。

第一题 候选集合

$B=64$ 表示64个原始输入，每个产生两个视图，因此共128个视图。对任一锚点，排除自己后剩127个候选。其中一个是同一原始输入的另一视图，另外126个是负样本。正伙伴必须留在分母中，否则分子不再是分母所归一化集合的一项，式子不再是候选分类概率。

排除自己，是因为同一向量与自己的余弦相似度总是最大值1，这项不能帮助学习跨视图关系。正伙伴和锚点不是同一个数组元素，即使某个极端例子数值相同也不能把正伙伴遮掉。常见错误是对“同一个原始输入”全部做掩码，从而同时排除自己和正伙伴。

第二题 四视图手算

每个锚点有一个分数1的正伙伴、两个分数0的负伙伴。 $\tau=1$ 时，正确概率 $e/(e+2)$ ，损失 $\log(e+2)-1 \approx 0.551445$ 。 $\tau=0.5$ 时正logit为2，负logit仍为0，损失 $\log(e^2+2)-2 \approx 0.239545$ 。四个锚点相同，因此求和再除4不会改变结果。

若把自己也留在分母， $\tau=1$ 时损失 $\log(2e+2)-1 \approx 1.006409$ 。它仍是另一个候选问题的交叉熵，却不是我们声明的三候选目标。若把正伙伴也删掉而分子仍保留 e ，得到 $\log 2 - 1 \approx -0.306853$ ，这种负数已经暴露它不再是正确归一化概率的负对数。

第三题 相似度梯度

把损失写成 $-s_{ip}/\tau + \log \sum \exp(s_{ik}/\tau)$ 。第一项对正伙伴分数的导数为 $-1/\tau$ ，对其他候选为0。第二项用链式法则求得得到 $P(k|i)/\tau$ 。因此导数是 $(P(k|i) - \text{指示函数})/\tau$ 。这里是对单个锚点候选分数的导数，不是最终网络权重梯度，后者还需考虑归一化、共享参数和所有锚点的平均。

$\tau=1$ 时正概率约0.576117，负概率各约0.211942。正导数-0.423883，两个负导数各0.211942，总和为0。梯度下降会提高正分数、降低负分数。总和为0体现softmax对所有候选共同平移不敏感，不意味着网络参数梯度也逐元素相加为0。

第四题 常量表示

$B=3$ 产生6个视图，任一锚点有5个完全同分候选。正确概率 $1/5$ ，损失 $\log 5 \approx 1.609438$ 。改变温度不会改变所有候选相同这一事实。这是一个可用于实现校验的特殊值。

它不能证明训练永不坍塌。它只说明完全常量表示在该目标上的取值，并且一般存在能更好区分伙伴的表示。实际能否到达、梯度如何、模型容量与数据增强是否允许区分，都还需要分析。出现常量向量时，归一化也可能引入特殊梯度行为，不能靠一个损失值提供全局优化保证。

第五题 错误不变性

破语义增强重新抽取角度，却保留原始干扰，因此同一实例两视图共享的是干扰。模型可以用这些干扰分清实例，输出在样本间丰富变化，标准差不小；但干扰独立于象限标签，冻结线性分类会差。这里主要诊断是目标与下游不匹配，而非全部表示相同。

同时也不能凭“标准差大”排除一切表示退化。例如两个坐标高度相关时仍可能只有一条有效方向。更完整检查应看协方差谱、不同输入敏感性、增强依赖和下游协议。本课只把平均标准差当粗诊断，没把它用作质量排名。

第六题 线性探测矩阵

训练前缀有128行，每行h有2个坐标。用这128行计算均值标准差，再补截距列，A形状 128×3 ；四类一位有效标签Y形状 128×4 。A转置乘A为 3×3 ，正则矩阵也是 3×3 ，求解后的W为 3×4 。测试矩阵为 384×3 ，乘W得到 384×4 得分。

正则对两个特征权重各加1，对截距加0。截距用于表示类别整体偏置，不因数据原点选择被同样惩罚。标准化使用训练前缀，常量坐标缩放设1。这使闭式方程在该设置下可求解，同时避免把零方差当除数。

若把一位有效标签直接换成整数0、1、2、3做一维回归，将人为引入类别间的数值距离，得到不同问题。四类分数回归并非逻辑回归；二者都可作为线性探测，比较时必须说明目标、正则与拟合协议。

第七题 测试标准化

不符合本课协议。虽然没读测试标签，仍用测试输入分布改变了特征变换。本课要评估训练阶段固定的表示和读出器如何推广到未参与拟合的测试输入，故均值标准差只可由训练前缀计算。

这不代表任何利用未标注测试输入的研究都无效。有些研究明确采用传导式或测试时自适应设定，但必须说明允许的信息、更新规则和比较基准。问题在于悄悄改变设定后仍称“相同冻结评估”。本题的修复是保存训练前缀均值标准差，并用于验证和测试。

第八题 标签预算

监督预训练使用全部768个训练标签，而自监督只使用训练输入；之后所有方法才共同使用128个标签拟合新probe。相同的探测阶段不抹掉此前用过的标签。因此监督结果接近100%应读为有标签参考，而不能归因于仅128标签的公平竞争。

若研究目标是相同标签预算的性能，需新增只用固定128例标签的监督预训练配置，控制数据曝光与搜索预算，再报告全部种子。这是新实验，不能从现有768标签结果倒推出128标签性能。

第九题 三个初始化的报告

保语义对比测试准确率为237/384、322/384、222/384，分别约61.7188%、83.8542%、57.8125%。均值为781/1152 $\approx$ 67.7951%，范围57.8125%至83.8542%。最小和最大是三个已观察种子的描述，不是未来运行的性能界限。

只有三个初始化而且使用同一个数据划分，不能把样本当作三个独立总体数据集，也不能从均值推断现实场景必然同幅度提升。较谨慎的句子是：“在本固定合成划分的三个预声明初始化中，保语义对比均优于随机编码器与破语义对比，但种子敏感性明显。”

随机基准均值约30.03%，破语义约21.35%，监督约99.65%。四类平衡时恒定随机猜测期望25%，但有限测试样本和训练程序使观察值上下变化；低于25%的结果不能自动解释为模型发现了“反语义”。

第十题 预先约定的消融

一个合格方案是只改变信号噪声标准差，候选0.02、0.04、0.08，其他保持数据划分、768个未标注输入、350步、批64、温度0.2、相同种子、128标签probe和正则1。事先约定以三种子验证准确率均值选择噪声强度，平局按较小值选择；测试只评估最终被选方案一次。

记录每个候选和选择规则，不能只发布最佳测试种子。因为本教材已经展示了固定测试结果，学习者在这个数据上做后续探索时应承认测试已见；真正严格的后续验证应预先生成新的独立保留测试数据，并在选择完成前不读它。

这个方案只回答该小分布对噪声强度的敏感性。若把视图规则、编码器维数、温度同时改变，就难以知道差异来自哪一项。计算资源有限时，少做几个问题但保持比较清楚，往往比大范围盲目搜索更有教学价值。

实验结果的标准解释示例

本实验把八维记录压缩为二维表示，在固定训练子集标准化和岭回归线性探测下进行四分类。保语义对比在三个初始化中取得约57.81%至83.85%的测试准确率，均值约67.80%；随机与破语义对比的均值约30.03%和21.35%。保留角度、替换干扰的视图优于相反视图，说明该任务中增强假设影响下游可用性。

监督参考均值约99.65%，但预训练额外使用全部768个标签，因此不构成同标签预算比较。三个初始化共用一个数据划分；合成数据的语义由人指定，结果不能外推为真实视觉任务结论。所有编码器在probe期间冻结，测试表示未用于标准化或参数选择。这个解释同时说清发现与限制。

常见答案为何不充分

“loss低所以语义好”忽略两个增强对应不同任务。“没有标签所以没有人为偏见”忽略视图和负样本定义。“每个方法probe相同所以标签预算公平”忽略预训练用过的信息。“散点图分开所以推广可靠”忽略样本选择、坐标变化和定量评价。“只设requires_grad=False就完全冻结”忽略某些层的运行状态。

代码检查背后的证据链

单元测试先检查数学特殊值，再检查错误输入，再从保存数据和权重逐样本重放；Notebook从头重新训练全部配置到新目录。它们检查不同层次，不能用其中一项代替其他项。普通和-O均通过说明关键检查不依赖会被优化删除的assert语句，但不意味着覆盖了所有可能错误。

如需扩展为正式科研，继续增加独立数据划分、任务、预算公平基准和提前规定的模型选择。先把本课的机制与可复现边界掌握清楚，再扩大规模，比把一个漂亮均值写成普遍规律更可靠。