

变分自编码器练习详解

第060单元 把下界解释到每一个数

本册对应讲义十题，先给推导再说明实验边界。实验数值见outputs/results.json；它们保留更多小数只是便于重放，不表示统计误差可以忽略。全部对数为自然对数。

第一题 联合分布与边缘似然

生成模型联合分布为 $p_{\theta}(x,z)=p(z)p_{\theta}(x|z)$ 。只观测 x 时，需要积分消去 z ：

$p_{\theta}(x)=\int p(z)p_{\theta}(x|z)dz$ 。非线性解码器常使这个积分没有易算闭式。真实后验 $p_{\theta}(z|x)=p_{\theta}(x,z)/p_{\theta}(x)$ 又依赖同一个难算分母。

编码器 $q_{\phi}(z|x)$ 是我们选择并学习的可计算分布族，本课限制为对角高斯。它不是贝叶斯公式保证正确的真实后验；若真实后验多峰或强相关，即使参数优化很好也可能存在近似误差。把 q 直接当 p 会隐藏ELBO与精确似然之间的间隙。

第二题 两条推导路线

先在积分中乘除 q ，把 $p(x)$ 写成 $E_q[p(x,z)/q(z|x)]$ 。由 $\log$ 的凹性， $\log E[W] \geq E[\log W]$ ，得到ELBO为 $E_q[\log p(x,z) - \log q(z|x)]$ 。展开联合分布后就是 $E_q \log p(x|z) - \text{KL}(q||p(z))$ 。

展开第二条路线： $\text{KL}(q||p(z|x))=E_q \log q - E_q \log p(x,z) + \log p(x)$ 。这里 $\log p(x)$ 与 z 无关，期望后不变；前两项恰好是 $-\text{ELBO}$ ，因此间隙恒等式成立。

另一条路线从 $\text{KL}(q(z|x)||p_{\theta}(z|x))$ 开始，将真实后验替换为 $p_{\theta}(x,z)/p_{\theta}(x)$ ，得到该KL等于 $\log p_{\theta}(x) - \text{ELBO}$ 。KL非负，因此下界成立；相等要求 q 与真实后验几乎处处一致。有限次抽样算出的ELBO估计会有随机误差，下界性质针对期望目标，不能要求每次单样本值都低于精确似然。

第三题 对角高斯KL

先在一维展开 $\log q = -0.5 \log(2\pi) - \log \sigma - (z - \mu)^2 / (2\sigma^2)$, $\log p = -0.5 \log(2\pi) - z^2 / 2$ 。相减后两个 $\log(2\pi)$ 常数抵消。 q 下 $E[(z - \mu)^2] = \sigma^2$, 所以标准化平方项期望为1; $E[z^2] = \mu^2 + \sigma^2$ 。于是 $KL = -\log \sigma - 0.5 + 0.5(\mu^2 + \sigma^2)$, 即 $0.5(\mu^2 + \sigma^2 - 1 - \log \sigma^2)$ 。独立各维的log密度相加, 期望也逐维相加。

每维贡献为 $0.5(\mu^2 + \text{variance} - 1 - \log \text{variance})$ 。第一维 $\mu_1 = 1$ 、 $\text{variance}_1 = 4$, 所以贡献 $0.5(1 + 4 - 1 - \log 4) = 0.5(4 - \log 4) \approx 1.306853$; 第二维 $\mu_2 = 0$ 、 $\text{variance}_2 = 1$, 贡献0。因此总KL约 1.306853 nat/例。

当所有 $\mu = 0$ 、 $\text{variance} = 1$ 时, q 与标准正态先验相同, 每维贡献0, 总KL0。注意 $\log \text{var} = 0$ 对应 $\exp(0) = 1$ 的方差。若错误地认为它对应方差0, 将完全误解后验坍塌: 坍塌时仍可从标准正态抽出不同 z , 只是它们与输入几乎无关。

KL对 μ_j 导数是 μ_j , 对 $\log \text{var}_j$ 导数是 $0.5(\exp(\log \text{var}_j) - 1)$ 。KL项单独优化把均值拉向0、方差拉向1。重构项则鼓励携带输入信息, 两者共同决定最终后验。

第四题 重参数化与梯度

$\sigma = (2, 1)$, $\epsilon = (0.5, -1)$, 所以 $z = \mu + \sigma \epsilon = (1 + 2 \times 0.5, 0 + 1 \times (-1)) = (2, -1)$ 。对 μ 每维的局部导数为1。对 $\log \text{var}_j$, 因为 $\sigma_j = \exp(0.5 \log \text{var}_j)$, 导数为 $0.5 \sigma_j \epsilon_j$, 所以是 $(0.5, -0.5)$ 。

下游函数为 $z_1 + z_2$ 时, 其对 z 每维导数均为1, 因此最终 μ 梯度 $(1, 1)$, $\log \text{var}$ 梯度 $(0.5, -0.5)$ 。若下游换成真正解码NLL, 还要乘解码器与损失对 z 的梯度, 不能直接把本题数值当训练梯度。

重参数化的意义是先从与参数无关的标准噪声抽样, 再做可微变换; 它并不取消随机性, 也不自动适用于离散类别采样。本课二值 x 并不违背这一点, 因为 z 仍是连续高斯。

第五题 高斯NLL的常数

$D=2$ 、 $\sigma=1$ 且预测等于观测，平方偏差项为0， $\log \sigma$ 为0，每维剩 $0.5\log(2\pi)$ ，两维合计 $\log(2\pi) \approx 1.837877$ nat/例。若只报告平方误差会得到0，说明它不是完整高斯NLL。

连续密度可以大于1，因此log密度可以为正，负对数密度可以为负。比如 $\sigma=0.25$ 、二维均值精确时，每维常数 $\log 0.25 + 0.5\log(2\pi) \approx -0.467356$ ，两维合计约 -0.934712 。它不违反区间概率不超过1，因为概率需要对密度积分。

连续NLL还随输入单位改变而变化，不能把厘米与米下的数值直接比较。二维标准6001模型的MC重构NLL约 -0.0055 是允许的，并非精确重构常数；它还包含实际残差和后验抽样影响。

第六题 伯努利NLL与归约

零logit对应概率0.5。无论像素实际为0还是1，每像素NLL都是 $-\log 0.5 = \log 2$ 。64像素求和得到 $64\log 2 \approx 44.361420$ nat/例。若像素平均则是 $\log 2 \approx 0.693147$ ，数值小64倍。

若KL仍按每例潜在坐标求和，训练目标从 $R+KL$ 变成 $R/64+KL$ 。乘64后等价于 $R+64KL$ ，因而相对KL压力大64倍。要保持同一标准目标，可同时把KL也除64；或者保留本课逐像素求和、最后批平均。不能只说“mean比较稳定”而忽略目标比例。

第七题 beta训练与共同评价

$NLL+100KL$ 不等于标准负ELBO，它是加权变分目标。 $\beta=1$ 时才与本课模型的负ELBO一致。不同 β 训练的模型，可以统一用测试MC NLL加精确KL按 $\beta=1$ 评价，以比较同一种下界目标；这就是results中的negative_elbo。

这个共同评价仍不是精确边缘似然，也不消除近似后验族带来的间隙。若某模型下界更好，不能据此断言精确似然必定以相同幅度更好。报告时同时列重构项、KL和估计次数，有助于理解差异来源。

第八题 坍塌诊断

后验坍塌表示 $q(z|x)$ 接近先验、失去对 x 的依赖，并不是每次采样 z 都等于0。标准正态有方差1，即使 μ 恒为0仍会产生不同 z 。真正消失的是输入特有信息，而非所有随机变化。

本实验三项诊断是：每例KL近0；后验均值在不同输入之间的方差近0；把 μ 与输入配对打乱后，均值解码NLL几乎不变。二维high_beta两个种子KL约0.000196和0.000105，图像约 $7.63e-6$ 和 $7.42e-6$ ，另外两项也接近无输入依赖的情形。

这些数值由beta100的明确压力测试诱发，不是标准beta1自然失败的证据。三个指标也不是普遍阈值，必须结合数据结构、观测模型和重构表现解释。仅看某一维均值很小不足以认定所有潜在维度失效。

第九题 干预的控制与不完全恢复

restore_beta和high_beta共享前300步的初始化、模型、批次、epsilon、优化器状态和目标。之后只改变beta100 $\rightarrow$ 1，不重新初始化，也不改变训练预算。测试要求前缀记录逐数相同，使“从同一个受压状态继续训练”的说法有直接证据。

二维恢复负ELBO约2.9158与2.9259，显著优于高beta约22.1078与22.0849，但略差于标准约2.8141与2.8053。图像恢复约23.3749与23.0835，虽优于高beta约25.8531与25.8219，仍差于标准约20.6330与19.9724。数据任务不同，恢复程度也不同，不能只发布更容易恢复的二维案例。

可能原因包括300步恢复不足、优化路径依赖和任务复杂性，但本实验没有逐项隔离这些解释，故只能写为后续假设。两个种子和一个划分限制了外推范围。这不是KL热身实验，也不能证明所有自然坍塌都由过大beta造成。

第十题 四种容易混淆的对象

后验均值重构：先对给定 x 算 $\mu(x)$ ，把 μ 送入解码器，得到高斯均值或伯努利概率。它不包含后验抽样，因此主要用于稳定可视化，不是完整期望重构项。

先验解码均值：先从 $p(z)$ 抽一个 z ，再取解码器的观测均值。它用于观察生成分布的条件均值，但还没抽观测噪声。与前一个对象相比， z 来自先验，不依赖某个输入。

真正观测样本：在先验 z 的解码分布下再抽 x 。二维需加 $\sigma 0.25$ 高斯噪声；图像逐像素伯努利抽样，只含0与1。同一列概率均值和二值样本看起来看起来很不同，却属于同一模型的两层随机过程。

MC负ELBO：对每个测试 x ，从 $q(z|x)$ 抽16个 z ，平均每例NLL，再加解析KL，最后对测试样本平均。它是带有限抽样误差的评价数，不是图像，也不是精确边缘似然。

一段合格的实验报告

本实验在二维高斯观测和64维伯努利观测下训练小型VAE，重构项与KL均按坐标求和后按样本平均，单位nat/例。高 $\beta 100$ 诱发近先验后验，KL、 μ 变化和配对打乱诊断共同显示输入依赖减弱。保持共同前缀后仅把 β 恢复为1，两个任务都重新利用潜变量，但图像任务在相同总步数下未恢复到标准 $\beta 1$ 模型水平。

报告的负ELBO采用16次固定噪声MC估计，不是精确似然；两个初始化共用一个合成数据划分。图像只为 8×8 二值线条，不外推现实图像质量。保存检查点逐样本重放、完整Notebook重训与普通/O测试分别提供实现、执行和归约证据。

继续学习前的自检

若你能解释为什么KL零时后验仍有随机性、为什么二维NLL可为负、为什么 $\beta 100$ 目标不等于标准负ELBO、以及为什么概率均值不等于二值样本，就已经掌握本课最重要的四个边界。再扩大模型时，应保留这些判断，而不是只复制一个loss函数。