

对抗生成与博弈训练 详细答案

第061单元 计算、程序检查与结论边界

答案对应实验手册任务A至F。数值以随包outputs/results.json为准；本地重新运行可能因平台产生小幅变化，应报告自己的结果。这里提供解释路径，不鼓励只复制最终数字。扩展研究尚未执行的部分明确标为设计，不作为实测证据。

一 环境与两步更新的验收

数据形状为 4096×2 ，中心编号为4096维整数数组。G与D训练均不读取中心编号。参考集使用独立数据种子611，评估噪声使用9000加模型种子的独立torch.Generator。保存快照不会消耗训练用的随机序列，所以仅增加记录次数不应改变参数轨迹。

D步骤中的`g(z).detach`让假样本成为常量输入，D仍能计算并更新自己的参数。若删除`detach`且仅执行D优化器step，G参数当场可能不变，但G梯度会被额外计算和积累，因此“参数没变”是必要检查而非全部检查。本测试同时检查新建G的梯度为空。

G步骤把D参数`requires_grad`设为False，保留D对输入的微分，因而G能收到梯度。若用`torch.no_grad`包住D前向，最终损失不再连到G，`backward`会失效或G无法更新。若在这一步再次`detach`假样本，也会切断同一条必要路径。正确测试是D参数不变、G至少一个参数改变、D最终恢复可训练。

这些测试没有证明整个算法一定收敛。它们证明最基本的更新边界符合设计，排除了若干常见实现错误。完整训练失败仍可能来自优化动态、有限容量、数据和超参数。先验证程序行为，再解释算法现象，是两类不同证据。

任务A 判别损失

真实组均值为 $-(\log 0.8 + \log 0.6)/2 = 0.3669846$ ；假组因为 $1-0.2=0.8$ 、 $1-0.4=0.6$ ，结果相同。两组相加为0.7339692。若四个概率都为0.5，每组损失是0.6931472，总损失1.3862944。将真假合并后平均得到一半的数字，仅改变缩放约定，不能作为质量提升。

二 任务B 梯度为什么不同

设 $d = 1/(1 + e^{-s})$ ，先求 $d'(s) = d(1 - d)$ 。对经典极小极大假样本项应用链式法则：外层 $\log(1-d)$ 对 d 的导数是 $-1/(1-d)$ ，乘内层 $d(1-d)$ ，得到 $-d$ 。非饱和项 $-\log d$ 的外层导数是 $-1/d$ ，乘内层后得到 $d-1$ 。

在 $d=0.01$ 处，两者分别为 -0.01 和 -0.99 ；在 $d=0.5$ 处，分别为 -0.5 和 -0.5 。梯度下降将参数沿负梯度移动，因此两个负的logit导数都推动 s 增大，让 D 认为生成点更像真样本。差别在于假样本被强烈拒绝时，非饱和目标仍提供较大logit梯度。

完整生成器参数梯度可以写成三段乘积：损失对 s 、 s 对生成点 x 、生成点 x 对参数 θ 。仅第一段不小，并不意味着后两段也有用。例如 D 在生成区域输出近似常数时， s 对 x 接近 0；又如 G 某些参数不影响当前批次输出，对应最后一段为 0。答案若说“非饱和损失解决所有梯度消失”，应判为过度结论。

softplus 形式与显式 Sigmoid 加 $\log$ 在数学上等价，但数值计算路径不同。很大的正负 logit 会让浮点 Sigmoid 接近 0 或 1，随后取 $\log$ 可能产生无穷；稳定实现通过等价变换避免直接计算危险的指数或对数。测试用极端 logit 检查有限损失，也是数值实现的一部分。

任务C 两个评价器反例

每个模式放 41 个点，共 328 个有效点，剩下 3768 个在零点。每个模式占全部样本 $41/4096 \approx 1.001\%$ ，超过 1% 阈值，故覆盖 $8/8$ ；有效比例 $328/4096 \approx 8.008\%$ 。有效内部概率恰好均匀，最大条件模式占比 $1/8$ ，条件熵 $\log 8$ 。所有这些“平衡”数字都无法挽救 92% 的无效输出。

把全部 4096 个点放在中心 0，则有效比例 1、覆盖 1、最大条件占比 1、条件熵 0。这是有意构造的常数集合，不含训练过程，故只说明评价器能识别极端情形。真正训练坍塌需要记录模型、优化过程和不同随机输入的实际输出，随包压力轨迹提供了这些证据。

三 三种子实测与任务D诊断

基准种子11、23、37的最终覆盖均为8，有效比例依次为0.6242676、0.6748047、0.6042480。这意味着三个模型都给每个模式至少1%的总生成概率，却仍有约三至四成采样落在0.35半径之外。不能写成“模型完全恢复了真实混合分布”。

压力配置种子17在800轮时，4096个采样全部通过有效阈值，且全部被分到同一个中心编号5。其覆盖为1，最大条件占比1，最近中心平均距离约0.1141。这是不同 z 经过真实训练 G 得到的集中输出。判别器真实均值约0.4993、生成均值约0.4984，仍不能提供成功证明。

最简单的反例是令 $D(x)$ 恒等于0.5。不论 G 输出真实分布、一个点还是远处垃圾， D 均值都一样。因此“某个 D 无法区分”不能推出“真实与生成分布相等”。必须补看覆盖和有效比例，还应查看分配是否均匀及图中的形状。压力800轮正是高有效、低覆盖的清楚反例。

最终2200轮，压力模型有效比例为0、覆盖0，最近中心平均距离约0.5747。其坐标标准差很小，说明输出仍集中，但不在真实团内。正确表述是“训练中出现过单模式坍塌，最终变成偏离数据模式的集中输出”。把800轮当最终结果，或者把最终覆盖0解释为“什么都没输出”，都不正确。

快照选择规则会强调失败现象，因此必须披露。报告同时保存全部每100轮轨迹和最终模型，是为了让读者检查选取是否片面。它证明某种失败确实出现，不估计默认GAN在所有随机种子下的坍塌概率。压力配置还同时改变三个因素，因此无法单独识别唯一因果来源。

一个合格的控制变量设计是：四组分别为基准、仅增大 G 学习率、仅减小 D 学习率、仅增加 G 更新次数；每组使用相同三种子、固定评价规则和相同数据。除了按 D 轮数画图，也按累计 G/D 更新数报告预算。该设计在本包中未执行，不能预填哪组会成功或失败。

四 任务E 理想判别器与JS手算

对 $f(d) = a \log d + b \log(1 - d)$ ，导数为 $a/d - b/(1-d)$ 。设为0后， $a - ad = bd$ ，所以 $d = a/(a+b)$ 。a、b均正时二阶导严格为负，故是极大值。 $a > 0$ 且 $b = 0$ 取边界1； $a = 0$ 且 $b > 0$ 取边界0；两者皆0时 f 恒为0，任意 d 都最优。

若真实来源先验为 π ，目标变成 $\pi a \log d + (1 - \pi) b \log(1 - d)$ ，同样推导得到：

$$D^*(x) = \frac{\pi p_{\text{data}}(x)}{\pi p_{\text{data}}(x) + (1 - \pi) p_g(x)}.$$

当 $\pi = 1/2$ ，分子分母同时约掉 $1/2$ ，恢复标准公式。此时若 $p = q$ ，最优 $D = 1/2$ ；但若来源先验不是 $1/2$ 而 $p = q$ ，最优 $D = \pi$ 。这也解释了为什么真假采样权重属于目标定义的一部分，不能随意更换后继续引用旧平衡数值。

对离散例子 $p = (1/2, 1/2)$ 、 $q = (1, 0)$ ， $m = (3/4, 1/4)$ 。计算 $KL(p||m)$ ：第一格为 $0.5 \log(2/3)$ ，第二格为 $0.5 \log 2$ ，合计 0.1438410 。 $KL(q||m)$ 只有第一格，结果 $\log(4/3) = 0.2876821$ ；第二格使用 $0 \log 0$ 的极限为0，不应让程序产生NaN。

因此JS是两者平均 0.2157616 。理想 $V = -\log 4 + 2JS = -0.9547713$ 。也可直接计算理想判别器两格为 $(1/3, 1)$ ，代入真实与生成期望，得到同一结果。直接法与距离法一致，是很好的独立代数核对。

$p = q$ 时 $JS = 0$ ， $V = -1.3862944$ ，低于上述缺失第二格的生成分布。这个比较是理想函数空间里的目标值比较，并没有告诉我们当前有限网络从什么参数出发、每次更新多大、能否找到正确方向。答案必须把“最优解在哪里”与“算法是否到达最优解”分开。

五 任务F 正确结论与验收标准

原说法“生成器loss下降就是JS下降”至少有四个问题。第一，JS恒等式使用针对当前G充分优化的理想D；实际D每轮只更新一次。第二，理论期望与有限批次估计不同。第三，实验G用非饱和目标，数值不等于经典V。第四，loss可能只是最后一个批次，甚至最后一次G更新，不是整个生成分布上的精确评价。

合格改写可以是：在理想判别器和充分函数容量等条件下，经典极小极大目标与JS散度相联系。本实验采用有限网络、随机批次和非饱和生成器目标，损失只能作为训练诊断；是否学到目标分布，还要用独立采样检查覆盖、有效比例与模式概率。

Notebook应该显示什么

Notebook应从导入和版本检查开始，经过手算、梯度边界测试、完整重新训练、结果读取、保存图展示和结论检查。全部代码单元按顺序编号，无error输出；训练数字来自新运行，不只是读一张预先存好的图。notebook_outputs保留重新运行的参数与样本，便于与教材outputs对照，但不必逐字节一致，因为记录中包含耗时。

顺序执行通过证明代码在新的IPython进程中可运行。它没有测试浏览器Jupyter界面、远程内核传输或所有操作系统。若用户使用自己的Jupyter环境，应再次Restart Kernel and Run All，并检查路径与解释器。不要把一种执行方式的通过外推到所有部署方式。

建议评分

总分100：环境与两种模式测试10；梯度边界解释与行为检查20；三种子指标及局限15；评价器反例10；真实坍塌与最终状态区分20；理想判别器与JS推导15；控制变量研究设计10。把人工常数对照冒充训练坍塌、删除失败种子或声称MSE/判别损失即生成质量，属于核心概念错误。

你最终应该带走什么

GAN同时训练“提出样本”的模型和“指出差别”的模型，学习信号来自对方而非固定标签规则。理想化推导解释了分布匹配为何可能，但实际交替更新会出现有限容量、追逐和多样性问题。可靠的实验报告不只给出成功图片，也给出损失缩放、随机种子、梯度边界、失败过程与评价定义。

本包所有数据与图均为原创合成教学材料。参考来源见sources.md；版本与测试证据见verification.json。若你做了自己的扩展，请保留新的文件和配置，重新生成相应图表，并明确哪些结论来自新实验，哪些只是理论预期。