

离散扩散与去噪学习

第062单元 从可计算的加噪到学出的反向生成

把一张清楚的图逐渐加上噪声，最终会很难看出原来的内容。反过来，能否训练一个程序，把噪声逐步变成有结构的数据？扩散模型给出的路线是：先规定一个容易计算的破坏过程，再学习与之对应的反向条件分布。本讲从二维点开始，不要求读者先做完整VAE，也不把复杂图像系统作为理解概率公式的前提。

标题中的“离散”指时间编号 t 取0、1、2直到 T ，并不表示状态是离散符号。本讲每个状态 x 都是二维实数向量，属于连续状态空间。把时间离散的高斯扩散，与词元取有限类别的离散状态扩散混为一谈，会造成目标函数和转移概率上的根本错误。

目录先修017、018、019、030、032、035提供概率、期望、梯度与网络基础。本讲仍会补齐三个连接环节：马尔可夫链怎样分解联合概率；已知原始点时怎样计算一个高斯后验；为什么变分下界中的KL能变成加权噪声预测误差。每一步都给出条件与端点，避免只记住一条采样公式。

实验证据是一个真正训练的DDPM：八个二维高斯团、200个离散加噪步、三种初始化、每种7000次参数更新。三个种子最终均覆盖8个模式，有效比例分别约98.46%、98.34%、99.27%。这些结果来自本包运行，不是把真实点加噪后再用已知原始点恢复，也不是直接从真实数据分布抽样冒充生成。

网络输入只有当前噪声点和时间编号，输出二维噪声预测。训练时才有原始 x_0 与我们主动抽出的 ε 作为监督；采样从标准正态开始，不访问任何真实训练点。本包提供完整数据、检查点、训练轨迹、顺序执行Notebook、公式测试与图。结论限定在这个小型合成任务，不声称这些参数能直接生成高质量真实图像。

一 先读懂马尔可夫分解

把 $x_0, x_1, \dots, x_T$ 看成同一个样本在不同噪声程度下的状态。一般的条件概率链式法则会让每一步依赖所有过去状态。马尔可夫假设将这种依赖简化为：给定紧邻的上一步后，更早的状态不再提供额外信息。因此前向条件联合分布写成：

$$q(x_{1:T} | x_0) = \prod_{t=1}^T q(x_t | x_{t-1}).$$

符号 q 专门表示我们规定的前向过程；它不含待训练的网络参数。乘积表示先从 x_0 抽 x_1 ，再从 x_1 抽 x_2 ，依次继续。它不是把 T 个独立样本相乘，因为每个条件均值都依赖上一步。完整联合分布还要乘数据分布 $q(x_0)$ 。

我们采用如下转移：

$$q(x_t | x_{t-1}) = \mathcal{N}(\sqrt{\alpha_t}x_{t-1}, \beta_t I), \quad \alpha_t = 1 - \beta_t.$$

β_t 在0与1之间，是本步加入噪声的方差；其平方根才是乘在标准正态随机数前的标准差。 I 是单位矩阵，表示各坐标噪声独立且方差相同。实现一小步相当于 $x_t = \sqrt{\alpha_t}x_{t-1} + \sqrt{\beta_t}\epsilon_t$ ，其中 ϵ_t 在不同步之间独立。

为什么还要缩小旧信号？如果只不断加噪，整体方差会一路增加。乘 $\sqrt{\alpha_t}$ 可以在输入已是标准正态时保持标准正态的方差： $\alpha_t + \beta_t = 1$ 。对我们的八团数据，初始方差并非1，因此中间和最终分布不一定精确标准正态；不过信号衰减后会越来越接近它。




图1 原创前向与反向流程。前向转移由日程固定，反向均值由一个共享网络结合时间预测；训练时可直接跳到随机时间 t_0 。

反向过程同样写成链，但方向从 T 到 0 ：

$$p_{\theta}(x_{0:T}) = p(x_T) \prod_{t=1}^T p_{\theta}(x_{t-1} | x_t).$$

下标 θ 提醒我们，反向转移含有需要训练的参数。马尔可夫结构让长联合分布可分解，但不自动告诉我们这些反向条件是什么。

二 高斯分布与条件信息

二维各向同性高斯可以用均值向量 μ 和一个标量方差 v 描述，协方差是 vI 。均值决定点云中心，方差决定每个坐标的扩散程度。若 ε 服从标准正态， $\mu + \sqrt{v}\varepsilon$ 便具有这个分布。请特别区分 v 与 $\sqrt{v}$ ，把方差直接当标准差会让噪声强度平方地偏离设计。

条件分布表示“已知一些量之后，剩余不确定性怎样分配”。例如已知原始 x_0 和当前 x_t 时，对上一步 x_{t-1} 的推断，比仅知道 x_t 时容易得多。因为 x_0 提供了这条噪声链从哪里出发的信息。训练时我们有这种额外信息，可以构造解析目标；采样时没有 x_0 ，必须让网络从大量训练经验中学到平均意义上的反向规律。

这两个分布一定要区分：

$$q(x_{t-1} | x_t, x_0), \quad q(x_{t-1} | x_t).$$

前者在本讲线性高斯前向链中可精确写为高斯；后者需要对未知 x_0 的条件分布积分，通常可能是混合分布，并不一般精确高斯。DDPM用高斯形式近似可学习的反向转移，是建模选择。较小步长可以帮助这个近似合理，但“所有反向条件本来都是高斯”是错误理由。

一个一维类比：原始数据可能来自 -2 或 $+2$ 附近，重噪声后的同一个 x_t 可能由两边都产生。仅看 x_t 无法唯一知道起点；给定起点后，剩余中间状态的推断就简单得多。网络不需要神奇地恢复这一次随机扰动的全部历史，而是在有限信息下预测对训练目标最合适的统计量。

这种信息差也解释了为何噪声预测MSE不必降到0。不同 x_0 与 ε 组合可能产生同一个 x_t ；若网络只看 x_t 和 t ，最佳平方误差预测是 ε 的条件期望。它不一定等于训练例中实际抽到的 ε 。不可约的不确定性与程序错误是两回事，不能把非零损失一律解释为模型没学会。

三 前向闭式怎样从两步推出来

把第一步代入第二步：

$$x_2 = \sqrt{\alpha_2 \alpha_1} x_0 + \sqrt{\alpha_2 \beta_1} \varepsilon_1 + \sqrt{\beta_2} \varepsilon_2.$$

ε_1 和 ε_2 独立、均值为0，因此后两项之和仍是高斯，方差为 $\alpha_2 \beta_1 + \beta_2$ 。利用 $\beta_1 = 1 - \alpha_1$ 、 $\beta_2 = 1 - \alpha_2$ ，可化为 $1 - \alpha_1 \alpha_2$ 。这里方差相加的前提是独立；如果把每步噪声都错误复用为同一个 ε ，交叉协方差不为0，公式就不成立。

定义累计信号保留量：

$$\bar{\alpha}_t = \prod_{s=1}^t \alpha_s, \quad \bar{\alpha}_0 = 1.$$

通过归纳，每一步均值乘 $\sqrt{\alpha_t}$ ，方差按 α_t 乘上一步方差再加 β_t ，得到：

$$q(x_t | x_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} x_0, (1 - \bar{\alpha}_t) I).$$

于是训练可以直接抽一个标准正态 ε ，计算：

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t} \varepsilon.$$

这个 ε 代表前 t 步累积噪声归一化后的整体扰动，不是单独第 t 步的 ε_t 。闭式抽样与逐步抽样在给定 x_0 后的边缘分布相同，通常不会逐样本相等。若要得到一条联合一致的前向轨迹，应按链逐步抽样；若只训练随机时间的一步任务，直接闭式抽样即可。

手算 $\beta_1=0.1$ 、 $\beta_2=0.2$ ，则 $\alpha_1=0.9$ 、 $\alpha_2=0.8$ 、 $\bar{\alpha}_2=0.72$ 。给定 $x_0=2$ ，一维 x_2 均值是 $2\sqrt{0.72} \approx 1.6971$ ，方差0.28。取整体 $\varepsilon=-1$ ，得到 $x_2 \approx 1.1679$ 。这是一次抽样值，不是均值，也不是原始信号减去0.28。

在 $t=0$ 处， $\bar{\alpha}_0=1$ ，闭式返回 x_0 且噪声项系数为0。程序明确允许`q_sample`使用 $t=0$ ，用来检查这个恒等端点；训练则只抽1至 T ，反向均值也只接受1至 T ，因为它在 $t=0$ 有除以 $\sqrt{1-\bar{\alpha}_0}$ 的非法项。

四 日程不只是长度为T的一串数字

本实验 $T=200$ ， β 从0.0001线性增加到0.05。为了让数学下标与数组一致，数组长度是201，索引0专作占位： $\beta_0=0$ 、 $\alpha_0=1$ 、 $\text{bar}\alpha_0=1$ 。真正的加噪步是1至200，真正的反向循环是200、199直到1，输出 x_0 后立即停止。

很多实现把 β_1 存在数组索引0，这也完全可行，但不能把两种约定混写。例如在当前代码中`torch.randint(1,201,...)`会生成1至200；如果误写`randint(0,200)`，便同时纳入不该训练的 $t=0$ 并漏掉 T 。错误往往不导致立刻崩溃，却悄悄改变整个任务。




图2 本实验实际日程。 β 是单步方差， $\text{bar}\alpha$ 是累计信号保留量；数值跨度不同，不能只看 β 末值判断终点是否近似噪声。

终点 $\text{bar}\alpha_T$ 约0.006， $\sqrt{\text{bar}\alpha_T}$ 仍非0，因此 $q(x_T|x_0)$ 并非精确 $N(0,I)$ 。我们选择标准正态作为采样先验，是在终点信号足够弱时的近似。检查终点必须看累计乘积和数据尺度；只说“加了200步，所以已经纯噪声”没有数学保证。

一个常见错误是把原论文1000步的线性 β 末值0.02照搬到200步，却不检查累计信号。缩短 T 后噪声未必足够抹去数据结构。本实验选0.05是二维教学中的明确配置，不是通用于图像的推荐值，也不是原论文完全复刻。

日程还决定不同时间的学习难度。在小 t 处噪声轻微，预测噪声可能需要区分数据自身的局部变化；在大 t 处 x_t 本身接近噪声，预测整体 ε 可能反而较容易。不能想当然认为时间越大，噪声MSE一定越大。后面的分时间区间统计能检验这个直觉。

数据尺度同样重要。本课八团半径为2、团内标准差0.08，没有额外归一化。若坐标整体乘100却保持日程不变，终点的残余信号也放大100倍，标准正态先验近似会恶化。预处理、日程和先验必须一起说明。

五 已知 x_0 的后验：完成平方

设 $t \geq 2$ ，把待推断的上一步记为 $y = x_{t-1}$ 。由贝叶斯规则与马尔可夫性质，忽略不含 y 的归一化常数后：

$$q(y | x_t, x_0) \propto q(x_t | y)q(y | x_0).$$

第一项均值为 $\sqrt{\alpha_t}y$ 、方差 β_t ；第二项均值为 $\sqrt{\bar{\alpha}_{t-1}}x_0$ 、方差 $1 - \bar{\alpha}_{t-1}$ 。把两个高斯的负对数相加， y 的二次项系数（精度）为：

$$A = \frac{\alpha_t}{\beta_t} + \frac{1}{1 - \bar{\alpha}_{t-1}} = \frac{1 - \bar{\alpha}_t}{\beta_t(1 - \bar{\alpha}_{t-1})}.$$

精度的倒数就是后验方差。线性项系数为 $h = \sqrt{\alpha_t}x_t/\beta_t + \sqrt{\bar{\alpha}_{t-1}}x_0/(1 - \bar{\alpha}_{t-1})$ 。将二次式写成 $A\|y - h/A\|^2$ 加常数，可读出后验均值 h/A ：

$$\tilde{\beta}_t = \frac{1 - \bar{\alpha}_{t-1}}{1 - \bar{\alpha}_t} \beta_t.$$

$$\tilde{\mu}_t = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t} x_0 + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t} x_t.$$

这不是神经网络近似，而是已知 x_0 后的解析结果。它为训练提供一个可计算的目标分布。注意均值中的两个系数一般不恰好相加为1，不能不加说明地把它叫作普通的凸加权平均。

仍用 $\beta_1=0.1$ 、 $\beta_2=0.2$ ， $\bar{\alpha}_1=0.9$ 、 $\bar{\alpha}_2=0.72$ ，得到 $\tilde{\beta}_2=0.2 \times 0.1/0.28 \approx 0.0714286$ 。 x_0 的系数约0.677631， x_2 的系数约0.319438。若 $x_0=2$ 、 $x_2=1$ ，则后验均值约1.67470。

$t=1$ 是特别边界：给定 x_0 后，要推断的 x_0 已经被知道，后验退化为点质量， $\tilde{\beta}_1=0$ 。均值公式形式上返回 x_0 ，但不能把这个零方差后验与普通非退化高斯一起机械代入含log方差的KL公式。变分分解把这一端点作为重构项单独处理，正是下一节要解释的事。

六 为什么需要变分下界

反向模型定义联合分布后，数据的边缘密度需要把所有潜在中间状态积分掉：

$$p_{\theta}(x_0) = \int p_{\theta}(x_{0:T}) dx_{1:T}.$$

对一个有200步神经网络转移的模型，这个积分通常很难直接求。训练时我们有已知的前向分布 $q(x_{1:T}|x_0)$ ，可以在积分中乘除同一个 q ，把边缘密度写成一个期望。再利用log的凹性，也就是Jensen不等式，得到：

$$\log p_{\theta}(x_0) \geq \mathbb{E}_q[\log p_{\theta}(x_{0:T}) - \log q(x_{1:T} | x_0)].$$

右边叫证据下界ELBO。它是对log密度的下界；取负号后就变成负log密度的上界。符号容易记反：如果我们的损失 L 是负ELBO，那么 $-\log p_{\theta}(x_0) \leq L$ 。最小化上界是一条可计算的训练路线，但上界不一定等于真实负对数似然。

这个差距可精确写成前向条件 q 与模型真实后验 $p_{\theta}(x_{1:T} | x_0)$ 之间的KL。KL非负，因此不等式方向成立；只有两者一致时差距为0。这里 q 不是另一个本课要训练的编码器，而是预先固定的噪声链，所以不需要先实现VAE实验才能理解推导。

KL的含义是比较两个分布。它在两个分布一致时为0，通常不对称；不是比较两个样本点的欧氏距离。后面之所以出现平方误差，是因为特定高斯分布的KL能够化简，而不是任何KL都天然等于MSE。

在计算机里训练时，我们用随机 x_0 、随机 t 、随机 ϵ 估计期望。即使公式定义了一个严格上界，单个随机批次的数值也不一定处处大于每个样本的真实负对数密度；上界关系是完整期望和正确目标下的数学陈述。进一步换成无权重噪声MSE后，更不能拿日志数字直接当似然上界。

七 把长链下界拆成三类项

为了把ELBO变成容易训练的表达式，先把前向联合分布反向分解。给定 x_0 时，有：

$$q(x_{1:T} | x_0) = q(x_T | x_0) \prod_{t=2}^T q(x_{t-1} | x_t, x_0).$$

将这个式子和模型联合分解同时代入负ELBO，按log项分组，得到三部分。第一部分是终点前向分布与采样先验的KL：

$$L_T = \text{KL}(q(x_T | x_0) \| p(x_T)).$$

第二部分对 $t=2$ 至 T 逐项比较已知 x_0 的后验与模型反向转移：

$$L_{t-1} = \mathbb{E}_{q(x_t | x_0)} \text{KL}(q(x_{t-1} | x_t, x_0) \| p_\theta(x_{t-1} | x_t)).$$

第三部分是 $t=1$ 端点的重构负log密度：

$$L_0 = -\mathbb{E}_{q(x_1 | x_0)} \log p_\theta(x_0 | x_1).$$

三类相加，再对数据 x_0 取期望，便是负ELBO。记号 L_{t-1} 表示与从 t 退到 $t-1$ 的转移有关，名字里出现 $t-1$ 不意味着代码应该把时间输入也减1。网络在预测这一步时看到的是 x_t 和 t 。

固定日程与标准正态先验后， L_T 不含 θ ，因此优化网络参数时可以忽略它；“可以忽略梯度”不代表其值为0，也不代表先验近似完美。本包不报告完整似然，便不必把它与端点常数混进训练日志。若要报告ELBO，应把所有项按定义完整计算。

对于连续二维数据，本讲理论端点可选择正方差高斯 $p_\theta(x_0 | x_1) = \mathcal{N}(\mu_\theta, \beta_1 I)$ ，于是 L_0 是含归一化常数的连续密度损失。它不同于真实图像整数像素的离散概率解码器。离散像素要考虑概率质量和量化区间，不能把连续密度数值原样称为每个像素的概率。

这套分解与DDPM原论文第二、三节对应。本讲后续明确区分理论密度、简化训练目标和最后一步不加噪的展示采样，不把三者偷偷当成同一件事。

八 高斯KL怎样变成均值误差

设已知 x_0 的后验是 $N(\tilde{\mu}, \tilde{\sigma}^2 I)$ ，模型反向转移是 $N(\mu_\theta, \sigma^2 I)$ ，维度为 d 。当 $t \geq 2$ 且两个方差都正时，高斯KL为：

$$\frac{1}{2} \left[d \left(\frac{\tilde{\beta}_t}{\sigma_t^2} - 1 + \log \frac{\sigma_t^2}{\tilde{\beta}_t} \right) + \frac{\|\tilde{\mu}_t - \mu_\theta\|^2}{\sigma_t^2} \right].$$

若 σ^2 固定，不依赖 θ ，第一部分是和网络参数无关的常数。网络需要最小化的是均值差平方，权重为 $1/(2\sigma^2)$ 。若进一步 $\sigma^2 = \tilde{\beta}_t$ ，方差那一整块恰好为0；若选择 β_t ，它通常不为0，但仍是固定日程下的常数。

本实验对 $t \geq 2$ 选择 $\sigma^2 = \tilde{\beta}_t$ 。方差越小，同样的均值误差在KL里代价越大，这符合直觉：一个窄分布对中心错位更加敏感。但我们实际训练还会采用去掉时间权重的简化目标，因此不能仅凭“固定后验方差”就说日志等于高斯KL。

手算一维同方差例子：两个高斯方差都是0.25，均值相差0.2，KL等于 $0.2^2/(2 \times 0.25) = 0.08$ 。若方差改成0.01而均值差仍为0.2，KL变为2。相同欧氏误差在不同噪声尺度上的概率意义完全不同。

若方差也由神经网络预测，原先被称为“常数”的项就可能依赖 θ ，不能删掉再沿用同样推导。本课不训练方差，也不引入学习方差的扩展模型。代码、数学和报告必须对这个选择保持一致。

$t=1$ 不能把 $\tilde{\beta}_1=0$ 放进上述公式，因为那是退化点质量而非普通连续高斯密度。理论上端点用L0处理，程序上采样末步也单独分支。许多“loss突然变NaN”的问题，根源不是学习率，而是在端点把 $\log 0$ 或除以0带进了本不适用的公式。

九 从均值预测改写为噪声预测

由前向闭式可以把原始点解出来：

$$x_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t} \varepsilon}{\sqrt{\bar{\alpha}_t}}.$$

把它代入后验均值公式，合并 x_t 的系数后得到：

$$\tilde{\mu}_t = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \varepsilon \right).$$

训练时 ε 已知，但采样时未知。于是定义网络 $\varepsilon_\theta(x_t, t)$ ，用它替换 ε ，便得到模型反向均值 μ_θ 。网络输出不是新的样本，也不是方差，而是与状态同维的噪声估计。每次采样时，先算均值，再按选定方差加入新的反向随机噪声。

两个均值的差只剩噪声预测误差乘一个确定系数。代入上一节均值KL项，可得 $t \geq 2$ 时：

$$L_{t-1} = w_t \mathbb{E} \|\varepsilon - \varepsilon_\theta(x_t, t)\|^2 + C_t,$$

$$w_t = \frac{\beta_t^2}{2\sigma_t^2 \alpha_t (1 - \bar{\alpha}_t)}.$$

这里 C_t 与 θ 无关， w_t 通常随时间变化。实验使用的简化目标不带 w_t ，且对两个坐标取平均：

$$L_{\text{simple}} = \mathbb{E}_{t, x_0, \varepsilon} \frac{1}{d} \|\varepsilon - \varepsilon_\theta(x_t, t)\|^2.$$

t 在1至 T 均匀抽取， $d=2$ 。平方和与坐标均值差一个常数2；KL时间权重的变化则不是单一常数能够消除。若精确估计各时间KL总和，还要考虑随机抽时间后的求和缩放，例如均匀抽取时乘相应项数。省略这些细节便不能声称计算了精确ELBO。

因此本实验日志是噪声预测MSE，不是精确负log似然，也不是完整ELBO。它是基于高斯推导启发的重加权训练代理目标。这个目标可以生成很好的样本，但样本质量与密度估计仍应分别评价。推导关系解释了为什么预测噪声有用，并不赋予任意MSE“精确似然”的名称。

十 时间嵌入让同一网络知道噪声程度

相同坐标 x_t 在不同 t 下有不同含义。 t 很小时，它可能已接近一个真实团； t 很大时，它可能主要是高斯噪声。若不给网络时间信息，网络必须用同一映射应对相互冲突的条件任务。时间不是训练迭代次数，而是一个样本在噪声链中的位置。

本实验将 $u=t/T$ 与六组正弦余弦拼接，频率为1、2、4、8、16、32，角度为 πfu 。时间向量共13维，再与二维 x_t 拼接为15维输入。网络采用 $15 \rightarrow 96 \rightarrow 96 \rightarrow 96 \rightarrow 2$ 和SiLU激活。所有 t 共享同一组参数，而不是训练200个独立网络。

一轮训练包含六步：从固定4096个训练点里抽256行；为每行独立抽 t ；独立抽同形状 ϵ ；通过闭式得到 x_t ；用网络预测 ϵ ；对全部行与坐标求平均平方误差并更新一次参数。训练无需显式走完200步前向链，这正是闭式的计算价值。

```
t = torch.randint(1, T + 1, (batch_size,))
eps = torch.randn_like(x0)
xt = q_sample(x0, t, eps, schedule)
pred = epsilon_model(xt, t)
loss = ((pred - eps) ** 2).mean()
```

验证集2048行使用独立数据种子621；时间和噪声使用固定种子622，因此跨训练阶段的验证MSE可比较。我们不依据验证结果挑选最佳检查点，三个种子都用7000步最终模型。固定验证随机数减少曲线噪声，但正式评估时仍应意识到它只是一组有限样本。




图3 三个种子的验证噪声MSE和分时间区间MSE。大 t 处的预测可能比小 t 处容易；一条平均曲线会掩盖这种差别。

零预测器始终输出0，对标准正态噪声每坐标的期望MSE是1。实际验证噪声是有限样本，因此基线不会恰好等于1。训练后的整体验证MSE约0.29，明显低于零预测基线，但不能据此宣布已经知道了精确数据似然或保证所有模式概率一致。

十一 真正采样时不能偷看原始点

采样先抽 $x_T \sim \mathcal{N}(0, I)$ ，然后从 $t=T$ 倒数到1。每步把 x_t 与 t 送进网络，得到 ϵ 预测并构造 μ_θ 。对 $t>1$ ，再加入标准差 $\sqrt{\tilde{\beta}_t}$ 乘新的独立标准正态 z ：

$$x_{t-1} = \mu_\theta(x_t, t) + \sqrt{\tilde{\beta}_t} z, \quad t > 1.$$

最后 $t=1$ ，本实验默认返回 $\mu_\theta(x_1, 1)$ ，不再注入随机噪声。这与常见DDPM展示采样约定一致。它不是从前面选定的正方差端点密度 $\mathcal{N}(\mu_\theta, \beta_1 I)$ 精确抽样；为使区别可检查，代码提供`terminal_noise=True`，末步加入 $\sqrt{\beta_1} z$ ，并另存对应样本与指标。




图4 同一批真实生成轨迹，从标准正态 x_{200} 经过 x_{150} 、 x_{100} 、 x_{50} 到 x_0 。每一步只访问网络、当前状态和日程，不访问训练样本。

这里涉及三个不同的“噪声”。训练监督 ϵ 是闭式前向累计噪声；网络输出 ϵ_θ 是对它的估计；反向每步抽的 z 是新随机变量。把训练例中已知 ϵ 直接带到采样，或在生成时使用真实 x_0 计算后验均值，都属于把答案泄露给模型，不能称为真正生成。

同样不能每一步重新抽一个 x_T ，否则上一轮反向计算的结果被丢弃，链便断了。正确做法是把新 x_{t-1} 作为下一步网络输入，直到得到 x_0 。代码保存若干中间状态帮助检查这个依赖；不同 t 的子图展示的是同一批样本的推进。

我们的所有反向网络调用严格使用 $t=200$ 至1，无 $t=0$ 调用。训练网络也从不接收 $t=0$ ，因此最后多调用一次不仅数学公式非法，还超出了训练时间范围。边界测试会用记录时间的虚拟模型核对这个调用序列，防止看似不起眼的`range`写错。

十二 从二维结果得出有限结论

评价规则与第061单元保持同样直观含义：点到最近真实中心距离 ≤ 0.35 视为有效；每个模式收到至少全部4096个生成样本的1%才算覆盖。中心只用于评价，不用于网络训练损失或采样。三种种子都达到8/8覆盖，有效比例接近99%，但模式占比仍有差别。




图5 三个最终DDPM样本与独立参考数据，所有图保持相同坐标范围。覆盖与有效比例同时报告，避免只展示筛选后的点。

种子11有效比例0.9846，种子23为0.9834，种子37为0.9927。最高条件模式占比依次约0.1349、0.1661、0.1481，而理想均匀八团为0.125。有限生成样本会带来统计波动，网络也可能存在分配偏差；仅凭视觉接近不能宣布概率完全正确。

当前DDPM在这套数据上比第061单元的基础GAN有更高有效比例，但这不是公平算法排行榜。两课模型结构、更新次数、采样成本和优化选择不同。GAN通常一次前向即可产生点，本DDPM需要200次网络调用；它使用了更多训练步骤与不同训练目标。比较方法需要约定共同预算和多套配置，不能凭一个教学配置断言普遍优劣。

这次实验没有计算似然、FID或图像感知质量，也没有测试条件生成、文字提示或分类器引导。二维高斯团没有真实图像中的纹理、语义与版权问题。课程下一步可以迁移到小图像，但迁移前应保留这里已经建立的数学与边界检查，而不是只复制一个更大的网络。

采样随机种子与训练种子分开记录。相同模型换采样种子会改变点云，但不改变参数；换训练种子会改变模型本身。若要估计评价不确定性，可以固定检查点反复采样，再在多个训练种子之间比较，两层变异不应混为一个标准差。

十三 错误检查表与下一步

第一类错误来自索引。确认数组位置0代表干净端点，训练 t 只在1至 T ，反向循环包含 T 与1且不调用0。

第二类来自方差。 β 、 $1-\bar{\alpha}$ 与 $\tilde{\beta}$ 分别代表单步前向、累计前向和已知 x_0 后的后验方差，不能互换；采样乘的是其平方根。第三类来自条件信息。训练可用 x_0 与 ϵ ，采样只能用 x_t 、 t 和网络。

第四类来自目标解释。简单噪声MSE省略时间权重、端点密度和先验项，不能直接叫精确似然。第五类来自过度评价。低MSE、高覆盖或漂亮图各自只测量一部分现象，要同时检查概率分配、样本质量、计算预算与随机性。

本包单元测试包含闭式与逐步前向的矩比较、后验均值两种表达式的一致性、噪声误差与KL均值项的等价性、 $t=0$ 恒等、 $t=1$ 零后验方差、反向时间序列、非法索引与不匹配形状。正常与-O模式都运行，以确认输入检查不会随着assert被移除而消失。测试是公式到代码的连接，不应只是检查文件是否存在。

本讲的核心链条

从马尔可夫结构出发，固定高斯前向转移；由独立噪声的线性组合推得任意时间闭式；在知道 x_0 时通过完成平方求后验；用Jensen得到可训练的变分界；把中间高斯KL化为均值差；再用前向闭式把均值差改写为噪声误差。实际训练选择简化无权重MSE，实际采样明确处理末步边界。每个箭头都带条件，不能跨过条件直接套用结果。

主要来源与原创范围

Ho、Jain、Abbeel, [Denoising Diffusion Probabilistic Models](#)给出本讲采用的离散时间框架、噪声参数化和简化目标。Sohl-Dickstein等, 2015是前向破坏与反向建模路线的重要早期来源。本包的二维数据、网络尺寸、200步日程、训练输出、数值例子、图与练习均独立制作，不复制论文图像或宣称复现其图像基准成绩。

完成实验后，你应能不用背诵地回答：为何训练无需走完前向链？为何给定 x_0 的后验高斯不意味着真实反向条件总是高斯？为何 $t=1$ 不能套普通KL？为何一个0.29的训练指标不能当作数据的负log似然？这些问题比记住某个采样器名字更能检验理解。