

生成模型评价与风险习题解答

第063单元 用分解推理检查结论

本解答给出计算过程与判断边界。它不是一份只列指标名称的答案表。若你的结果不同，先定位自己改变的是定义、样本、模型还是数值精度；这四类变化对应不同修正方式。

任务A 质量覆盖和条件熵

100个点中90个有效，所以质量为0.9。中心0、1、2分别占全部点0.4、0.3、0.2，都超过0.01；其他中心为0，所以覆盖为3。有效条件分布为4/9、1/3、2/9，熵计算为：

$$H = -\frac{4}{9}\log\frac{4}{9} - \frac{1}{3}\log\frac{1}{3} - \frac{2}{9}\log\frac{2}{9} \approx 1.0609.$$

熵只描述有效点之间如何分配，故分母90；覆盖定义要求某团拥有全部输出中至少1%的有效质量，故分母100。若把两者都除以90，等于改了覆盖定义。改变定义可以作为另一个实验，但必须换名字并重新说明，而不是误以为实现等价。

200个点中只有1个有效，质量1/200=0.005。有效团计数占全部输出0.005，小于0.01，故覆盖0。若分母误用有效总数1，就会得到比例1，错误覆盖1。这个例子比随机测试更有力，因为它专门把两种实现放到不同答案上。

4096点时最低计数为41：40/4096 $\approx$ 0.0097656，41/4096 $\approx$ 0.0100098。阈值采用大于等于，因此恰好0.01的情况应该算覆盖。测试既要检查远离阈值的普通情况，也应检查边界和无有效点情形。

多样性的补充判断

重复一个中心的4096个点，质量1、覆盖1、熵0；在八个中心各重复512次，质量1、覆盖8、熵log8。但后者的团内方差为0，仍与真实高斯团不同。模式级指标可以全部很好，类内结构却错误。这个反例说明多个指标不是为了凑数量，而是分别约束不同部分。

一 高斯距离的数值与反例

任务B 手算距离

一维公式是均值差平方加标准差差平方。给定均值0与1、标准差1与2，得到 $1+1=2$ 。若误用方差差平方，会得到 $1+9=10$ 。方差有原坐标的平方单位，直接再平方也会使量纲不匹配。

二维对角例子中均值项为1，协方差项为 $(1-2)^2+(2-1)^2=2$ ，所以总计3。因为两个协方差在同一坐标轴上对角化，这里可以逐坐标计算；一般有旋转的非对角矩阵不能盲目只读对角元素。

为什么一维共用Z是最优？对任意具有指定均值和标准差的耦合，展开 $E[(X-Y)^2]$ 后，固定项之外只有 $-2\text{Cov}(X,Y)$ 。Cauchy-Schwarz给 $\text{Cov}(X,Y) \leq \sigma_X \sigma_Y$ ；共用Z达到上界，因此平方代价最小。这个推理解释公式来源，而不只是记住符号。

旋转反例

原八中心均值为0；对称性使坐标交叉和为0，两个坐标平方和相同。旋转22.5度不改变这个各向同性协方差，因此拟合高斯距离为0，数值代码可能留下极小舍入误差。

几何上到最近原中心的距离是弦长：

$$d = 2R\sin(\Delta/2) = 4\sin(\pi/16) \approx 0.78036.$$

$R=2$ ，旋转角 $\Delta=\pi/8$ 。因此所有旋转点都在半径0.35的有效域之外，质量0、覆盖0。指标没有算错，它准确反映了自身只比较前两阶矩的限制。

两组同时乘10，均值差乘10，协方差乘100，最后距离乘100。只有一组缩放时，相对均值与方差关系改变，不能把原距离整体乘100。实验若使用了不同预处理，差异可能来自单位，而非模型生成能力。

二 训练接口与公平性的答案

任务C VAE目标和采样

批量128下，各输入与二维输出为 128×2 。编码均值和对数方差也是 128×2 。重参数化使用 $\exp(\text{lv}/2)$ 而非 $\exp(\text{lv})$ ，因为 lv 是对数方差，抽样乘的是标准差。每样本NLL先把两个坐标的贡献求和；KL也先按潜变量坐标求和；之后求128个样本的均值。

固定 $\sigma=0.15$ 定义条件分布 $p(x|z)$ 的标准差，不是训练噪声大小的随意显示选项。先验生成 $x=\text{decoder}(z)+0.15\epsilon$ ，才从所定义模型抽样。只取 $\text{decoder}(z)$ 产生条件均值分布，通常更集中；比较时必须把它视为不同的输出协议。

任务D GAN梯度边界

判别器更新用`detach`切断生成网络，避免该步给生成器累积梯度。生成器更新冻结判别器参数，却仍计算D对其输入的导数。链式法则需要D输入梯度乘G参数梯度；如果把整个D计算置于`no_grad`，后半条路径无法传播。冻结参数与禁止运算记录不是同一操作。

VAE有9094参数。GAN生成器4482、判别器4417，总计8899。VAE4000次优化器调用；GAN4000次生成器加4000次判别器调用。两者主生成部分更新数和真实小批次次数匹配，但FLOPs、总优化器调用和最优超参数搜索没有匹配。正确报告应同时列出匹配与未匹配项目。

任务E 指标冲突

本次VAE三种子有效比例均值约0.7073，GAN约0.7576。全部覆盖8；坐标高斯距离VAE更低，加入角度后的距离GAN更低。一个合理解释是坐标矩只看总体位置和尺度，不能完全反映团间错误质量。这个解释由旋转控制支持，但不能排除有限样本、模型方差和其他误差来源。

不能从近邻中位数较小推断“GAN更会复制”，因为GAN也有更高的有效比例，更集中在真实密集区域，独立真实点在那里同样容易找到近邻。需要同时看留出距离、精确副本和其他控制。相关数值必须回到测量定义解释。

三 样本量与记忆审计的答案

任务F 三种波动量

20次重复的均值估计期望分数；样本标准差描述一次抽样所得分数的典型波动；标准误为样本标准差除以 $\sqrt{20}$ ，描述这20次均值估计的波动。图中画的是标准差，不能在报告中改称95%置信区间。若构造置信区间，还需要选择相应分布近似并解释独立性。

样本量32、128、512、2048的均值约0.2246、0.0521、0.0197、0.0051。两个分布本来相同，说明有限样本会使插件分数非零。把一个模型用32点、另一个用2048点评价，会把模型差异与估计偏差混在一起。多抽样提高测量精度，不会改变已固定网络的生成分布。

一维均值差方差的推导是 $\text{Var}(X-Y)=\text{Var}(X)+\text{Var}(Y)$ ，独立使协方差为0；两组各有 n 点，所以得到 $2\sigma^2/n$ 。这个结果只计算均值项，不是整个高斯距离偏差的完整表达式。

任务G 近邻散点

点位于对角线上方时 $d_H > d_T$ ，即训练集合更近。下方则留出更近。即使生成分布等于真实分布，固定有限训练与留出集合的局部密度也不同，单次比例无需恰好0.5。我们的oracle控制约0.507只是本次观察，不是强制成立的单位测试。

复制器从训练数组抽原样本，精确训练匹配率1；留出集独立且连续，精确匹配率本次为0。所有六个神经模型的精确训练匹配率本次为0。这证明给定抽样预算和容差下没有检出原样点，不能证明模型永不泄漏，也不能覆盖被轻微变换的副本。

一个可能漏检的图像复制是裁剪后再缩放，它可能保留内容却改变像素距离。一个不代表记忆的近邻情形是所有真实图像都为几乎相同的产品正面照。可考虑针对任务验证的感知特征、变换不变匹配与样本来源复核；任何新评价器又有新的盲点，不能因为换了名字就视为完备。

四 复现验收和一份合格结论

任务H 检查点验收

六个检查点按family恢复模型结构，加载state_dict，调用eval，再用保存sampling_seed抽样。样本数量、潜变量维数、VAE σ 和随机数调用顺序都必须一致。仅加载权重并不自动恢复代码外的采样约定，因此检查点同时保留家族、种子与更新步数。

Notebook逐元素比较六份samples与means；完整重新执行也可与教材固定outputs比较，排除墙钟秒数字段后数值应在当前相同CPU运行环境中一致。跨平台或版本结果可能不同，这时先比较合理容差内的数值和统计结论，不应假装逐位一致是PyTorch对所有环境的保证。

合格报告示例

“我们在原创二维八团数据上，以同一训练集、每次128点、4000次主模型更新、三种子和4096点评价比较了本包VAE与GAN实现。两者均覆盖8团；GAN本次有效比例更高，VAE坐标高斯距离更低。旋转控制证明坐标前两阶矩会漏掉模式错位；加入角度特征后排序改变。预算没有匹配FLOPs，也没有进行大规模家族调参，因此结论仅适用于这些实现与协议。”

“质量和覆盖都很好的训练复制器被近邻审计检出。六个网络在本次采样与容差下没有精确训练副本，但这不是隐私保证。模型均无条件，因此条件一致性不适用。真实图像、提示遵从和敏感数据风险尚未测试。下一步可固定权重，改变评价样本数并重复抽样，检验当前排序是否稳定。”

这份结论保留冲突、交代控制并列边界，没有把“需要更多研究”当空泛结尾。若一份报告只剩“GAN比VAE好”，它丢失了题目、指标、预算、样本量和不确定性，不能支持可靠行动。

常见错误更正

“损失更小所以样本更好”应改为分别解释各目标与统一外部评价。“FID为0说明分布相同”应限制为所拟合的特征高斯一致。“近邻很近说明泄漏”应补充同大小留出比较和检出定义。“零重复说明安全”应改为给定预算下未检出。“只需要漂亮图”应补固定随机样本、失败样本和完整计数。理解这些限定不是保守措辞练习，而是把一个数还原成它真正测到的对象。