

生成模型评价与风险实验

第063单元 从公平协议到近邻审计

本实验交付物是一份能被他人复跑的VAE与GAN比较。目标不是证明哪个家族永远更好，而是学会让指标、数据、预算和结论对应起来。推荐先读讲义第一至八节，再运行代码，最后带着实际结果阅读审计与风险部分。

准备环境和理解目录

在本单元文件夹中创建独立Python环境，推荐Python3.11或3.12。只需CPU，不下载外部数据，不需要账户或GPU。requirements.txt列出实验、Notebook及文档重建依赖；environment.yml提供等价的环境入口。中文PDF重建还需要Noto CJK字体与WeasyPrint系统库。

```
python -m pip install -r requirements.txt
python -m unittest -v test_experiment.py
python -O -m unittest -v test_experiment.py
python experiment.py
python make_figures.py
```

前两条测试命令应各运行20项测试并结束于OK。完整训练为六个模型，每个4000轮，CPU耗时依硬件而变。experiment.py重建outputs中的同名文件；若想保留一次新结果，使用python experiment.py --output my_run。不要把--steps改短后仍把结果称为教材完整配置。

data/mixture.npz含训练、近邻留出、特征参考、独立真实控制四组数组。outputs/results.json是完整测量，protocol.json是机器可读协议。六个pt文件是真实训练权重，六个samples.npz包含生成点、解码均值与近邻距离。四个control.npz是明确构造的指标控制，不是网络训练结果。

实验前写下三个预测

在看数值前写：一，质量与坐标高斯距离是否一定给出同一排序；二，旋转八中心能否被坐标距离识别；三，训练复制器能否同时在质量和覆盖上很好。每个预测写一句理由。这个小步骤让你能区分“原先假设”与“看到答案之后的解释”，是研究记录最简单的起点。

一 用手算验证指标代码

任务A 质量与覆盖

构造100个点：40个在中心0，30个在中心1，20个在中心2，10个远离所有中心。半径仍为0.35，最低频率仍为1%。不运行代码先算有效比例、覆盖数、有效条件分布及熵。然后调用mode_metrics核对。解释熵使用90作为分母，而覆盖使用100作为分母的理由。

再构造200个点：只有1个在中心0，199个远离所有中心。质量应很低，覆盖应为0。若你的实现返回覆盖1，请查它是否误用了有效点数作覆盖分母，或把“出现过”当成“达到最低频率”。这里错误不会导致Python崩溃，因此必须用有明确答案的样例测试。

任务B 高斯距离

一维真实均值0、标准差1；生成均值1、标准差2。手算距离并说明为什么不是把方差1与4直接相减再平方。接着构造二维对角协方差 $C_r = \text{diag}(1, 4)$ 、 $C_g = \text{diag}(4, 1)$ ，均值差(1,0)，手算结果。

代码接收的是样本而非任意均值协方差，随机抽有限样本时结果不必等于理论值。若要验证解析矩阵公式，可单独调用psd_sqrt，或构造对称点集精确匹配指定样本矩。不要因为随机样本结果有0.01差距就立刻认定公式错了。

```
import numpy as np
import experiment as e
x = e.centers().astype(float)
a = np.pi / 8
rotation = np.array([[np.cos(a), -np.sin(a)],
                      [np.sin(a), np.cos(a)]])
y = x @ rotation.T
print(e.mode_metrics(y))
print(e.gaussian_feature_distance(x, y))
```

记录两个输出为何并不矛盾。把同一对样本都乘10，检验坐标距离是否乘100。再只缩放一组，解释为什么此时不能用同一个简单倍率关系。每一步都要写清缩放发生在原始样本、特征还是最终指标上。

二 重训两类模型并核对预算

任务C 跟踪一次VAE更新

阅读train函数中的VAE分支。标出训练批次 x 、重参数化噪声 ϵ 、编码均值 μ 、对数方差 $\ln v$ 、解码均值 pred 、NLL与KL的形状。批量128时， x 和 pred 为 128×2 ， μ 和 $\ln v$ 也为 128×2 ，NLL与KL各为128维，最终loss是标量。

写出本课固定观测标准差0.15的意义。生成代码为何在decoder(z)之后仍然加噪声？把means与samples分别画出可以帮助理解，但主表必须继续评价samples，不能看到means更集中就无声替换采样定义。

任务D 跟踪一次GAN更新

判别器更新时生成点被detach，防止更新生成器；生成器更新时冻结判别器参数，却保持判别器对输入的梯度。找到这两处代码并解释：若整个判别器前向放在no_grad内，为什么生成器会失去需要的学习信号？

核对protocol.json：三种子11、23、37，批量128，主模型更新4000，生成数4096。分别记录VAE和GAN的参数数量、辅助网络参数量、优化器调用次数。两者各看4000个真实小批次，但GAN还有4000次判别器优化。因此“更新次数完全一样”“计算成本完全一样”都不是准确表述。

任务E 保留完整结果

把六行有效比例、覆盖和三种特征距离写到你的报告，不能只写最佳种子。计算每类质量均值与样本标准差，但保留原始三行，因为三个种子不足以精确估计尾部失败概率。检查距离排序是否随特征改变，并用讲义中的几何盲点给出一个可检验解释。

建议报告一句形式为：“在某数据、某预算、某指标下，观察到某差异；其他指标出现某结果；尚不能推出某结论。”这里的限制必须具体，例如尚未比较图像、尚未匹配FLOPs、尚未搜索最优超参数，而不是笼统地说“可能有局限”。

三 检查样本量和记忆控制

任务F 分离估计误差与模型差异

打开sample_size_audit。每个n有20个数，来自同一真实分布的两组独立抽样。重算均值、样本标准差与均值标准误。解释图中误差线为何是标准差，不是均值标准误。三个量的单位相同，但回答的问题不同。

若把一模型评估为32个点、另一模型评估为2048个点，哪类混淆会进入排序？写出至少一个由均值估计引起的偏差来源。不要把“多抽样后分数通常变小”误认为模型被重新训练得更好。本实验中生成分布没有任何改变。

任务G 匹配参考大小的近邻审计

读取vae_seed11_samples.npz中的train_distance与holdout_distance，画散点并加对角线。对角线上方表示训练更近，下方表示留出更近。两边各有多少点？为什么“上方必须恰好一半”不是单次有限样本实验的定律？

用copier_control.npz重复。复制控制应有全部train_distance为0，精确训练匹配率为1。它的质量与覆盖可能满分，这正是审计需要独立于总体质量的原因。再看oracle_control，它不是神经生成器，而是从已知真实分布独立抽样的参照。

```
import numpy as np
import experiment as e
d = np.load('data/mixture.npz')
s = np.load('outputs/copier_control.npz')['samples']
report, distances = e.audit(s, d['train'], d['holdout'])
print(report)
```

提出一个欧氏近邻可能漏检的真实图像复制方式，例如裁剪或轻微旋转。再提出一种会产生近邻但不代表记忆的情况，例如目标分布本来很窄。你提出的后续检测应与失败方式对应，不能只说“换一个更大的模型”。本课没有真实个人数据，勿把这个练习用于探测他人的敏感内容。

四 复生权重并完成评价报告

任务H 验证检查点确实产生保存样本

Notebook最后一节受限加载六个pt文件，用保存的采样种子生成样本，再逐元素比较samples和means。运行以下命令可重新创建与执行Notebook；执行结果写回experiment.ipynb，训练结果写入notebook_outputs，不覆盖讲义固定结果。

```
python create_notebook.py
python execute_notebook.py experiment.ipynb
```

确认所有代码单元有顺序执行计数，无error输出，并且散点与样本量图是嵌入的PNG，不只是当前内核中的临时对象。本包执行器使用新进程内的IPython内核，适合无需网络socket的CPU环境；不声称验证浏览器端交互。普通Jupyter也可打开该文件并逐格运行。

最终报告结构

第一段写研究问题与适用范围。第二段写数据拆分、预处理、模型配置、匹配预算及未匹配资源。第三段给全部种子结果和固定样本图。第四段解释质量、覆盖与特征排序冲突。第五段给样本量控制和最近邻控制。末段写出条件一致性尚未测试、近邻零匹配不构成隐私保证，以及一个具有明确停止条件的后续实验。

推荐后续实验是“固定两个模型权重，仅改变评价样本数，重复抽样检查排序稳定性”。它不混入新训练误差，能回答排名是否容易被估计噪声翻转。若要比新的网络配置，另建验证选择规则与保留测试集，不要反复根据本份参考结果调参却继续称之为独立测试。

自检标准

你应能独立解释五个区别：密度与概率、ELBO与精确似然、质量与覆盖、真实模型输出与人为控制、未检出复制与证明隐私安全。数学自检至少包含覆盖分母和一维高斯距离。工程自检包含20项普通及优化模式测试、完整训练日志、检查点复生和Notebook图像输出。

正文PDF可用build_pdf.py从Markdown重建。资料内容只引用公开一手来源；合成数据和图由本单元代码生成。若运行结果与教材不同，先核对PyTorch、NumPy、种子、线程和steps，再检查是否改过采样或指标，而不是删掉不符合预期的种子。