

表示或生成研究项目解答

第064单元 负结果也需要完整论证

任务A 合格的实验前声明

“在原创8×8带噪条纹数据、四维潜变量前馈VAE、Adam学习率0.003、批量64和2000次更新下，比较前500步线性KL预热与恒定 $\beta=1$ 。五个配对种子共用架构、初始化、小批次索引和重参数化噪声。主指标为固定512例测试集32次Monte Carlo估计的负ELBO。平均差 ≤ -0.2 、至少4/5胜且生成有效率平均下降 ≤ 0.02 才支持收益假设。另做双预算恒定对照，固定终点完成后停止。”

这段声明给出了可执行的边界。它没有承诺结果一定正面，也没有把未来可探索的所有日程都塞入本次问题。若读者选择另一门槛，应在实验前说明，并把它作为另一个协议；不能在当前结果出来后重写历史。

机制预测的正确形式

若恒定基线发生完全后验塌缩，可预期KL接近0、编码均值跨样本方差很小、打乱编码对重建影响有限。预热若解决这一瓶颈，应在这些诊断上出现相应变化，并最终带来预先规定的主指标收益。

若恒定基线已充分使用 z ，预热可能没有空间带来同类收益。当前各方案4维活跃、打乱编码的MSE增量都约0.19，与后一解释更一致。但它只排除了明显完全不使用 z 的情况，不能证明潜表示已经最优，也不能证明早期优化过程完全相同。

可证伪不等于普遍否定

本次假设涉及一个数据分布、架构、预算与具体500步日程。它未获支持，可以指导下一次研究；不能扩展成“KL预热对任何VAE无效”。相反，引用其他论文曾有收益，也不能代替当前条件下的实测。研究价值来自范围明确的可重复证据，而不来自结果符合流行观点。

一 概率目标的逐步答案

任务B 伯努利数值

真实 $x=1$ 、预测 $\pi=0.8$ 时 $NLL=-\log 0.8 \approx 0.22314$ ； $x=0$ 时 $NLL=-\log 0.2 \approx 1.60944$ 。64个logit全为0意味着每个 $\pi=0.5$ ，无论亮点数多少，每项都是 $\log 2$ ，因此总 $NLL=64\log 2 \approx 44.36142$ 。

四维 μ 全1、 lv 全0时， $\exp(lv)=1$ ，每维 $KL=(1+1-1-0)/2=0.5$ ，总计2。 μ 与 lv 全0时每维0， $KL=0$ 。 $\exp(lv)$ 是方差，进入高斯密度的解析KL；抽样乘标准差，所以用 $\exp(lv/2)$ 。

$KL=0$ 意味着近似后验等于先验，在该输入下没有偏离先验；不是“重建完美”的证据。如果所有 x 都得到同一个标准正态后验，编码器没有通过 z 向解码器传递输入相关信息。良好的VAE通常在重建与先验约束间取得有用折中。

任务C 归约错误

每像素平均交叉熵0.2，则每图64像素NLL为12.8。每图 $KL=4$ ， $\beta=1$ 总目标16.8。若误用 $0.2+4=4.2$ ，重建项被缩小64倍；等价于将KL相对于原重建项放大64倍。过强的相对约束可能让编码器忽略输入，因此该错误会伪装成需要预热解决的训练困难。

修复顺序应是先统一归约，再研究日程。不能把一个实现错误留着，再用复杂技巧补偿，最后声称技巧提供了新的科学收益。测试 $64\log 2$ 和固定 μ 的KL，正是为了锁住这种单位一致性。

任务D 日程与导数

β 在1、100、500、1000步分别为0.002、0.2、1、1。 z 对 μ 导数1，对 lv 导数为 $0.5\exp(lv/2)\epsilon$ 。 ϵ 固定时是普通微积分；通过多次 ϵ 抽样得到期望梯度估计。不要把“可微”误理解为不需要随机性，也不要对 torch.randn 本身寻找有意义的参数梯度。

二 控制变量与诊断答案

任务E 配对随机流

每次train先用相同seed初始化权重，再用独立Generator(seed+6400)抽训练批次与 ϵ 。恒定和预热的随机调用数量相同，因此每一步用到相同数据和噪声，差别集中在 β 引起的梯度上。仅写一次相同seed却在某分支额外抽随机数，会破坏后续配对。

评价函数另建固定种子6499的随机流，不推进训练Generator。保存图或追加评价因此不会改变之后训练批次。主程序还固定CPU单线程与确定性算法，但这些设置不保证所有硬件与版本逐位相同，版本仍需记录。

任务F 基线解释

独立像素模型用训练均值估计每个 π_j 。它把各种线的位置平均在一起，能够学到中间像素比边缘更常亮，却不能在同一张图中协调选择一条完整横线或竖线。本次测试NLL约25.8346；VAE估计负ELBO约14.1，说明潜变量结构明显有用。

干预是否有效仍须比较恒定VAE和预热VAE。两者都战胜像素基线只证明潜变量模型优于简单边际模型，不证明日程变化有收益。长恒定方案只研究额外更新的影响，属于预算不同的辅助对照，不能混入同预算主排名。

任务G 训练曲线

不同 β 下总目标数值不能直接排名。例如NLL=10、KL=4， $\beta=0.2$ 时目标10.8， $\beta=1$ 时目标14；两网络完全相同也会出现这个差距。统一评价时始终用 $\beta=1$ ，同时保留NLL和KL分项。

当前恒定基线所有4潜维都活跃，打乱编码使MSE平均增量约0.1902。预热约0.1905，长恒定约0.1915。没有充分依据说主基线完全忽略 z ；“预热解决完全塌缩”的机制在此任务中缺少前提。仍可能存在局部塌缩、冗余维度或先验匹配问题，这些需要另外的定义和实验。

三 配对差判据和测量核验

任务H 实际计算

五个预热减恒定的测试负ELBO差约为0.140911、0.026848、0.047349、0.001235、0.012648。平均+0.045798，样本标准差0.055886，均值标准误0.024994，0/5种子为负。

近似t区间为 $0.045798 \pm 2.776 \times 0.024994$ ，即约 $[-0.02358, 0.11518]$ 。它只涉及固定拆分与固定评价流下的训练种子变化。测试例独立抽样、重新生成训练数据、另一架构的变化不在这个区间内。

为什么保留原始五个数？第一个种子差异明显大于其他，样本量很小，均值和区间容易受它影响。写出原始数使读者能判断分布形状，而不必猜测一个汇总数后面发生了什么。不能因某个种子不利就删除它。

任务I 联合判据

平均差 ≤ -0.2 ：未通过，实际+0.0458。至少4/5胜：未通过，实际0/5。平均有效率下降 ≤ 0.02 ：通过，实际差-0.007031。整体假设不获支持，因为要求三个条件同时成立。

区间跨0，意味着依据这个小样本近似分析，不应强称预热严格更差。它不影响“未达到预先规定的-0.2收益”这一事实。没有支持收益、证明无差异、证明劣势是三个不同主张，不能互相替换。

任务J 可选核验的解释

增加draws而不训练，会改变Monte Carlo估计误差，不改变权重和真实模型概率。若差0.0012的种子在更高精度评价下变号，说明微小差对测量噪声敏感；它不会凭空产生平均至少0.2的改善。具体128次结果应以你实际执行为准，本答案不虚构尚未作为固定交付运行的扩展结果。

若想给新的测试数据做不确定性分析，可在固定模型下重新生成独立测试例；若想研究训练数据变异，则必须重新生成训练集并训练。每种重复都对应不同成本和推断范围，应在设计阶段决定。

四 图像证据与最终结论

任务K 三种图的区别

sample_probabilities来自先验 z 解码，数值在0与1之间；samples从这些概率真正伯努利抽样，为0或1；mean_reconstruction先对测试 x 编码，再将 $\mu(x)$ 送进解码器。它依赖真实输入，因此不能当成自由生成样本展示。

后验均值解码还不等于完整后验预测均值，因为解码器非线性。失败图以该确定性视图帮助定位结构，但主负ELBO用32次后验抽样计算。两者各有用途，不能说图中每个像素误差与ELBO逐项相等。

高损失图可能有罕见背景噪点；正确模型本来也应应对罕见事件付出高NLL。也可能模型错认线条位置。先检查数据生成机制、整体结构和误差图，再提出机制。当前按测试排序只用于解释，若据此改变训练，就需要新的独立最终测试。

任务L 工程验收

全部15个检查点加载后，使用保存采样种子产生1024张二值图与概率，应逐元素匹配对应数组。Notebook有8个顺序执行代码单元、3幅嵌入PNG和无error输出；它真实重训15模型，不只是读取现成results打印。普通及优化模式各20项单元测试通过。

一份合格的研究结论

“在固定 8×8 带噪条纹分布、小型四维VAE和五个配对种子的2000步预算下，500步线性KL预热未达到预设收益。测试估计负ELBO平均差+0.0458 nats/图，0/5种子改善，生成质量护栏平均差-0.0070。恒定基线已使用全部四个潜维，打乱编码明显损害重建，因此完全潜变量塌缩可能不是这里的主要瓶颈。双预算恒定训练提高了模板有效率，但负ELBO改善较小且不一致。”

“结论只覆盖一个数据拆分、架构和日程。样本量较小，Monte Carlo与测试集误差仍存在；没有复刻语言模型周期退火研究。下一次应选择能检验不同瓶颈的新设计，例如更强解码器或明确诱发潜变量忽略的设置，并在验证阶段冻结日程后用新测试集评估。”

这样的结论有观测、有判据、有解释、有边界。把它改成“预热没用”会删去研究最重要的信息。研究项目完成的标志是问题被可信地回答，而不是一定获得更漂亮的样本或更低的一行数字。