

表示或生成研究项目实验

第064单元 完成一次有边界的KL预热研究

本实验包含15次真实训练，目标是从一个可证伪假设走到完整证据，而非得到预设的正面答案。先阅读讲义第一至七节，写好实验预测，再运行完整项目。整个文件夹独立使用，不需要其他单元代码或任何外部数据。

环境与执行

推荐Python3.11或3.12，CPU即可。requirements.txt提供Python依赖；environment.yml提供环境定义。PDF重建另需Noto CJK字体与WeasyPrint系统依赖。先运行数学与接口测试，再开始完整训练。

```
python -m pip install -r requirements.txt
python -m unittest -v test_experiment.py
python -O -m unittest -v test_experiment.py
python experiment.py
python make_figures.py
```

两种测试模式各应运行20项并显示OK。完整experiment.py训练恒定 β 、预热、双预算恒定 β 三方案各五种子，分别2000、2000、4000步。结果写入outputs；想另存使用--output my_run。短跑可验证流程，但不能替代完整研究结果。

任务A 写一份实验前声明

用一段话填写：对象是什么；唯一主要干预是什么；强基线是谁；主指标为何可比较；成功门槛是多少；如何避免生成质量明显下降；训练何时停止。本课门槛已经固定：平均负ELBO差 ≤ -0.2 、至少4/5胜、平均有效率差 ≥ -0.02 。不得看完结果再改成对当前数据有利的门槛。

写出两个不同的预期解释。如果预热改善，可能因为什么？如果没有改善，可能因为什么？把“基线发生完全后验塌缩”和“基线已充分利用潜变量”转成可观察的区别，例如KL、均值方差和打乱编码损失。一个机制解释若没有对应观察，只是故事。

交付物

最终报告应包含完整协议、推导、全部种子数值、配对差、固定先验样本、按规则选出的失败样本、可复跑命令、权重与边界。已执行Notebook只是证据之一，不能代替正文解释。若结论是否定的，保持同样的交付深度。

一手算目标并检查实现

任务B 伯努利与KL

一个像素真实为1，模型概率0.8，算负对数概率；真实改为0，再算一次。若64个logit全为0，一张图的条件NLL是多少？这与亮像素数有关吗？把你的答案与terms函数的输出比较，注意代码接收logit而非概率。

四维后验均值全为1、对数方差全为0，求到标准正态先验的KL。再设均值全为0、对数方差全为0，检查KL为0。解释为什么 $\exp(\text{lv})$ 进入KL，而 $\exp(\text{lv}/2)$ 进入重参数化抽样。

```
import torch
import experiment as e
x = torch.zeros(2, 64)
mu = torch.ones(2, 4)
lv = torch.zeros_like(mu)
nll, kl = e.terms(torch.zeros_like(x), x, mu, lv)
print(nll, kl)
```

任务C 归约单位

假设一个批次平均每像素重建交叉熵为0.2，平均每样本KL为4。按本课归约，重建项是多少？ $\beta=1$ 的总目标是多少？如果误把重建项保留为0.2而KL仍为4，相对权重改变多少倍？写出这个错误为何可能被误诊为“需要预热”。

任务D 日程边界与梯度

计算step=1、100、500、1000时的 β 。阅读beta_at，确认步从1开始，500之后饱和为1。用自动微分验证 $z=\mu+\exp(\text{lv}/2)\epsilon$ 对 μ 、 lv 的导数。冻结 ϵ 进行这个导数检查，不需要也不应该对随机种子求导。

在一个小批次上执行前向和反向，检查所有模型参数都得到有限梯度。梯度存在只证明计算图连通，不证明目标正确；因此仍需前面的数值手算。输入检查用异常，-O模式下也必须保留，避免生产运行悄悄跳过无效数据。

二 跟踪控制变量与训练证据

任务E 配对训练

检查train函数如何设初始化种子和独立训练随机流。对同一种子，恒定 β 与预热是否抽取相同批次和 ϵ ？如果为了记录图像额外调用全局随机数，是否可能改变后续训练？说明将评价随机流与训练流分开的价值。

确认三方案的网络架构、学习率、批量、训练集一致。只有预热改变前500步 β ，长恒定方案只改变更新总数。列出不能同时改变的项目：若把预热模型变宽、学习率也改掉，就无法把差异归因于日程。

任务F 三种基线的作用

用训练集像素平均值计算独立像素测试NLL。解释它为什么能学到边际亮度，却不能表达同一张图中多个像素共同属于一条线。随后比较恒定VAE与预热，而不是只拿预热战胜独立像素基线作为干预有效的证据。

阅读长恒定对照。它多用一倍更新，所以不能称为同预算比较；它回答“增加计算是否也能改变结果”。检查单元测试中的前缀一致性：恒定训练2步应与长恒定以base_steps=1运行的2步完全一致。

任务G 训练曲线解释

分别画NLL与KL，不先把所有方案的training_objective叠加排名。预热期间 β 变化，即使模型预测不变，目标值也会改变。选同一固定批次重新评价是另一种诊断，但必须标清它不是程序原本记录的随机批次曲线。

从results.json读取每方案各种子的active_dimensions、mu_variances和shuffle_mse_delta。当前基线是否表现为完全不使用z？如果四维都活跃、打乱编码使重建显著变差，你还能直接说“预热失败是因为未解决完全塌缩”吗？把观察与解释分两列写在草稿中，避免将推测混进事实。

三 主结果与不确定性

任务H 计算配对差

对五个种子分别算预热测试负ELBO减去恒定基线。报告全部五个数、平均数、样本标准差、胜出次数与质量差。不要先挑每方案最好的种子再相减，那比较的是不同随机起点下的精选结果。

按讲义公式算近似t区间，使用自由度4的系数2.776。说明这个区间覆盖哪一层随机性：训练种子，还是重新生成训练集，还是测试例抽样？五个种子共用一个数据拆分和固定评价随机流，所以它不包含所有层面。

任务I 执行预设判据

三个条件逐条写通过或未通过。即使质量护栏通过，只要主收益门槛不满足，整体就不能写“假设成立”。若均值差很接近0，应区分“没有支持预定收益”与“证明任何微小差异都不存在”。当前五个种子不是全世界VAE的代表。

任务J 可选测量核验

不重新训练，加载固定权重，把evaluate的draws从32增加到128，记录主指标变化。该操作只检查Monte Carlo测量精度。使用独立输出文件保存结果，不覆盖本课固定表。若微小种子差变号，解释为什么这自动恢复“至少降低0.2”的主张。

```
from pathlib import Path
import torch
import experiment as e
c = torch.load('outputs/constant_seed11.pt', weights_only=True)
m = e.VAE()
m.load_state_dict(c['state_dict'])
m.eval()
data = e.make_data()
metrics, arrays = e.evaluate(m, torch.from_numpy(data['test']), draws=128)
print(metrics)
```

额外核验在本实验要求中属于可选探索，教材固定结果仍是32次估计。若你用这份测试结果选择新的 β 日程，就进入新一轮开发；下一轮正式比较应重新规定独立评价，不能继续把已经用来调参的测试集称为从未见过。

四 失败检查与最终验收

任务K 区分三类图

打开warmup_seed11_arrays.npz, 分别展示sample_probabilities、samples和mean_reconstruction。前两者来自先验, 后者依赖测试输入。概率图不是二值抽样, 后验均值解码不是先验生成。给每幅图写准确标题, 比只写“模型结果”更重要。

根据failure_indices展示测试负ELBO最高的12例。对每例区分可能的整体结构错误与真实观察噪声。逐例NLL高不必然表示模型有错误, 因为罕见噪声本来就应有较低概率。写出至少一个目前证据无法区分的原因, 以及能区分它的下一步实验。

任务L 重建Notebook与复生权重

```
python create_notebook.py
python execute_notebook.py experiment.ipynb
```

Notebook真实重训15模型, 另存notebook_outputs, 嵌入配对差图、先验概率与样本图、失败图。最后从全部检查点重新生成1024样本与概率, 逐元素匹配保存数组。确认8个代码单元顺序执行、无error输出、PNG已嵌入。执行器验证的是新进程内IPython顺序运行, 不是浏览器端Jupyter交互。

最终报告的五段逻辑

第一段给假设与预先门槛。第二段给目标推导与代码归约。第三段解释数据、强基线、配对随机流和双预算对照。第四段给完整结果、护栏、机制诊断和失败图。第五段给结论边界及下一次可区分解释的实验。报告应明确写出本次不支持假设, 保留负结果的学习价值。

最终目录应包含Markdown/PDF讲义、实验与答案, 源代码和20项测试, 原创合成数据, 15份实际训练权重与数组, results和protocol, 已执行Notebook, 图和一手来源。不要把临时缓存、测试时另外跑的短步输出或未经核验的草图当成正式结果。

自检时间自己: 别人能否只凭这些文件恢复我画的图和表? 我的标题是否把测试估计说成精确似然? 我是否在看到结果后修改了主张? 对失败样本的解释是否超出当前证据? 这四个问题比一句“代码运行成功”更接近科研交付的验收标准。