

第068讲 练习详解

答案的目的不是给一串最终数字，而是帮助你定位错误属于哪个层次：输入语义、模型状态、数值实现还是服务测量。所有实测值指随课固定结果；手算例子明确标注。

一 标准化与形状

四个原始值和四个标准化值都有形状[1,4]。张量维度只能检查结构，无法验证单位和列含义。对于均值8、尺度3、原始值11，标准化结果为1；局部线性函数 $2z-1$ 得到1，跳过标准化则得到21。这里没有改变权重，却已经改变完整函数。

把统计量注册为buffer有两个好处：不被优化器当作训练参数更新；可随state_dict和导出状态保存。它不能自动检测输入的物理单位是否变化，所以数据字典与入口合同仍需保留。

二 两种状态控制

eval改变Dropout、BatchNorm等依赖training标志的模块行为，通常使Dropout成为恒等映射、BatchNorm使用运行统计量。inference_mode关闭自动微分相关记录和额外检查，它不把training设为False。

反例是在train状态保留Dropout，放入inference_mode后对相同输入调用两次。随机掩码仍不同。本课该反例最大logit差约8.21，不能把它解释成导出误差，因为根本没有在相同确定性函数间比较。

正确顺序是恢复权重及buffer、调用eval，再进入inference_mode执行。若要研究随机推理，应把随机性作为有意设计，并报告预测分布，而非假装每次必须相同。

三 平均值与分位数

五个耗时之和为110，因此平均为22毫秒。linear p50的位置为 $(5 - 1) \times 0.5 = 2$ ，对应第三个值3。p95位置为3.8，在4和100之间插值，得到80.8毫秒。

少数慢调用把平均从典型的1至4毫秒范围拉高。p95也受单个100毫秒点强烈影响，因为样本只有5个。这说明应报告样本量和定义；小样本p99并不神奇地拥有高可靠性。nearest-rank p95会选100，两个数值不一定是谁算错，而可能是定义不同。

四 吞吐与凑批

单样本耗时0.0002秒，吞吐为 $1/0.0002 = 5000$ 样本/秒。32样本批耗时0.001秒，吞吐为 $32/0.001 = 32000$ 样本/秒。这个计算假定批次输入已备好，且只考虑模型计算。

若第一条请求等待凑批20毫秒，再计算1毫秒，其响应时间至少21毫秒，尚未加上网络和序列化。吞吐提升和响应变快不是同一件事。即使把批耗时均摊为每样本0.03125毫秒，也不能说该请求只等待0.03125毫秒。

五 排队递推

到达时刻 $a_i = 0.2(i - 1)$ 毫秒，每次处理0.5毫秒。因为到达速度快于服务速度，服务器从第一条开始一直忙。第 j 条完成时刻为 $0.5j$ ，所以响应为：

$$r_i = 0.5i - 0.2(i - 1) = 0.3i + 0.2.$$

第八条在1.4毫秒到达，4.0毫秒完成，响应2.6毫秒。等待为2.1毫秒，再加0.5毫秒服务。图6来自这个确定性递推，不能写成服务器实测。

六 导出合同与数值误差

batch1导出图具有固定[1,4]输入约束。给[2,4]应报形状错误。此时没有有效预测结果，不能拿异常与参考logit相减；它属于调用不符合合同。数值误差只应在两条都合法、语义相同的执行路径间比较。

本次batch1与完整批参考最大logit误差约 $3.81e-6$ ，batch32为0，全部argmax一致。不同批次矩阵乘法的累加顺序可以产生微小差异。容差应预先选择并逐元素检查；只有类别一致不足以证明概率或阈值行为一致。

七 服务器实验计划示例

先固定模型、数据版本、输入合同、机器配置与软件版本。选择开放到达或闭环负载并说明原因；逐级增加到达率或并发量，不同时更换模型。统计从客户端发出到完整响应的端到端时间，保留超时与失败，另测服务端排队和计算阶段。

预先定义质量约束、p95或p99门槛、最大错误率和回退行为。分开报告冷启动窗口与稳定窗口。测试合法、非法和超大请求，同时说明容量限制。失败分母必须覆盖全部请求，不能删除超时后只对成功请求报一个好看的数字。

该计划尚未执行，不能加入本讲结果表。已有证据覆盖本地CPU模型调用、暖进程资产重载和新Python进程启动，不覆盖网络服务或容器就绪。

八 实验验收核对

数据形状为 1152×4 ；训练768、测试384；180次全批更新。正确分类380/384，漏预处理143/384。合法输入返回ok；三种非法输入返回rejected且prediction为空。两份.pt2文件实际存在并能重新载入。原始计时位于results.json的timings，而非只有图中均值。

若你的硬件延迟不同，不必马上判为失败。先比对版本、线程、预热与计时区间；数值检查和性能检查应独立。若准确率或导出误差明显变化，再核对数据、标准化统计量、eval状态与checkpoint。这个顺序比反复增加训练轮数更能定位问题。