

DL071 参考答案与审查解释

答案不仅给数字，也说明数字对应的分母、数据角色和适用范围。下列实测值来自随附outputs中的完整默认运行；自己重跑时应保留环境与数值差异，不要为了对齐末位小数改数据。

1 五个域的协议

同分布域不改变输入。核心加噪域在 x_0 增加标准差1.8的高斯噪声；捷径衰减域将 x_1 乘0.1；捷径反转域将 x_1 乘负1；少数群反转域只对预先固定的 $g=1$ 样本反转 x_1 。所有变换沿用原标签和原样本索引，测试域之间因而相关。

真实标签来自生成器的 y ，变换改变输入通道而不改 y ，这是本实验的任务定义。它没有证明所有真实图像增强都保留标签。例如把数字6旋转成9就可能改变标签。实验也未覆盖恶意优化攻击、现实传感器故障或新类别到来。

2 四条预测的逐步手算

预测类别依次为0、1、0、1，错误指示量为0、1、0、0。阈值0.75接受前两条，接受数2，错误数1，覆盖率 $2/4=0.5$ ，风险 $1/2=0.5$ 。接受且答错占全部样本比例为 $1/4=0.25$ ，这与风险不同。

阈值0接受全部四条，覆盖率1，风险 $1/4=0.25$ 。阈值1没有样本达到，覆盖率0，风险分母为0，结果未定义。把未定义改成0会让一个完全不提供服务的系统看起来没有风险，也破坏下游比较。

对于两条置信度都为0.8的样本，阈值大于0.8时全拒绝，小于等于0.8时全部接受。没有阈值能实现覆盖0.5。曲线只应出现覆盖1、风险0.5的有效点；代码不画空接受点的风险。

3 温度缩放与NLL

$T=1$ 时第一类概率为0.880797，第二类为0.119203； $T=2$ 时分别为0.731059和0.268941。若真类为0，NLL分别为0.126928和0.313262；若真类为1，分别为2.126928和1.313262。

所有正温度保持logit排序，所以预测类别和准确率不变。NLL使用真实类对应概率，故会变化。本例升温降低置信度，帮助错误预测的NLL，却损害正确预测的NLL；实际温度由校准集平均目标决定。

随附三个种子的温度都为0.5，达到预先给定搜索范围下界。正确解读是：在这份非常容易的校准数据与有限候选范围内，最尖的候选获得最小NLL。不能解读为所有分布都应更自信。seed17反转域原始NLL约8.727218，温度后约17.452023，说明原域选择反而强化了错误域的自信程度。

4 覆盖目标与实际覆盖

seed17阈值约0.9999999811217154，来自校准最大概率的20%分位数。校准覆盖目标为80%，实际测试同分布覆盖为463/600=77.1667%。样本有限、校准与测试为不同样本，出现差异不奇怪；分布改变后覆盖可发生更大变化。

捷径衰减域只有0个样本超过该阈值，因此风险是null。该域全量有31个错误，错误率31/600=5.1667%，其中19个错误仍满足置信度至少0.95。0.95示例门槛低于部署阈值，二者不矛盾。

5 子群总体风险

多数群n=460，接受353，错误0，覆盖76.7391%，风险0。少数群n=140，接受74，错误74，覆盖52.8571%，风险100%。总体n=600，接受427，错误74，覆盖71.1667%，风险17.3302%。

总体风险按接受人数加权：

$$R = \frac{353}{427} \times 0 + \frac{74}{427} \times 1 = \frac{74}{427}.$$

如果按原群体占比460/600和140/600加权，计算出来的是在两组覆盖相同时才可直接对应的另一种量。本例覆盖不同，不能混用权重。

6 错误实例和共同捷径

反转域第0条输入约[1.86734,-2.45439]，真类1、预测类0、置信度约0.9999999873。 x_0 为正，与真实类方向一致， x_1 为负，与训练中类0的捷径一致；这与网络依赖捷径的解释相符。

单个例子不能独立证明网络所有内部表征或因果机制。支持解释的额外证据包括系统性的捷径反转、所有样本上的错误率，以及保留核心维度的配对设计。三个模型的概率平均也在该域全错，提示初始化多样性不足以消除共享捷径。

7 熵分解手算

两个成员都给[0.5,0.5]时，平均分布仍为[0.5,0.5]，总熵和平均成员熵都为0.693147，差为0。若成员分别给[0.99,0.01]、[0.01,0.99]，平均分布相同，总熵仍为0.693147；成员熵为0.056002，差为0.637146。

两种情况下总熵一样高，成员分歧却不同。它说明“只报熵”会丢失一些结构信息；没有说明第一种必然只有数据不确定性，或第二种就是严格后验模型不确定性。这里的网络集合没有经过这种概率模型认证。

8 零错误的区间与代价

$n=463$ 、观察错误率 $r=0$ ， $z=1.96$ 的Wilson区间上端约0.0082289，即0.823%。因此“观察零错误”与“真实总体风险严格为零”不同。这个区间依赖独立近似与固定选择规则，不能外推为任何未来域的保证。

在拒答代价0.2的简化设定下，系统A覆盖0.5、风险0.01，总代价0.105；系统B覆盖0.9、风险0.05，总代价0.065。B更合算的结论仅适用于给定代价模型，不代表应普遍选择更高覆盖。若拒答成本、错误类型损失或人工可靠性改变，需要重新计算。

9 三个故障应怎样定位

风险分母改为总人数会使`test_selective_denominator`失败，因为本来应返回0.5却返回0.25。空接受风险改为0会使`test_empty_acceptance_is_undefined`失败。将大于等于改为严格大于，会使`test_threshold_equality_included`失败，因为置信度恰等于0.8的样本被错误排除。

修复应回到定义而不是更改期望。`unittest`的`assertEqual`、`assertIsNone`等是普通方法调用，`python -O`不会移除；裸Python `assert`语句则会受优化模式影响。

10 权重与Notebook复核

默认三个checkpoint分别对应种子17、29、43。保存后立刻重载，对同分布测试logit逐元素比较，最大绝对差为0。文件包含模型参数、架构标识、种子、训练步数、温度和阈值；没有优化器状态和训练随机状态，故适合推理复核，不是完整续训快照。

Notebook按序重新生成数据、训练三个模型、检查关键指标，并内嵌风险覆盖与错误置信度图。提供的是新进程内的实际IPython执行，不是浏览器或外进程传输测试。耗时不要求与固定outputs一致；相同软件环境的预测与损失应匹配。

11 合格结论示例

已验证：在固定生成器和三个初始化下，原域校准无法防止捷径反转失败；seed17反转域的接受后风险为100%，少数群失败被总体平均弱化。机制支持：训练信号中高可预测性的捷径导致共享错误，是与配对变换结果一致的解释。尚未验证：真实数据、其他模型族、风险控制算法、攻击鲁棒性以及长期部署表现。

下一步合理实验可以预先指定训练时打乱捷径，同时保留不改训练的基线与无关位置扰动的消融。必须重新封存测试数据，说明预算，并报告原域性能代价，不能只筛选成功的鲁棒性结果。