

DL072 参考答案与项目审查

以下回答基于随附默认协议和实际CPU结果。报告的合格程度取决于证据是否对应问题，而不取决于你是否得到了比讲义更漂亮的数字。

1 可被推翻的问题

主问题是：相同MLP与160次更新下，训练时随机化已知左上角标，能否降低预定反转域的错误率？若改善量 $A-B$ 小于等于0，主要假设未获支持。若错位随机化有相似改善，则位置针对性解释被削弱；若简单遮挡同样有效，则随机化的独特优势没有得到支持。

“任何分布都更鲁棒”不是本实验能检验的主张，因为只有四个预定域，且使用强先验的合成数据。报告应收窄到具体生成器、方法与预算。

2 数据角色与方法差别

训练800条只更新模型；验证240条只选择目标覆盖80%的最大概率阈值；测试600条只做最终报告。三个数据生成种子不同，所有方法共用同样基础数据。

线性模型不做增强；原始MLP不做增强；角标随机化仅训练时替换左上 3×3 ；错位随机化仅训练时替换右下 3×3 ；遮挡角标训练与推理都将左上 3×3 设为0。后者推理预处理不能省略。

四测试域由相同测试例变换。它们便于配对比较，但不能把四域600例合并成2400条独立现实样本。

3 参数与内存手算

线性层 $144 \rightarrow 2$ 含 144×2 个权重与2个偏置，共290。MLP第一层 $144 \rightarrow 32$ 含 $4608 + 32 = 4640$ ；第二层 $32 \rightarrow 2$ 含 $64 + 2 = 66$ ，总计4706。

训练图像float32占 $800 \times 144 \times 4 = 460800$ 字节，标签int64占 $800 \times 8 = 6400$ 字节，合计467200。它只计算两个数组，未包含模型、优化器、梯度、运行库、缓存、其他数据或峰值临时分配。因此不能写“整个实验只需467200字节内存”。

相同训练步数控制了更新次数，不控制每一步的计算量。图像增强还增加额外操作。更严格的效率比较需要明确计时边界、硬件和多次测量。

4 期望目标与代码对应

ERM目标是训练损失的样本均值。随机化目标进一步对与标签独立的角标 u 取期望。正负角标各半、损失0.2与1.0时，期望为 $0.5 \times 0.2 + 0.5 \times 1.0 = 0.6$ 。

每步抽一次时，单次估计可能是0.2或1.0；方差为 $0.5 \times (0.2-0.6)^2 + 0.5 \times (1.0-0.6)^2 = 0.16$ 。独立重复抽样的平均在通常条件下更稳定。真实代码每个样本每步独立抽样，不是给整个批次共享一个角标，也不是固定一次后永远不变。

opt.zero_grad清空旧梯度，transform构造本步输入，模型输出logit，cross_entropy计算损失，backward计算梯度，step更新参数。把softmax提前塞给交叉熵会改变数值语义，不是本课实现。

5 主结果和配对统计

种子11：MLP错误率413/600=0.688333，随机化108/600=0.18，改善305/600=0.508333。

种子23：MLP错误率405/600=0.675，随机化114/600=0.19，改善291/600=0.485。

种子37：MLP错误率411/600=0.685，随机化106/600=0.176667，改善305/600=0.508333。

平均改善为0.500556，样本标准差约0.013472。对应50.0556个百分点均值、1.3472个百分点标准差。若错误地用ddof=0，得到约0.011000，描述的是这三个已观察数值的总体型离散量，不能与样本标准差混写。

三个种子共用数据，标准差只反映初始化与增强过程的变化。不应将其称为对现实人群泛化误差的95%置信区间。也不应把15个模型当成15个独立数据集。

6 收益与代价同时报告

角标随机化的反转错误率均值从68.2778%降至18.2222%。同分布错误率从5.7778%升至18.2222%，代价12.4444个百分点。核心加噪域从12.4444%升至30.0556%，代价17.6111个百分点。

这是重要的反面证据。移除原域强相关角标后，模型依赖更难的中心特征；中心再受干扰时性能更差。是否值得交换，要由未来环境分布和错误成本决定，不能只凭一项反转测试替用户决定。

7 消融支持什么

错位随机化反转错误率均值65.9444%，只比原始MLP略低，远不如角标随机化的18.2222%。这支持“干预已知角标位置是重要因素”，却不证明任意一般噪声方法都无效。

遮挡角标与角标随机化在三位小数尺度上具有相近均值。正确报告会承认简单信息删除解释了相当部分现象；错误报告会删掉遮挡基线，声称随机化有独特优势。同样均值不说明逐样本预测相同，原始预测文件保留了复核所需信息。

8 预算核对

5种方法×3种子=15次训练；15×160=2400次更新；每次更新800条基础样本，所以总呈现量为1920000。运行时间记录是本机实际计时，优化循环之和与整个实验进程用时口径不同，依赖安装和文档构建不在其中。

Notebook又执行了一次全部训练。因此课程的主实验预算是15次模型运行；复核过程还包含Notebook重跑和短测试训练。把完整教学构建总成本伪装成只有一次主实验，也是不透明的。

9 故障应该怎样识别

删除推理遮挡应触发`test_mask_applied_at_inference`，因为方法定义要求训练和推理均遮挡。它也会改变checkpoint重载时的预测，不能仍用旧报告。

标准差`ddof`从1变0不一定会让程序报错，但改变了统计量。研究错误常常没有异常栈；需要定义审查和数值复核。

错位随机化误改成左上角会触发`test_wrong_corner_preserves_shortcut`。即使忘记写此测试，消融意义也已损坏，因为它不再代表“与主要干预强度相同但位置无关”的对照。

10 权重与可重跑结论

15份checkpoint都保存真实训练参数，保存后立即重载，测试预测最大绝对差均为0。每份都保留方法名，因此推理时能恢复对应预处理；只恢复网络参数却忘记方法预处理，仍然可能得到错误结果。

这些文件缺少优化器状态与完整训练随机状态，不支持宣称精确恢复第 k 步后的继续训练。官方建议中推理保存和完整训练checkpoint是不同需求，必须按实际保存内容写结论。

Notebook已重新执行全部主实验，内嵌由该次输出计算的图。相同环境下，损失、预测、计数和配对差值应一致；训练时间可以不同。跨版本或跨设备存在数值变化风险，环境说明是证据的一部分。

11 审查后可以保留的结论

可以保留：在已知角标的合成线条任务、固定数据、三个种子和相同同步数下，随机化降低了预定角标反转错误率，且伴随原域和核心噪声域代价；错位干预没有相同收益，遮挡角标提供相近均值。

应删除或改写：“学到了真正的因果特征”“对所有域稳健”“拒答已保证安全”“显著优于一切增强”“具备发表价值”。这些说法都超出了实验能支持的范围。

合理下一步示例：事先定义一个新角标位置和新的测试种子，比较固定位置方法与知道新位置的对照。若固定位置方法失败，会直接展示当前方法对位置先验的依赖；结果无论正负都能推进理解。