

DL073 练习答案与审查要点

本讲对应原大纲T1。下面的数字来自随附outputs；扩展实验只给推理与操作方向，未执行的改动不会被写成实测结论。先完成lab中的预测，再用这些答案检查自己的理由。

1 一步更新与越界的直接原因

初值 $w=(4,2)$ ， $f=(16+16)/2=16$ ，梯度为 $(4,8)$ 。 $\eta=0.25$ 时， $w_{\text{新}}=(4,2)-0.25(4,8)=(3,0)$ ，损失为 $9/2=4.5$ 。 $\eta=0.6$ 时， $w_{\text{新}}=(1.6,-2.8)$ ，损失为 $(2.56+31.36)/2=16.96$ ，一步已比16更高。

沿第二坐标的递推是 $w_{1\text{新}}=(1-4\eta)w_{1\text{旧}}$ 。 $\eta=0.6$ 给因子负1.4，绝对值大于1，因而交替远离0。代码运行25步的目标约161,991,329.918。这个例子明确指出“步长导致不稳定”，并没有证明所有非凸训练失败都只因步长大。

界为 $40/t$ 。第1步实际差 $4.5 \leq 40$ ，第10步约 $0.02537 \leq 4$ ，第50步约 $2.5658 \times 10^{-12} \leq 0.8$ 。全部50步的最大实测减界约-0.8，不能把它叫“误差为零”；它是未违反上界且很保守的证据。

2 证明逐行对应条件

平滑性提供下降引理； $\eta=1/L$ 把二阶曲率项限制住，得到损失下降至少梯度长度平方除 $2L$ 。凸性提供 $f(w)-f(w^*)$ 不超过梯度与指向当前点向量的点积。更新规则和平方展开是代数恒等式，尚未用凸性。

有限 w^* 存在让距离平方有可代入的参考。合并以后，对 t 求和，中间距离项相消；非负性让最终距离项可以丢弃；损失单调性让最后一步不超过之前 T 项平均。若只完成求和却没有单调性，通常只能直接得到平均目标值或某一步的界，不能无条件写最后一步界。

T 变成 $4T$ 时， $40/T$ 变成原来的 $1/4$ ； $DG/\sqrt{T}$ 变成原来的 $1/2$ 。实际二次目标可能按几何速度更快下降，因此“理论保证 $1/T$ ”不等于“观测曲线必须是 $1/T$ ”。

3 为什么不能把同一有限点证明搬到可分logistic

任意能严格分开所有样本的方向 v ，都有每个 $y_i v^T x_i > 0$ 。令 $w=cv$ ， c 越来越大时，各项 $\log(1+\exp(-c \times \text{正数}))$ 趋于0。有限 c 的每项仍大于0，因此0是下确界，通常不在有限参数处取得。此时不可以选一个不存在的 w^* 来计算固定 D 。

参数长度不收敛到有限数，与归一化方向趋近某个方向并不矛盾。把不断增长的向量除以自己的长度，只保留方向。讲义的有限步实测只能说明方向正在靠近；极限方向结论依赖原论文的假设与证明，不能由有限轨迹单独推出。

4 硬间隔手算与全部约束

正类的五个 yx 分别为(1,0)、(0,2)、(1,1)、(2,1)、(1.5,2)，负类镜像乘负标签后给出同样的五个向量。前两项约束迫使 $w_0 \geq 1$ 和 $w_1 \geq 0.5$ 。这样范数平方至少1.25，而 $w=(1,0.5)$ 在其余三个向量上的点积为1.5、2.5、2.5，均大于等于1。所以它是可行的最小范数点。

其几何间隔为 $1/\sqrt{1.25} \approx 0.894427$ 。若 w 乘以 $c>0$ ，分子和分母都乘 c ，商不变；若 $c<0$ ，分类方向会翻转，不能再说边界分类规则相同。只有 w 不为0时方向与几何间隔才有定义。

5 核心代码手算与梯度核验

零点损失为 $\log 2 \approx 0.693147$ 。十个 yx 的平均为(1.1,1.2)，梯度为(-0.55,-0.6)。eta=0.1时一步为(0.055,0.06)。解析梯度测试在 $w=(0.3,-0.8)$ 对每个坐标使用中心差分，差分步长为10的负6次方，并用绝对容差10的负9次方比较。

中心差分把参数分别向正负方向推一点，用两次损失差除以2倍小步，近似局部坡度。它独立检查推导与实现，却不是所有参数位置的形式证明。极端大参数测试再检查稳定表达没有无穷或NaN；两类测试目的不同，不能互相替代。

运行记录的三种初值最终损失分别约0.0000469898、0.0000468141、0.0000464024。方向角分别约3.61890、3.59396、3.83095度；参数长度约9.92773、9.93164、9.94492。第10步方向角到最终都下降；最终错误率都为0。

因此合格解释同时保留“已经全分对”“方向仍在变”“范数持续增大”。不能因为错误率停止变化就声称优化器已经停止，也不能因为损失越来越小就声称未知测试准确率一定提高。

6 随机梯度答案应保留的限定词

无偏性的含义是给定过去历史时，随机梯度的条件期望等于当前全梯度，不是每个批次的梯度都等于全梯度。有界二阶矩 G^2 控制的是平方长度的期望；如果数据重尾、抽样规则自适应或梯度估计有偏，就要重新验证条件。

固定步长下的 $D^2/(2\eta T) + \eta G^2/2$ 解释两个来源：起点距离债务与随机步子代价。设 $\eta = D/(G\sqrt{T})$ 需事先把 T 当预算，而且这只是满足相关条件时的一种理论选择。结论针对平均迭代点的期望目标差；一条随机曲线偶尔上升不构成对该期望界的反例。

本单元未实现SGD对照，因此答案不能添加“本实验已经证实 $1/\sqrt{T}$ 速度”。正确表述是完成了符号推导，实验只核验确定性二次目标和全梯度logistic。

7 扩展题判分与失败诊断

翻转某个标签后，要重新检查所有带符号分数是否可能同时为正。这个对称数据若将一对镜像点变成相同标签，过原点的齐次线性模型无法同时满足它们的严格正间隔。原线性可分假设已被破坏，即使程序完全正确，也不应期待原最大间隔方向结论照常成立。

加入 λ 范数平方一半的惩罚时，梯度增加 λw ； $\lambda > 0$ 使大范数有代价，并让目标有有限最优点。这里可进一步证明严格凸与唯一性，但不要把有正则解称为同一个无正则渐近方向实验。使用固定 λ 与报告新目标，才能形成可比较的扩展。

更改特征单位时，输入矩阵的曲率、硬间隔几何与更新路径都会改变。如果只改数据不重算 L ，甚至可能因步长失配出现数值问题。定位顺序是先查数据条件、再查目标与梯度、再查步长和数值稳定，最后才讨论理论失效。

8 一个合格的简短结论

“固定10点、齐次线性、无正则logistic、保守固定步长的三条20,000步轨迹，均出现错误率归零且方向继续缓慢靠近硬间隔参考。有限实测支持该实例的机制描述。一般深网不满足凸性，参数化与优化器也可能不同，本实验没有证明深网全局优化或测试泛化。”

审查时给理由比给漂亮数字更重要。若报告缺失零向量未定义处理、只报最好初始化、把0.6失败组删掉、或把合成数据写成现实数据，即使代码能运行，也尚未通过本讲的证据标准。