

DL074 练习答案与证据解释

对应原大纲T2。这里的“真实风险”是原创有限总体的精确求和；在现实问题里通常无法同样获得。所有固定实测值可由outputs/trials.npz独立重算。

1 三个手算答案

预测[0,1,1]、条件正类概率[0.2,0.7,0.4]，逐点错误概率为0.2、0.3、0.6，总体风险为 $1.1/3 \approx 0.366667$ 。第三点预测1，错的是Y=0，其概率为1-0.4，不能直接拿0.4相加。

M=23、n=100、delta=0.05时， $\log(2M/\delta) = \log 920 \approx 6.824374$ ， $\epsilon \approx 0.184721$ 。经验风险0.12对应风险范围[0,0.304721]，在一致好事件上有效。负的代数下界可以截到0，因为风险天然非负。

要求 $\epsilon \leq 0.05$ ，平方并移项得 $n \geq 6.824374/0.005 \approx 1364.875$ ，向上取整为1365。这个数是分布无关推导中的足够量，不是经验最小数据需求。M扩大十倍使对数项增加 $\log 10 \approx 2.302585$ ，半径乘以 $\sqrt{((\log 920 + \log 10)/\log 920)}$ ，约1.1565，而不是10。

2 为什么需要2M

对一个固定假设，正向经验偏差与负向经验偏差各可用一个指数尾界控制。两个方向合并给因子2。对M个预定候选，把“任一个出错”的概率用并集界相加，给因子M。不同假设在同一数据上的误差事件往往高度相关，但并集上界本身不要求这些事件独立。

独立性实际用在每条样本损失的指数矩期望分解成乘积。混淆“候选间独立”与“样本间独立”是常见错误。候选完全重复也不会使证明无效；按重复数计数只会更松。本课23阈值中，-1.1和-1.0在输入域上都恒预测1，因此不同函数只有22个，用23是保守选择。

把 $2M \exp(-2n \epsilon^2)$ 设为delta，得到epsilon平方为 $\log(2M/\delta)/(2n)$ 。若少写分母2或用以10为底的对数，数值会改变；理论原式使用自然指数，所以对应自然对数。

3 ERM为何付出两份epsilon

$\hat{h}$ 是训练集选出的经验最优， h 是同一预定类中的真实风险最优。先用一致界得 $R(\hat{h}) \leq \text{经验}R(\hat{h}) + \epsilon$ ；再用经验最小性得 $\text{经验}R(\hat{h}) \leq \text{经验}R(h)$ ；最后用一致界得 $R(h) \leq R(\hat{h}) + \epsilon$ 。把链条相接即超额风险 $\leq 2\epsilon$ 。

第一份epsilon补偿选中模型的训练低估，第二份补偿参考模型的训练高估。它们在具体实例中未必同时达到最坏，但保证必须覆盖可能情况。删去一份需要更强结构或新的证明，不能因为实测好就改理论公式。

本课 h^* 的真实风险为0.15。这个不可消除基准来自当前输入下的标签随机性：每个格点多数类别也仍有15%反例。更复杂的记忆表不可能根据尚未发生的独立随机标签把总体风险变成0。

4 固定重复结果与正确频率解释

$n=20$ 时，400次平均一致偏差0.1802917，半径0.4130488，超界1次；平均ERM训练风险0.13475，总体风险0.1975833。 $n=100$ 时分别为0.0798917、0.1847211、0次、0.14935、0.1536667。

$n=500$ 的半径0.0826098，平均最大偏差0.0358883； $n=2000$ 的半径0.0413049，平均最大偏差0.0178517。后二组平均总体风险都为0.15，训练均值分别为0.149995和0.1500825，略微在真值两侧波动是正常现象。

一次超界没有反驳概率界。 $\delta=0.05$ 限制单次抽样坏事件的概率，并非承诺任何400次都恰有20次或最多20次。观察到0次也不能证明概率为0；有限重复不能枚举无限多可能训练样本。将重复次数继续扩大，会得到更稳定的频率估计，但不是替代理论证明。

均值偏差小于半径也不是同义比较：均值记录典型大小，半径控制尾部坏事件。只比较两条均值曲线而不看完整重复分布，不能判断所声明的失败概率是否合理。

5 事后单元素类为什么不合格

记忆表由训练标签决定。对一个固定表，所有训练样本的损失可按固定 h 分析；但用同一批样本先生成表，再条件在生成结果上，样本与模型已关联。不能直接把这个随机选中的表当作抽样前确定 h 套用同一集中证明。

修复一：在抽样之前把21个输入上所有标签表作为 H ，共 2^{21} 个。无论学习算法输出哪张表，都在该固定集合内。一致事件自动覆盖它； $n=20$ 对应半径0.6753697， $n=100$ 对应0.3020345。更丰富的集合增加了选择代价。

修复二：模型定稿后独立抽评价数据。条件于训练过程，模型对评价集固定，单模型Hoeffding界可用。此时界控制评价经验风险到总体风险的距离，并不是训练经验风险。若评价结果又被用于选模型，必须重新处理依赖，不能继续叫一次最终留出。

错误地代入 $M=1$ 时， $n=20$ 得到0.3036807， $n=100$ 得到0.1358102。数字更小只是少算了选择过程。某些样本可能碰巧仍被这个小数字覆盖，但没有由本讲证明获得保证。

6 记忆表实测的解释

$n=20$ 时，记忆表平均训练风险0.076125，总体风险0.3481667。训练样本少，许多格点未出现；默认0在正半轴会频繁出错。即使格点出现一次，它的标签也有15%概率是少数类别，直接记住这次标签会把噪声当规律。

阈值类共享一个有序结构：一个点的信息会通过阈值位置约束其他点的类别。记忆表逐格点独立决定，因而小样本下难以借用相邻格点的信息。这是本合成问题中的归纳偏好比较，不是声明阈值类在所有现实任务都更好。

当 n 到500或2000，各格点有了足够重复标签，预定400次里记忆表都恢复了多数类别，平均总体风险达到0.15。这也说明“复杂模型总会过拟合”不是本实验支持的结论。数据量、生成规律和模型结构共同决定表现。

7 哪些改动要重新建立前提

看测试标签后移动候选阈值，再用原 $M=23$ 界评价，是集合发生数据依赖变化；反复试许多候选但只把最后保留的两个计入 M ，是漏算搜索空间；从同一病人抽多个高度相关记录却当独立，是样本假设变化。

若部署时 $P(Y|X)$ 从0.85变成0.4，即使输入格点不变，训练总体 P 与部署总体 Q 不同。原界控制 R_P ，不自动控制 R_Q 。它不是“看见23个模型所以所有未来分布都可靠”的保证。

对无限假设类，直接把 M 设为无穷得到空泛上界，不代表无法学习。需要其他复杂度度量或算法稳定性等专门工具。数据依赖界同样可以成立，前提是有对应证明，而不是自由删改固定类条件。

8 可接受的交付结论

“我们在21格点IID合成总体和抽样前确定的23阈值候选上，对四种样本量各做400次重复。有限类一致界保守， $n=20$ 出现1次超界，其他组未出现；所有原始重复均保留。事后按 $M=1$ 处理训练所得记忆表不受相同证明覆盖。实验没有证明现实高维网络或分布漂移下的泛化。”

审查应拒绝把真实风险称为“测试准确率”、把95%置信解释成每次模型有95%概率正确、或用零次超界作绝对安全保证。这些不是措辞小问题，而是把公式所控制的对象换掉了。