

DL075 练习答案与边界审查

对应原大纲T3。答案区分代数恒等式、局部近似、实际扫描结果和未执行扩展。所有实测数字来自 outputs，未用外部模型或数据。

1 Jacobian与Gram手算

J两行为(1,0)、(1,2)， $d=(0.1,-0.2)$ 。第一条输出变化为0.1；第二条为 $0.1-0.4=-0.3$ 。Gram第一行是两个行向量与第一行点积，得(1,1)；第二行为(1,5)。它是对称矩阵。

$v=(1,-1)$ ，先算 $Kv=(0,-4)$ ，再做 v 点积得4。另算 $J^T v=(0,-2)$ ，长度平方也为4。这给出 $v^T K v = \|J^T v\|^2$ 的具体检查。对所有 v 都非负才叫半正定；检查一个 v 只是手算例子，通用保证来自代数恒等式。

$m=1$ 、 $a=2$ 、 $w=b=0$ 、 $x=3$ ， $h=\tanh 0=0$ ， $f=0$ 。对 a 偏导为 $h=0$ ；对 w 偏导为 $a(1-h^2)x=6$ ；对 b 偏导为 $a(1-h^2)=2$ 。所以输出为0并不代表参数更新完全停滞。

2 三组偏导的链条

输出权重 a 只在线性求和中出现，因此导数是 $h/\sqrt{m}$ 。输入权重 w 先影响 $z=wx+b$ ，导数为 x ； z 经过 $\tanh$ ，导数为 $1-h^2$ ；再乘 $a/\sqrt{m}$ ，得到 $a(1-h^2)x/\sqrt{m}$ 。偏置 b 对 z 的导数为1，所以与 w 导数相比少一个 x 。

代码将三块 $[n,m]$ 矩阵按列拼接成 $[n,3m]$ 。如果把 a,w,b 交错排列却沿用当前拼接方式，形状仍可能合法，但参数坐标含义已错。有限差分逐坐标核验可以发现这种错误，仅看损失下降未必能发现。

测试用中心差分步长10的负6次方、绝对容差10的负9次方。另有Taylor余项阶数测试：把相同方向的小扰动从0.01缩成0.005，误差大致缩成1/4，符合二阶余项。它检查当前光滑点附近，不意味着全训练路径二阶余项都小。

3 固定核更新为何精确

线性化输出为 $f_0 + J_0 d$ ，平方损失对 d 的梯度为 $J_0^T(f-y)/n$ 。更新 d 以后再乘 J_0 ，新增输出恰好等于负 $\eta J_0 J_0^T(f-y)/n$ 。这里没有省略项，因为输出对 d 本来就是仿射函数。

真实网络首步使用相同初始梯度，参数增量相同，但 $f(\theta_0 + \delta)$ 通常不等于 $f_0 + J_0 \delta$ 。差来自二阶及更高项。下一步真实网络的Jacobian还会变，两条增量也不再一样。把 J_0 偷偷每步刷新，就已经不再训练原定义的线性化模型。

残差在固定核特征方向上乘以 $1-\eta \lambda$ 。正 λ 方向收缩需其绝对值小于1，即 $0 < \eta \lambda < 2$ ；最大 λ 给最紧限制。 $\lambda=0$ 方向因子为1，没有收缩；负 λ 不应出现在精确Gram中，微小负数可来自舍入。

4 目标幅度不是实际移动的替代物

目标为 $A g(x)$ ，但初始化输出 f_0 通常非零。初始残差是 $f_0 - A g(x)$ 。降低 A 可能使某些残差更小，也可能使某些残差更大，取决于 f_0 与目标的相对形状。因此不能先验断言 A 小就必然参数移动小。

本课同时记录四种尺度：相对参数移动、隐藏表示漂移、核漂移，以及网格相对预测差。它们在固定扫描中有趋势，但并不由定义保证逐次单调。较小 A 还会使“预测RMSE除 A ”放大同一绝对误差，所以结果保留两组原始网格预测；绝对预测差可由相对差乘 A 重算，避免只用相对指标选故事。

宽度不同意味着参数数目不同。相同种子值只是可复现编号，并不保证两种宽度抽到的所有参数是嵌套同一初值。幅度比较在同一宽度种子下共享 θ_0 ，才是这里明确的配对控制。

5 完整扫描的数值读法

三种子平均相对预测差，在 $A=0.2$ 时随宽度 8、32、128 依次为 0.09410、0.02721、0.01061； $A=1$ 时为 0.15215、0.09912、0.04428； $A=4$ 时为 0.21214、0.15932、0.10944。所有平均都保留在讲义图中，原JSON保留27条独立记录。

$A=4$ 、 $m=8$ 的核平均相对漂移 4.70939， $m=32$ 为 1.85049， $m=128$ 为 0.70015。漂移超过 1 只是变化范数大于初始范数，没有违反范围限制，因为这个比值不是概率。

$A=4$ 、 $m=8$ 时真实平均训练损失约 0.01992，线性化约 0.42684；这说明该固定预算里真实非线性路径获得更低训练目标，不等于证明实际任务测试泛化更好。两种模型可能有不同插值与外推行为，本实验只评估指定网格，没有现实分布风险。

$A=1$ 、 $m=128$ 时真实平均训练损失约 0.01646，线性化约 0.01330，显示真实网络并非每个配置都更低。不能把真实网络的更灵活表达能力误写成固定步数下优化效果的无条件优势。

6 何时可以说近似失效

先定义准则再看结果。例如预定相对网格预测差超过 0.1 作为本教学图中的显著分离阈值，可以标记多个配置；但这个阈值是任务尺度的选择，不是数学定理的普适分界。若没有预定阈值，直接报告连续差值更诚实。

核漂移大说明训练点局部耦合关系改变，表示漂移大说明隐藏激活改变；二者都不足以单独断言“发现了语义”。要研究有用特征，可另做冻结表示后的新任务线性探测、匹配预算的迁移比较，或受控输入干预。这些额外主张不在现有证据中。

反之，有限网格预测差很小也不是两个模型在所有输入完全相等。网格只覆盖 $[-1.5, 1.5]$ 的 151 点，可能漏掉点间和区间外差异。核稳定与预测稳定都是带范围的测量，应写清测量位置和时间。

7 宽度极限与扩展实验答案

至少写清隐藏层宽度趋于无穷、深度约定、 $1/\sqrt{m}$ 参数化、初始化分布、学习率尺度、训练时间或目标幅度是否固定，以及极限顺序。若把训练步数也随宽度无界增加，不应直接沿用固定时间窗口下的近似直觉。

步长减半、步数加倍的扩展近似匹配总训练时间，可帮助区分离散积分误差与长期特征变化；它不能完全排除优化路径、有限时间误差等混杂。发行实验没有跑这个扩展，所以答案只给设计逻辑，不编造数值。

冻结 w, b 只训 a 时，特征矩阵是 $H_0/\sqrt{m}$ ，核为 $H_0 H_0^T/m$ 。完整NTK还包含 w 和 b 导数组成的Gram项，因此不是相同固定核。把模型统称“核回归”之前必须注明核来自哪些可训练参数。

输出缩放改为 $1/m$ 时，全部偏导缩放也改变，初始 K 与 $\lambda_{\max}$ 需要重新计算。若仍用旧 η ，观察到速度变化既可能来自参数化，也可能来自学习率失配。正确研究要把这些尺度一并记录。

8 一段可以被检查的结论

“在单隐藏层 $\tanh$ 、24固定训练点、 $1/\sqrt{m}$ 参数化和500步谱尺度学习率下，27个预定配置真实重训。三种子平均预测差在本扫描中随宽度增加下降，较大目标幅度仍出现明显核与表示变化。结果说明固定初始化线性化有适用区域，也有可测分歧；不构成无限宽证明、普遍泛化保证或语义特征学习认证。”

审查时若看到只报最好配置、把真实网络每步核当固定 K_0 、漏掉平均损失分母 n 、或者把输入线性与参数线性混为一谈，应先修复这些问题，再讨论复杂理论。