

DL075 宽网络核视角与特征学习

发行序号075对应原大纲 **T3**。先修为013、015、027、038，原catalog编号和依赖不变。我们仍从“一个参数小动一点，输出怎样变化”出发，再建立Jacobian、核与宽度极限的语言，不默认读者已经熟悉这些词。

有时神经网络可以被一个更简单的模型准确模仿：先在初始化处测出每个参数对输出的影响，以后把这些影响固定，只学习它们的线性组合。这个替代模型仍可能对输入画出很弯的曲线，却对参数增量是线性的。它为什么有用，什么时候会失效？本讲用同一初值、同一数据和同一步长，同时训练真实网络与这个替代模型，再扫描宽度和目标幅度。

学习目标：能写出一阶参数线性化与NTK的有限矩阵形式；能区别输入非线性与参数线性；能用真实轨迹、核漂移和表示变化判断近似；能解释有限宽实验为何不能直接证明无限宽定理。

1 从一次轻推开始理解线性化

一维函数在点 θ_0 附近，可以用切线近似： $f(\theta_0+d) \approx f(\theta_0) + f'(\theta_0)d$ 。导数只在起点测一次，后续让 d 变化而斜率保持不动。真实曲线弯起来以后，切线就可能逐渐偏离；局部近似的“局部”指改变量足够小，不是说函数本来就线性。

网络有很多参数，把它们排成向量 θ 。一个输入 x 的输出为 $f_\theta(x)$ ，其参数梯度包含每个旋钮的局部影响。初值 θ_0 处的一阶参数线性化定义为

$$f_{\text{lin}}(x; d) = f_{\theta_0}(x) + \nabla_{\theta} f_{\theta_0}(x)^T d, \quad d = \theta - \theta_0.$$

我们会把 d 当作一个独立可训练向量。这里的 θ 只是解释增量的记号，线性化模型的 d 并不被强制等于真实网络训练时的参数变化；两条路径分别更新，它们会逐渐分开。

“对参数线性”不等于“对输入是一条直线”。例如固定函数 $\sin(x)$ 与 $\cos(x)$ ，模型 $d_1 \sin(x) + d_2 \cos(x)$ 对 d 线性，对 x 却是弯曲的。同样，初始化处的梯度特征可以是复杂的输入函数；冻结它们仍能拟合非线性关系。

2 一张表把所有局部影响排整齐

设训练样本有 n 条、参数有 p 个。把第 i 个样本输出对第 j 个参数的偏导放在第 i 行第 j 列，得到 $n \times p$ 的Jacobian矩阵 J 。行对应样本，列对应参数旋钮；它告诉我们“哪一次参数改动会共同影响哪些样本”。

如果 $n=2$ 、 $p=2$ ，且 J 的两行分别为 $(1,0)$ 与 $(1,2)$ 。改变量 $d=(0.1,-0.2)$ ，两条输出近似变化分别为 0.1 和 $0.1-0.4=-0.3$ 。这个例子不需要掌握抽象矩阵论，只需逐行点积。

初始化处的 J 叫 J_0 。线性化模型在训练集上的输出向量为 $f_{\text{lin}} = f_0 + J_0 d$ ，形状依次是 n 维、 $n \times p$ 乘 p 维，最终仍是 n 维。

3 核是样本之间通过参数相遇的方式

两个输入的参数梯度做点积，得到有限网络的神经切线核：

$$K_{\theta}(x, x') = \nabla_{\theta} f_{\theta}(x)^T \nabla_{\theta} f_{\theta}(x').$$

直觉上，若两条样本依赖相似参数方向，改善一条时往往也会影响另一条；点积刻画这种局部耦合。这里不把K当概率，数值不必落在[0,1]，非对角项也可能为负。它是关于“参数怎样共同改变输出”的相似性度量。

对全部训练点成对计算得到Gram矩阵 $K=JJ^T$ ，形状 $n \times n$ 。前面两行梯度(1,0)、(1,2)给出K两行(1,1)、(1,5)。对任意n维向量v，

$$v^T K v = v^T J J^T v = \|J^T v\|^2 \geq 0.$$

这种所有二次型非负的性质叫半正定。它意味着所有特征值非负，允许某些方向的特征值为0；半正定不等于严格正定。若某些样本的梯度行重复，Gram可能没有满秩。实验用小容差判断，因为浮点运算可能给出接近0的微小负数。

核方法可以不用显式更新p个参数，而直接通过 $n \times n$ 矩阵更新输出。但这是一种计算和分析视角，不保证更省内存：n非常大时，存 n^2 项反而昂贵。本课 $n=24$ ，矩阵很小，所以每一步都能检查。

4 从平方损失推到固定核动力学

目标为平均平方损失的一半： $L = \|f - y\|^2 / (2n)$ 。f是训练输出向量，y是真值，残差 $r=f-y$ 。“一半”用于抵消平方求导的2；“平均”除n，使样本量变化时梯度尺度可比较。

对线性化模型，参数梯度为 $\nabla_d L = J_0^T (f_{\text{lin}} - y) / n$ 。梯度下降一步是 $d_{\text{新}} = d_{\text{旧}} - \eta J_0^T r / n$ 。把它再乘 J_0 带回输出，得到精确递推：

$$f_{\text{lin}, t+1} = f_{\text{lin}, t} - \frac{\eta}{n} K_0 (f_{\text{lin}, t} - y), \quad K_0 = J_0 J_0^T.$$

这里对线性化模型是**精确等式**，不是再次近似。真正的非线性网络每次更新后J会改变，而且有限步的输出变化还带有高阶余项；直接写 $f_{\text{新}} = f_{\text{旧}} - \eta K_t r / n$ 只能作为一阶近似。连续时间梯度流中则可由链式法则得到相应微分等式，不能把连续时间等式无缝换成任意有限步长的离散等式。

如果r沿 K_0/n 的一个特征向量方向，该分量每步乘以 $1 - \eta \lambda$ 。只要 $0 < \eta < 2/\lambda_{\text{max}}$ ，所有正特征值方向都收缩；零特征值方向不被这个核学到。大特征值方向通常更快，小特征值方向更慢，这也解释为何固定预算下仍会有残差。



图1 两条路径共享初始函数、数据与学习率，区别只在真实网络每步更新局部影响，而线性化网络冻结 J_0 。

5 选择一个能完整手写的真实网络

本课使用一层隐藏单元的tanh网络，宽度 m 是隐藏单元个数。输入 x 与输出都是标量：

$$f_{\theta}(x) = \frac{1}{\sqrt{m}} \sum_{j=1}^m a_j \tanh(w_j x + b_j).$$

a 是输出权重， w 是输入权重， b 是隐藏偏置。 θ 按 $[a$ 的 m 项、 w 的 m 项、 b 的 m 项]排列，共 $3m$ 项。 $\tanh$ 把实数平滑压到-1至1之间，导数为 $1 - \tanh^2$ 。所有 a 、 w 、 b 都训练，不是只训练最后一层。

初始化 a 和 w 独立取标准正态， b 取标准差0.3的正态。标准正态是均值0、标准差1的钟形分布；随机种子固定为11、23、37。系数 $1/\sqrt{m}$ 防止许多随机项相加后的典型输出尺度随 m 随意膨胀。换成 $1/m$ 或去掉缩放，就改变了参数化与梯度尺度，不能继续假设相同步长与宽度结论。

令 $h_j = \tanh(w_j x + b_j)$ ，逐项应用链式法则：

$$\frac{\partial f}{\partial a_j} = \frac{h_j}{\sqrt{m}}, \quad \frac{\partial f}{\partial w_j} = \frac{a_j(1 - h_j^2)x}{\sqrt{m}}, \quad \frac{\partial f}{\partial b_j} = \frac{a_j(1 - h_j^2)}{\sqrt{m}}.$$

从右往左看，改变 w 先改变 $w x + b$ ，再通过 $\tanh$ 改变 h ，最后乘 a 并汇入输出。这三组偏导沿参数列拼起来，就是代码`forward_jacobian`返回的 J 。有限差分测试逐坐标轻推参数，独立验证这些导数，不调用PyTorch自动求导来掩盖推导过程。

6 宽度与训练幅度需要同时检查

数据由 $g(x) = \sin(2.4x) + 0.25\cos(5x)$ 原创生成。24个训练 x 均匀放在 $[-1.5, 1.5]$ ，另有151点插值网格。目标设为 $A g(x)$ ，宽度 m 取8、32、128，幅度 A 取0.2、1、4，配三种初始化，共27个预定配置。

这里 A 是目标振幅，**不等于参数移动大小**。初始化输出 f_0 一般不为0，所以 A 变小不一定使每个初值的目标残差变小。我们不拿“幅度小”代替真正测量，而同时记录相对参数移动、隐藏表示漂移、核漂移和预测差。目标幅度只是受控干预变量。

每个配置执行500次全批更新。步长固定为 $\eta = 0.3/\lambda_{\max}(K_0/n)$ ，同一配置的真实网络和线性化网络共用。它满足固定核的稳定条件；真实网络的核会变，所以不提供全程非线性稳定保证。不同宽度使用各自初始谱尺度，是控制初始梯度尺度的约定，不是所有配置都用了同一个绝对 η 。

每个配置保留完整初始化、最终真实参数、线性增量与每10步轨迹。实验输出NPZ中的每个网格预测都能从保存参数重新计算。训练点与插值网格均固定无噪声，本实验不是IID泛化估计，也没有测试区间外外推。




图2 两个预定配置的目标与最终预测。左为 $m=8$ 、 $A=4$ ，右为 $m=128$ 、 $A=0.2$ ，种子均为11。展示局部近似可能明显分开，也可能接近；完整27组仍全部报告。

7 一个“近似好不好”需要哪些尺子

预测差取151点网格上的真实与线性化输出RMSE，再除以 A ，便于不同目标幅度比较。RMSE是先平方误差、取平均、再开方，因此单位与输出相同。除 A 后无量纲，但 A 很小时相同绝对差会放大，所以保留原始两组预测；绝对预测差可由相对差乘 A 或两组数组重算，不能只挑有利尺度。

核相对漂移定义为 $\|K_t - K_0\|_F / \|K_0\|_F$ 。下标 F 是Frobenius范数：矩阵各元素平方、相加、开根号。它量化训练点上的耦合关系改变多少，未直接说明未见输入上的核是否也稳定。

隐藏表示 H 由每条样本每个隐藏单元的激活组成，形状 $n \times m$ 。表示相对漂移为 $\|H_t - H_0\|_F / \|H_0\|_F$ 。参数相对移动为 $\|\theta_t - \theta_0\| / \|\theta_0\|$ 。这三把尺子不同：参数变动不一定同样影响输出，表示变化不一定同样影响Gram，核变化也不必单调对应预测差。

这里所有分母都由实际初始化决定且在实验中非零。若另换初始化使某分母为零，必须定义替代尺度或标成未定义，不能随意除以一个极小常数再宣称数值可靠。




图3 实际损失与相对预测差轨迹。虚线是线性化损失，实线是真实网络；相同训练损失不保证在整个插值网格预测相同。

8 真实扫描结果支持到哪里

下表每格是预定三种种子的平均相对预测差，不是选择最好一次。行改变目标幅度，列改变宽度：

A	m=8	m=32	m=128
0.2	0.09410	0.02721	0.01061
1	0.15215	0.09912	0.04428
4	0.21214	0.15932	0.10944

在这个预定扫描里，宽度增加时三种幅度的平均预测差都下降，但没有降到严格零。A=4时m=128仍有约0.10944的相对预测差。不能只展示m=128、A=0.2的小差异，便宣布所有网络都等于核方法。

核平均相对漂移在A=0.2行依次为0.19455、0.06778、0.01618；A=4行依次为4.70939、1.85049、0.70015。值大于1不违背定义：它表示变化的矩阵长度超过初始矩阵长度。A=4、m=8的真实训练损失均值约0.01992，线性化约0.42684，说明在此配置中改变特征与非线性路径确实带来不同拟合行为；这自动等于现实泛化提升。




图4 宽度×幅度扫描的三种子平均。左为预测差，右为核漂移，颜色只在各面板内部比较；不同面板的色标并不相同。

三次初始化太少，无法精确描述所有随机初始化分布；同一宽度内幅度比较使用相同初值，是配对控制；不同宽度虽用相同种子标签，但参数维数不同，不是相同网络的简单扩展。本讲不为这个小型扫描计算“总体显著性”来制造过强外推。

9 什么叫特征学习，不能从哪里偷换结论

固定核模型的“特征”是初始化处的参数梯度函数，它可以非常丰富，但训练时不改变。真实网络的隐藏表示和Jacobian会随参数更新而改变，模型可能调整如何表示输入，这通常被称为特征学习。

本课确实测得H和K的变化，也测得真实与线性化路径不同。它支持“固定初始化特征不足以精确描述本次全过程”的机制结论。但仅见核漂移还不能证明模型学到了有语义、可迁移或更公平的特征；要证明这些主张，需要额外任务、对照与独立评价。




图5 全27配置散点。左图对比核漂移和预测差，右图对比表示变化与参数移动；每个点都是一次真实运行，相关趋势不等于已建立普遍因果定律。

更进一步，可以冻结隐藏层只训练a，与完整网络和 J_0 线性化形成三方比较。不过“只训a”的随机特征核只含对a的导数，与训练全部参数的NTK不同。这个扩展在本发行实验中未运行，不能把两种固定特征模型混写成一个。

10 无限宽是带条件的极限，不是形容词

Jacot等提出NTK视角，在特定网络、参数化、初始化与宽度极限条件下研究训练中的核与收敛。[原论文](#) Lee等进一步研究参数一阶线性化如何描述宽网络的训练动力学。[原论文](#) 这些工作给出分析入口，并不意味着只要日常语言称网络“大”，所有真实训练便自动处在相同极限。

至少需要问：哪个宽度趋于无穷？深度是否固定？权重按什么尺度初始化？学习率随宽度怎样变化？先让宽度趋于无穷还是先训练无限长？目标与训练幅度是否固定？有限步长与连续时间如何对应？更换这些约定可能得到不同极限机制。

关于惰性训练，缩放选择也很重要，并非只有“参数数量多”这一原因。[Chizat等的原始研究](#) 本课没有重新实现该文全部缩放实验，而是在明确参数化下用目标幅度和实际漂移观察局部近似的边界。

11 带着预测去做下一次实验

若真实与线性化路径已经显著分开，可以先缩小学习率并增加步数，区分离散步长误差与表示持续变化；也可以保持预算，换更宽网络看平均差是否缩小。每次只改变一个因素，保存全部结果，避免把计算更多误当纯宽度效应。

合格报告会写：“在固定24点、tanh、 $1/\sqrt{m}$ 参数化和500步谱归一学习率下，三种子平均预测差随本扫描宽度增加而减小；较大目标幅度仍出现明显核漂移，固定初始核不能精确描述全过程。”它没有声称证明无限宽极限，没有把训练拟合等同泛化，也没有把可见表示变化当作已解释的语义机制。

12 在两个输出上手算一轮核更新

继续使用J两行(1,0)、(1,2)的小例子。设初始输出 $f_0=(0,0)$ ，目标 $y=(1,-1)$ ，样本数 $n=2$ ，步长 $\eta=0.1$ 。残差 $r=(-1,1)$ 。先走参数空间： $J^T r=(0,2)$ ，所以 $d_{\text{新}}=-0.1 \times (0,2)/2=(0,-0.1)$ 。再换回输出空间， $J d_{\text{新}}=(0,-0.2)$ 。

现在完全绕过参数做同一步：K两行为(1,1)、(1,5)， $Kr=(0,4)$ ，输出新= $f_0-0.1(0,4)/2=(0,-0.2)$ 。两条计算路径完全一致，说明固定核递推并不是神秘的新训练算法，它只是同一次线性参数更新在输出坐标里的写法。

初始损失为 $(1^2+1^2)/(2 \times 2)=0.5$ 。更新后残差为 $(-1,0.8)$ ，损失为 $(1+0.64)/4=0.41$ 。第一条输出本轮没有改变，并不说明它永远不可学：两个样本梯度有耦合，后续残差变化会改变更新方向。一次梯度为零与整个方向处于永久零特征值空间是不同概念。

K的特征值为3加 $\sqrt{5}$ ，因此 K/n 的最大特征值为 $(3+\sqrt{5})/2 \approx 2.618$ 。 $\eta=0.1$ 小于 $2/2.618 \approx 0.764$ ，满足这个固定核的稳定区间。若学习率错误地按K而不是 K/n 的谱尺度定义，步长单位就差了样本数 n ；代码中记录 $\text{loss}=\text{'mean squared error'}/2$ 正是为了让这种尺度可追溯。

13 一阶余项与“靠近初始化”的尺度

光滑函数的Taylor余项可以沿参数增量 d 展开。若沿相关路径输出的二阶变化率受到常数 B 控制，某个输入处的一阶近似误差可被 $B||d||^2/2$ 这类量控制。它解释为何步子缩半时局部余项常约缩至四分之一，也解释为什么测试里会比较0.01和0.005两种扰动。

但参数维数增大时，“每个坐标只动一点”与“整个向量长度很小”不是同一件事。 p 个坐标各移动 c ，总长度是 $\sqrt{p} \times |c|$ 。宽网络的理论通常利用参数化、随机性和集体平均等结构，而非简单要求所有参数欧氏距离都无限小。用相对参数移动、核漂移与函数差互相印证，比只盯一项更稳妥。

反方向也要小心：存在参数对称性时，参数可以明显改变而函数几乎不变。隐藏单元重新排序，同时重排相应 a 、 w 、 b ，就给出完全相同的函数，却可能改变参数向量的表面距离。当前实验沿连续训练路径逐帧比较同编号单元，避免人为换序；它仍不能把参数距离当作函数距离的同义词。

要说“核视角忽略了什么”，最具体的回答是：冻结 J_0 会忽略训练中局部影响函数如何被重新组织，以及因此改变的样本耦合。如果任务需要学习新的表示，这可能重要；若当前尺度下 J 变化很小，固定核可能已经很好。选择分析工具应由测量和条件驱动，而不是先把网络贴成“核”或“非核”再挑图证明。