

DL077 练习答案与解释

本页对应原大纲 T5。数值来自固定发行实验；更换种子或模型后应报告新结果，不应手改输出使其符合答案。

1 梯度、积分与单位

练习1：设 $a=2x_1-x_2$ ， $f=3\tanh(a)+1$ 。在 $(0,0)$ ， $a=0$ 、 $\tanh(a)=0$ ，所以 $\tanh$ 导数 $1-\tanh^2(a)=1$ 。对 x_1 梯度为 $3 \times 1 \times 2=6$ ，对 x_2 为 $3 \times 1 \times (-1)=-3$ 。偏置1是不随输入改变的常数，导数为0。

中央差分将 x_1 分别加减 ϵ ，比较输出差再除 2ϵ ；对 x_2 同理。 ϵ 取 10^{-6} 时应非常接近 $(6,-3)$ ，但浮点舍入和差分截断误差使严格逐位相等不合理。测试使用数值容差，并检查两个不同查询点，避免只在梯度偶然为零的点验证。

练习2：线性函数梯度处处 $(2,3)$ 。从 $(0,0)$ 到 $(1,2)$ ，位移 $(1,2)$ ， $IG=(2,6)$ ，总和8等于 $f(1,2)-f(0,0)$ 。从 $(1,0)$ 出发，位移 $(0,2)$ ， $IG=(0,6)$ ，总和6等于 $f(1,2)-f(1,0)$ 。模型及目标点完全没变，改变的是“相对哪个参考状态”的问题。

因此“完整性”不能选出唯一基线。两个不同基线都可满足完整性，却给出不同归因。若报告省略基线，读者无法判断解释的分母背景。非线性模型里不同路径也可能改变各字段的分配，虽然总变化仍等于端点输出差。

练习3： $s=100x_1$ ，则 $\partial g / \partial s = (1/100) \partial f / \partial x_1$ 。原来1米变化等于100厘米变化，所以梯度缩小100倍、位移增大100倍，局部输出预测的乘积不变。拿两种单位下的原始梯度数字直接比较“重要性”会误导。

IG若同时正确变换目标、基线、路径和模型，线性单位缩放带来的导数缩小与位移增大可抵消。本题并不是说任意预处理下所有归因方法都不变；要区分特定线性换单位与改变模型/输入编码/基线含义。

2 随机化和扰动的真实结论

练习4：固定查询(0.8,4.0)的已训练梯度约(0.01422,1.00762)。零基线IG约(-0.00344,3.99532)；替代基线(0.5,2.5)的IG约(0.00410,1.50337)。第一字段的符号甚至可变化，但绝对贡献都很小。总和对应不同参考输出差，不应强求相等。

80个探测点上的相对L2变化：仅随机输出层约1.0379，全随机约1.0110；带符号余弦分别约-0.9269和-0.6204。它们支持归因依赖已训练参数这一有限结论。负余弦说明方向改变，若只画绝对值或每张图单独拉伸颜色范围，会隐藏重要变化。

不能据此宣布“解释正确”。随机参数自然可能改变很多图；通过这项检查不证明归因是唯一分解，不证明对所有查询点忠实，不证明所有基线合理，更不证明现实因果。检验有明确可否定对象，价值在于缩小错误主张，而非颁发万能认证。

练习5的真实结果如下；线性预测使用固定查询点的Z偏导数乘增量。

Z增量	实际输出变化	梯度线性预测
0.001	0.001007623	0.001007622
0.01	0.010076336	0.010076221
0.1	0.100774266	0.100762206
1.0	1.008979090	1.007622062

绝对误差随增量增加，但这条路径上最大增量的误差仍很小，约0.00136。正确解释是局部近似在此例的这段路径上较好；不能写成“所有大改动都会失败”或“梯度可以预测任意远处”。可另选饱和区探索，但必须另存并明确新查询点的选择过程。

完整性误差约 2.21×10^{-8} 说明512段中点积分近似良好。若把步数改成1，完整性一般变差；这主要检验积分分辨率，不是检验世界因果。在数值教学中把两个误差来源分开命名，有助于避免夸大检查结果。

3 混杂、干预和报告范例

练习6: 观察斜率为 $2+3\text{Cov}(X,U)/\text{Var}(X)$ 。由 $X=U+\varepsilon_X$ 且独立, 可得 $\text{Cov}(X,U)=1$ 、 $\text{Var}(X)=1.16$, 所以总体斜率 $2+3/1.16 \approx 4.5862$ 。实际400条测试数据估得4.5933; 控制正确共同原因U后X斜率约1.9836。真正 $\text{do}(X)$ 效应为2, 直接来自Y方程中X的系数。

增加样本使观察斜率更稳定地靠近4.5862, 不会让混杂项消失。这区分“估计误差”和“目标不一致”: 有限样本误差可随更多数据下降, 但错误目标即使估得极精确也仍不是干预效应。

练习7: 某个体 $U=u$ 、 $\varepsilon_Y=e$ 时, $\text{do}(X=-0.5)$ 给出 $Y_0=-1+3u+e$; $\text{do}(X=0.5)$ 给出 $Y_1=1+3u+e$, 因此 $Y_1-Y_0=2$ 。Z在两个世界分别为 $Y_0+\varepsilon_Z$ 、 $Y_1+\varepsilon_Z$, 也相差2。若只干预Z, Y方程没有Z, 因此Y不变。

只改变模型输入X并保留旧Z, 是一个合法的函数查询, 但不等于上述自然下游重算的结构干预。模型对一致重算后的成对输入平均响应约1.9615, 接近2; 它仍可能只是利用新Z读出了结果。网络没有因此获得对机制的独立因果理解。

练习8: 去掉Z后, 最小二乘预测会接近 $E[Y|X]$, 在线性高斯世界其斜率就是约4.5862。它利用混杂带来的可预测信息。若想估计X对Y效应, 应明确U是正确的充分调整变量, 或获得适当随机干预数据; 仅删除事后代理不解决共同原因。

一份合格的解释报告

“我们对固定 $2 \rightarrow 12 \rightarrow 1$ 网络, 在(0.8,4.0)上使用零基线与512段中点积分。IG完整性误差约 2.21×10^{-8} ; 80个探测点的归因在输出层与全参数随机化后均显著改变; 小步Z扰动与解析梯度一致。结果支持解释反映该模型的参数与局部输入依赖。”

“但模型主要依赖Z, Z是Y的事后测量。在已知SCM中 $\text{do}(Z)$ 不改变Y, 而模型对Z加1的平均输出响应约0.993; $\text{do}(X)$ 效应2又与观察斜率4.593不同。因此该实验反驳把预测归因直接当世界因果的主张。数据为合成机制, 图由设计给定, 没有声称从观察样本识别真实因果图, 也没有可部署的提前预测系统。”

这段报告同时承认方法有用和证据边界。10项测试验证实现与已知机制; 可复现不自动等于外部有效。更多来源与实际执行范围见 [sources.md](#)、[verification.json](#)。