

DL077 可解释性与因果主张

发行序号 077 对应原大纲 T5。 保留原先修 011、022、071；本讲不修改 catalog 编号。我们将一个容易混淆的问题拆开：某字段影响模型输出，是否意味着改变该字段会改变真实结果？回答通常需要两套不同的证据。

1 先写清解释对象

设一个已训练函数 f 接收两个数字 X 和 Z ，输出对 Y 的预测。归因方法把输出或输出变化分配到输入字段，帮助检查模型使用了什么线索。因果问题则询问在现实生成过程中实施干预， Y 会怎样变化。前者研究已经写好的计算程序，后者研究世界的生成机制。

例如 Z 是事后仪表对 Y 的精确测量，模型自然会依赖 Z 。把屏幕显示值改掉会改变模型读到的输入，却不会回到过去改变 Y 。预测上的重要性和可操控的原因在这里明显分叉。本课不是部署建议；若实际任务要求在 Y 发生前预测，使用事后 Z 会造成不可用信息或目标泄漏。



从这里走向现实干预，需要额外生成机制与识别假设

图1 模型归因回答计算依赖。要转向现实干预，需要额外的变量时间顺序、机制和识别假设。

本讲中心边界：梯度、积分梯度、注意力权重或热力图都不能仅凭自身证明世界中的因果效应。好看的图只是表达形式。我们会在小网络里用参数随机化、输入扰动和已知机制干预分别检验不同主张。

初学者无需先掌握矩阵微积分。下面从“轻轻改动一个输入”的斜率出发，再用一条路径把斜率累积起来；最后进入能手算的四条生成方程。完整实验仅用 NumPy，没有下载数据或调用外部模型。

2 梯度：把很小的改动传播到输出

导数表示输入发生极小改变时，输出变化与输入变化的比值。对于有多个输入的函数，偏导数 $\partial f / \partial x_j$ 指只动第 j 个字段，其他输入暂时固定。把各偏导数排成向量就是梯度。梯度的单位是“输出单位除以该输入单位”，因此不同尺度的原始梯度不能直接当无量纲重要性比较。

对足够小的改动 δ ，可以使用局部一阶近似：

$$f(x + \delta) - f(x) \approx \sum_j \frac{\partial f(x)}{\partial x_j} \delta_j.$$

这不是全局等式。输入改动越大、路径上曲率越强，误差通常越明显。在饱和区域，某点梯度可以接近零，即使从远处移动到这里时输出已经发生很大变化。因此“此点不敏感”和“这个字段从未重要”不是同一命题。

把小网络的链式法则写出来

本实验使用 $2 \rightarrow 12 \rightarrow 1$ 网络。输入 x 有两个元素，隐藏单元 j 先算 $a_j = w_{1j}x_1 + w_{2j}x_2 + b_j$ ，再算 $h_j = \tanh(a_j)$ ，输出 $f = \sum_j v_j h_j + c$ 。 w 是输入权重， b 是隐藏偏置， v 是输出权重， c 是输出偏置。求导时 c 不随输入变化而消失。

$$\frac{\partial f}{\partial x_i} = \sum_{j=1}^{12} v_j (1 - h_j^2) w_{ij}.$$

因果顺序是：改动 x_i ，先经 w_{ij} 改变 a_j ； $\tanh$ 的斜率是 $1 - h_j^2$ ；最后乘输出权重 v_j ，再把12条路径相加。这就是代码 $((1 - h * h) * v) @ w.T$ 的逐项含义。 $@$ 表示按行列求乘积和， T 把原来的 2×12 权重表转成 12×2 。

实际梯度必须核对。测试把每个输入分别加减 10^{-6} ，用 $(f(x + \epsilon) - f(x - \epsilon)) / (2\epsilon)$ 作中央差分，与解析结果比较。差分也受舍入与步长影响，所以使用合理容差，不要求所有浮点数字逐位相等。

3 积分梯度：给“相对哪个起点”一个明确答案

普通梯度只描述当前位置的斜率。若希望解释“为何从参考输入 b 的输出变成当前 x 的输出”，就需要路径。积分梯度 IG 选择直线路径 $b + \alpha(x - b)$ ， α 从0走到1，把每个字段沿途的偏导数平均，再乘该字段总位移：

$$IG_i(x; b) = (x_i - b_i) \int_0^1 \frac{\partial f(b + \alpha(x - b))}{\partial x_i} d\alpha.$$

b 是基线，分号表示我们特别强调它是解释设计的一部分。积分可看作沿途许多小段贡献之和。代码把路径分成512段，在每段中点算梯度，再平均；这叫中点数值积分，并不是调用一个神秘解释服务。[1]

由链式法则，沿路径对 α 求导得到各字段贡献之和；再对0到1积分，有：

$$\sum_i IG_i(x; b) = f(x) - f(b).$$

这是完整性性质：归因总和解释相对于基线的输出差。它不保证每一项是唯一正确的现实原因，也不保证路径上的组合是现实可发生状态。实际数值积分只有近似完整性，所以脚本保存 `completeness_error`。




图2 同一个目标输入可以从不同基线出发。两条路径的终点相同，累计位移和参考输出不同，归因当然可以改变。

手算一个线性例子： $f(x_1, x_2) = 2x_1 + 3x_2$ ， $x = (1, 2)$ ， $b = (0, 0)$ 。路径上梯度处处是 $(2, 3)$ ， $IG = (2, 6)$ ，总和8等于输出差。把基线改为 $(1, 0)$ ，第一字段从未移动，归因变为 $(0, 6)$ 。这不是算法出错，而是解释问题已经变了。

4 一张归因图需要哪些反驳机会

参数随机化检查。 如果解释被宣称反映已学习的模型行为，就把已训练参数逐步替换为随机参数，观察解释是否变化。本实验先只随机输出层，再随机全部网络；输入、基线和解释算法保持一致。若所谓解释几乎不变，它可能主要反映输入结构、绘图规则或方法固有偏好。[2]

变化本身也不是万能通行证。随机化后归因变化，只支持“解释依赖这些参数”的有限结论，不能证明它忠实捕捉了所有模型机制，更不能证明因果。本实验报告80个固定探测样本归因矩阵的相对 L2 变化和带符号余弦，不把绝对值热图相似当唯一指标。

L2 长度是各项平方和的平方根。相对变化把“随机化后减原归因”的长度除以原归因长度；大于1表示变化幅度超过原始总长度。带符号余弦是两组数的点积除以各自长度乘积，范围-1到1；负数可能表示方向相反。绘图若只看绝对值，会隐藏这类符号变化。




图3 同一目标点的基线改变与参数随机化。固定纵轴的数值比较比各自自动缩放的热图更能揭示幅度和符号变化。

输入扰动检查。 对 Z 依次增加0.001、0.01、0.1、1.0，其他模型输入保持不变，比较实际输出增量与梯度预测。小步一致验证局部导数，大步误差反映曲率；本次模型在该路径上仍接近线性，不应为了讲故事虚构大幅失效。

基线与尺度检查。 单位从米换成厘米，梯度数值会缩小100倍，但真实函数依赖可以完全不变。比较前应统一单位或明确使用“单位变化”的定义。基线也应记录选择理由与可行性；全零只是一个可复算的起点，未必代表“没有信息”。

5 用已知世界理解干预、混杂与识别

我们构造四个外生随机量：U 是共同原因； ε_X 、 ε_Y 、 ε_Z 是互相独立、也与 U 独立的高斯噪声，标准差分别为0.4、0.2、0.08；U 标准差为1。外生表示在这张机制图中不由其他变量计算出来。生成过程按下面顺序执行：

$$X = U + \varepsilon_X, \quad Y = 2X + 3U + \varepsilon_Y, \quad Z = Y + \varepsilon_Z.$$

U 同时影响 X 和 Y，所以观察到 X 大的人也往往 U 大。即使不改变 X，仅共同原因的变化也会导致 X、Y 一起变化。这叫混杂。Z 在 Y 之后生成，是结果的精确代理；它帮助预测已经发生的 Y，却没有进入 Y 的生成方程。




图4 已知结构因果模型。箭头是明确声明的生成机制，不是从相关系数图自动推断出的因果真相。

$\text{do}(X=x)$ 表示替换 X 原来的方程，直接设为 x；U、 ε_Y 等保持各自原有分布，随后按新 X 重新计算 Y 和 Z。与观察 $X=x$ 不同，观察会偏向某些 U，而干预切断 $U \rightarrow X$ 的生成关系。Pearl 的结构模型语言用于表达这种区别。[3]

本世界中把 X 从-0.5改为0.5，保持同一个 U 和噪声，Y 的差严格为2。若只改变 Z，Y 方程完全没变，所以效应严格为0。实验把这些成对结果保存，允许逐例核查。这里结论成立的依据是我们知道并控制生成机制；并不是网络的低测试误差赋予了因果识别能力。

现实里通常不能直接看到所有机制。要从观察数据识别效应，需要额外假设，如正确的时间顺序、适当测量的混杂变量、无未控制共同原因、一致性和足够的处理取值覆盖。假设不足时，更多数据或更复杂网络未必解决识别问题。

6 观察回归为何把2看成约4.59

协方差描述两个变量是否一起偏离均值；方差是变量与自身的协方差。带截距的一元最小二乘斜率等于 $\text{Cov}(X,Y)/\text{Var}(X)$ 。代入已知结构 $Y=2X+3U+\varepsilon_y$ ，并利用独立噪声，可得总体斜率：

$$\frac{\text{Cov}(X, Y)}{\text{Var}(X)} = 2 + 3 \frac{\text{Cov}(X, U)}{\text{Var}(X)} = 2 + \frac{3}{1+0.4^2} \approx 4.586.$$

这里 $\text{Cov}(X,U)=1$ ，因为 $X=U+\text{独立噪声}$ ； $\text{Var}(X)=1+0.16$ 。额外的约2.586来自共同原因的观察关联，不能算作改变 X 的效果。实际400个测试样本的一元斜率约4.593，接近这个总体推导；差别来自有限样本。

把 U 作为调整变量，与 X 一起回归 Y ，估得 X 斜率约1.984，接近结构系数2。这是因为我们特意知道 U 是正确共同原因且模型线性。不是“控制越多越好”：控制下游变量、碰撞点或错误测量可能改变目标或引入偏差。 Z 在结果之后，尤其不应被不加思考地当作估计 X 总效应的调整变量。




图5 左图检查局部梯度能否预测输入扰动的模型响应；右图显示近似误差随步长增加。它验证计算关系，并未实施真实世界干预。

再问一个常见问题：“保持其他字段不变，不就是控制实验吗？”在函数里固定另一个坐标，是一个定义明确的模型查询；但世界里的其他变量可能是被干预变量的后果。 $\text{do}(X)$ 后 Z 应随 Y 重新生成，不能一边改变 X 、一边强行把原 Z 保持不变，然后宣称这是同一个自然干预。

反事实进一步询问“对这个相同个体，如果当时改变 X 会怎样”。本课保留同一外生噪声做成对计算，这是在已知结构模型中的反事实耦合；现实里对个体噪声的推断可能不唯一，平均干预效应可识别也不代表每个个体反事实都可识别。

7 从训练、测试到因果反例的真实证据

训练集600条，数据种子7701；独立测试400条，种子7702。网络训练1800次全批Adam更新，初始化种子17；参数随机化种子77。没有测试集选模型或挑查询点，教学查询固定为 $(X,Z)=(0.8,4.0)$ 。网络只读 X、Z，U 只用于验证已知机制和调整回归。

检查对象	本次结果	支持的有限结论
测试 RMSE	0.0889	网络精确读取了事后代理
查询点对 X 的梯度	0.0142	模型局部对 X 不敏感
查询点对 Z 的梯度	1.0076	模型局部强依赖 Z
零基线 IG 完整性误差	约 2.21×10^{-8}	数值积分与输出差吻合
随机输出层归因相对变化	1.0379	归因依赖已训练输出层
全随机网络归因相对变化	1.0110	归因依赖已训练参数

完整性误差和梯度差分是计算验证；低 RMSE 是预测验证；因果效果来自结构干预验证。把三类验证放在同一表里不应抹掉它们的证据范围。没有真实业务数据，所以这些数字不能外推为某个行业系统的可靠性。




图6 左：观察斜率、调整斜率与真正干预效应。右：模型输入Z加1时预测平均改变约0.993，真实世界do(Z)的Y变化却为0。

值得注意的是，按机制同时更新 X、Y、Z 后，模型对 X 的成对干预输入响应约1.961，接近真实效应2。这个吻合来自新输入带入了结果的下游代理，并不能证明模型学会了 $X \rightarrow Y$ 的机制。如果推理时不能获得干预后的 Z，这个路径就不可用。

8 如何写出不越界的解释报告

一份可信报告先写查询：解释哪个模型、哪个输出、哪个样本、相对什么基线。然后写方法及数值精度：解析梯度如何检查，积分分多少段，随机化替换哪些层，用什么相似度，扰动是否处于合理范围。最后再说明该证据支持何种主张，而非用“可解释”一词替代所有细节。

可接受结论：在固定合成模型和查询点上，网络主要依赖下游代理 Z；积分梯度随参数和基线改变；但生成机制中干预 Z 对 Y 没有效果。因此本例的归因重要性不等同于世界因果效应。

不接受的跳跃包括：“热图最亮的像素是现实原因”“注意力大证明这个词导致结果”“随机化通过所以解释完全正确”“控制了很多变量所以没有混杂”。这些语句都缺少从模型计算走向现实机制的桥梁。可以把归因用于排查捷径、提出假设和设计后续实验，但新的因果主张仍需独立证据。

预设疑问与下一步

归因没有因果保证，那还有什么用？ 它可以发现模型依赖了不可用字段、提示单位错误、比较不同基线、检查梯度实现。本课恰恰用归因发现网络依赖事后代理，再用机制解释为何这不构成可操控原因。把用途写准确比把方法一概否定更有帮助。

如果移除 Z，X 的归因就能当因果效应吗？ 不能。模型可能用 X 预测混杂造成的关系，学得约4.59的观察斜率，而干预效应是2。删除明显代理解决一个信息边界问题，却不自动消除 U 的混杂。

能否从这400条数据证明真实图？ 本讲的图由生成程序给定，不是从400条样本中发现的。现实中多个因果模型可能具有相同观察分布。识别关注在明确假设下，目标效应是否由可观察分布唯一确定；估计关注有限样本里怎么算得准，两者顺序不能颠倒。

建议完成 [lab.md](#) 的手算、改基线和机制改写后，再看 [answers.md](#)。原论文入口与核对范围见 [sources.md](#)。本讲完成 T1-T5 发行批次的最后一讲；这里不新增后续分支或学习排期。