

DL083 练习与参考答案

建议先合上答案，用纸笔完成第1至6题，再用代码完成后四题。答案的数值容差与结论范围同样是评分的一部分。

1 参数数目

题目： 一个投影层输入维数512，输出维数256，LoRA秩为8。全量与低秩可训练参数各多少？底座是否消失？

答案： 全量为 $512 \times 256 = 131072$ ；低秩为 $8 \times 512 + 256 \times 8 = 6144$ ，约为全量的4.6875%。底座不消失，仍需存储并参与计算。6144不包括偏置、其他层和优化器状态。把这个比例直接当作峰值显存缩小比例不得分。

2 什么时候反而更多

题目： 本课 8×12 矩阵，取 $r=8$ 是否省参数？阈值是多少？

答案： 因子参数为 $8 \times (12+8) = 160$ ，多于96。省参数条件为 $r < 96/20 = 4.8$ ，所以整数 $r=1$ 至4省参数； $r=5$ 开始不省。即便因子参数较多，乘积仍受秩上限约束，但不能再称作此层的参数节省。

3 掩码分母

题目： 有效token损失为0.2、0.3、0.4、0.5，前一个来自短回答，后三个来自长回答。按token和按回答平均各是多少？

答案： token平均 $1.4/4 = 0.35$ ；回答平均为 $(0.2 + (0.3 + 0.4 + 0.5)/3)/2 = 0.3$ 。前者给每个token相等权重，后者给每条回答相等权重。必须说明选择，不应把其中一个隐藏在训练器默认值中。全零掩码需拒绝或跳过，并明确样本计数。

4 初始梯度

题目： A随机、B为零时，哪一个因子先学习？若二者为零呢？

答案： $dA = sB^T G = 0$ ； $dB = sG A^T$ 一般非零，因此B先动。下一次B不为零后，A可能开始更新。二者都为零时两个梯度都为零，普通梯度下降无法离开这个点。注意“一般非零”不是逻辑必然，某些特殊G也可能与A正交。

5 矩阵方向

题目： X形状为 $n \times d$ ，W为 $k \times d$ ，为什么代码用 XW^T ？LoRA支路怎样写？

答案： 每个样本按行存储， XW^T 得到 $n \times k$ 。支路为 $(XA^T)B^T$ ，形状依次为 $n \times r$ 、 $n \times k$ 。两路加法要求输出形状相同。把BA顺序颠倒通常形状就不匹配；恰好为方阵时也可能悄悄计算错误，故仍需数值测试。

6 合并等价的边界

题目：为什么合并后结果相同？是否说明所有部署没有额外误差和延迟？

答案：由矩阵乘法分配律， $(W_0+BA)h=W_0h+B(Ah)$ 。这是当前线性结构在实数代数中的等式。浮点舍入可能导致微小差别；训练dropout、重新量化、不同内核和其他适配结构需另外验证。不能由等式直接得到整套服务的性能结论。

7 读出遗忘

题目：新域NLL从1.967降为1.457，旧域从1.663升为3.281。能否只报告“模型改善”？

答案：不能。新域改善与旧域退化同时发生，说明目标之间有取舍。应报告两个评价域、样本数、指标和适用范围。若任务允许旧域损失，应提前给出容忍阈值；不能在看到结果后临时说旧域不重要。该合成冲突不估计真实LLM遗忘幅度。

8 参数字节与显存

题目：秩2有40个float64参数，320字节是否就是训练内存？

答案：不是。320字节只计算A和B本身。还包括底座96个数、梯度、输入批次、logits、中间量、Python对象及可能的优化器状态。GPU训练还可能有分配器缓存与临时工作区。测峰值应采用设备测量协议，而非只做参数乘法。

9 设计更公平比较

题目：所有方法用相同700步与学习率，是否足够公平？

答案：它控制了部分因素，却不保证相同算力或充分调优。不同参数化可能需要不同学习率，相同步数的计算量也可能不同。更严谨方案先划独立验证集，为每种方法分配相同调参预算，锁定配置后评价测试，并报告实际计算资源。若资源不足，应把结论限定为固定协议比较。

10 哪些结论不能写

题目：本课LoRA在微型模型上通过梯度、秩和合并测试。可以说它让大型科研语言模型更准确吗？

答案：不可以。已验证的是小型条件softmax模型的实现与有限合成数据行为，没有训练Transformer、没有自然语言任务、没有真实科研正确性或安全评价。可写“验证低秩更新机制，并展示适配与保留的取舍”。真实模型扩展需新的授权模型、数据、预算、评价与失败审计。