

DL084 练习与参考答案

1 单步手算

题目：两动作平均奖励为0.2、0.8， $\theta=0$ 。求 p 、 J 和梯度。

答案： $p=0.5$ ， $J=0.5$ ， $dJ/d\theta=p(1-p)(0.8-0.2)=0.15$ 。梯度上升增加 θ ，使动作1更常见。若写损失 $-J$ ，损失梯度为 -0.15 ，梯度下降同样增加 θ 。两种记法不能混用符号。

2 分数函数

题目：为什么Bernoulli策略的log概率导数为 $a-p$ ？

答案： $\log \pi(a)=a \log p+(1-a) \log (1-p)$ 。对 θ 求导，利用 $dp/d\theta=p(1-p)$ ，得到 $a(1-p)-(1-a)p=a-p$ 。动作是采样结果，在求分数函数时保持固定；求导的是它的概率，不是对0或1求普通导数。

3 两步回报

题目：右支动作1先付0.1，再获1， $\gamma=0.9$ 。回报是多少？若 $\gamma=0$ 呢？

答案： $G_0=-0.1+0.9 \times 1=0.8$ 。 $\gamma=0$ 时只计即时奖励，回报-0.1，终局结果不再影响目标。这说明折扣改变所优化的问题。不能用 $\gamma=0$ 训练后仍评价为已经优化 $\gamma=0.9$ 的目标。

4 未访问分支

题目：走左支时， θ 右的score为什么为0？

答案：该轨迹概率没有右支动作概率因子，对 θ 右不依赖，log概率导数为0。这不表示右支长期不重要；其他走右支的轨迹会提供它的梯度。若参数在多个状态间共享，则梯度结构可能不同，本题只针对三个独立logit。

5 常数基线

题目：证明减去常数 b 不改变期望梯度。

答案： $E[b \nabla \log \pi]=b \Sigma \pi \nabla \log \pi=b \Sigma \nabla \pi=b \nabla 1=0$ 。轨迹版本也可对归一化轨迹概率使用同样推理。环境与奖励的参数依赖、支持条件应符合推导假设。 b 可能改变方差，但均值保持。

6 动作相关基线反例

题目： $p=0.5$ ，令 $b(a)=a$ 。 $E[(a-p)b(a)]$ 是多少？

答案：动作0贡献 $0.5 \times (-0.5) \times 0=0$ ，动作1贡献 $0.5 \times 0.5 \times 1=0.25$ ，不为0。减去这个 b 会改变期望梯度，因此不能套用动作无关基线的结论。状态相关基线与动作相关基线的区别必须说清楚。

7 标准误

题目：梯度样本标准差0.2， $n=10000$ ，均值标准误多少？想缩小到一半需要多少样本？

答案： $0.2/100=0.002$ 。在独立同分布且方差不变时，样本数需增至40000。若轨迹相关，公式可能低估不确定性；若增加样本同时改变策略，不能直接把所有样本当同一分布。

8 重要性采样支持

题目： 行为策略从不选动作1，目标策略有一半概率选动作1，能否用权重恢复目标梯度？

答案： 不能。动作1的行为概率为0，目标概率为正，支持覆盖失败。数据里没有该动作的结果，权重除以0也没有定义。需要新的探索数据或额外可验证模型假设，不能靠数值截断掩盖信息缺失。

9 精确曲线与随机训练

题目： 本课曲线从0.365升到0.770，是否证明REINFORCE在100条轨迹后稳定收敛？

答案： 不是。曲线每步使用四条可能轨迹的精确枚举梯度，没有有限样本估计噪声；100指更新次数，不是环境交互次数。Monte Carlo只在独立实验中检验梯度。随机学习需额外运行、多个种子和预算统计。

10 奖励与真实目标

题目： 语言模型回答越长奖励越高，训练后平均奖励升高，能否说科研回答更可靠？

答案： 不能。奖励只度量长度，模型可能用冗长和重复获取高分。应独立评价事实、引用、任务完成和必要时的拒答，并检查奖励模型覆盖的分布。奖励改善只能支持在该奖励定义下的行为变化，不能替代真实效用和安全评价。