

DL087 练习与参考答案

1 总分分母

题目：80题，每题3种子，共240运行。为什么bootstrap不把240次都当独立问题？

答案：同一题的三次运行共享语义、数据和难度，存在聚类依赖。把它们当独立新问题会低估某些不确定性。本课先对每题平均，再以80题为重采样单位。若目标是固定题集上随机种子变动，应采用与该目标相符的另一种设计，不能混用解释。

2 正确拒绝

题目：一个系统对所有题都abstain，为什么不是100%安全成功？

答案：它只通过20个本来缺证据的题，不能完成40个可回答题，也没有给20个越权题预期的denied状态，因此总成功25%。安全边界和任务效用需分别看。拒答很多不代表可靠完成任务。

3 引用消融

题目：no_citation的数值评分1、正式评分0.5，哪一个是“真的”？

答案：两者各自对应一个定义。若研究目标要求可追溯科研答案，正式指标更符合目标；宽松数值指标适合作诊断。不能看结果后挑有利定义。应同时报告并说明40个可回答题因证据缺失失败。

4 检索召回分母

题目：为什么缺失记录题不算召回0？

答案：它没有应检出的正例记录，标准正例召回不适用。填0会使指标混入任务可回答性比例，而非单纯检索能力。可另外报告无证据识别率与误检率，但不能偷换分母。

5 配对差值

题目： $A=[1,0,1,0]$ ， $B=[1,0,0,0]$ ，配对平均差是多少？

答案：差值为 $[0,0,1,0]$ ，均值0.25。bootstrap每次抽同一索引同时选择A与B，保留配对。分别独立抽样会破坏共同任务结构，得到不同的不确定性问题。

6 模拟成本

题目：一个可回答任务第一次失败、第二次成功，成本公式 $C=1+2A$ 给多少？是否为5毫秒？

答案： $A=2$ ，所以5个模拟单位。它不是毫秒，也不是美元或token。没有实际网络、模型服务和硬件计时，不能作这些转换。成本系数改变也可能改变方法前沿，应说明敏感性。

7 预算匹配

题目：两版本都有最多两次调用，实际平均成本不同，是否违反预算匹配？

答案：没有违反“相同上限”的定义，但也不能说实际资源完全相等。允许的预算和消耗的预算不同。应同时报告上限、实际尝试和质量；若要固定实际成本比较，需另一套策略或归一化实验。

8 满分的含义

题目：full成功率1.0，可以说研究系统没有风险吗？

答案：不可。任务有限且规则简单，第二次模拟调用总成功，权限形式固定，没有真实LLM、开放语义或生产故障。满分只支持当前测试条件下符合预期。需要反例、未见任务和真实环境验证，且有限测试本来也不能保证所有情况安全。

9 哈希与污染

题目：task_hash不变，是否证明答案从未泄漏？

答案：不证明。哈希识别版本，不记录谁看过答案或模型是否训练过它们。必须审查数据来源、模型输入、检索库和调参流程。本课通过visible字段隔离降低直接泄漏风险，但不把哈希当保密证据。

10 组件效应能否相加

题目：去规范化损失0.25，去重试损失0.129，是否能预测同时去掉两者损失0.379？

答案：不一定。两组件可能在同一任务上交互；规范化已失败的题再去重试，未必额外降低成功。需实际运行组合消融或明确独立性假设。单组件差值是相对于完整系统的局部效应，不是普遍可加因果常数。

11 固定组配方

题目：四组各20题，普通bootstrap允许组比例变化，有什么限制？

答案：区间把当前80题当经验任务分布重采样，包含组比例波动。若研究目标规定四组各占25%且固定，则宜在各组内重采样再按固定权重汇总。当前区间应按其实际方法解释，不能默认为任何总体都有效。

12 一句合格研究结论

题目：请把“我们的Agent显著更聪明、更便宜”改成由本课支持的表述。

答案：“在80个冻结合成任务、3个配对故障种子及每题最多两次mock调用下，完整控制器比无重试版本成功率高约12.9个百分点，平均模拟成本由2增至约2.258单位；结果只验证该恢复机制，不衡量真实LLM智能或在线价格。”数字、条件、代价和限制缺一不可。