DL092 练习答案与研究审查

1 四种组合与信息条件

(a,b)为(+1,+1)或(-1,-1)时y=1，其余两种y=0。a、b独立均匀，给定a以后b仍各有一半概率，因此仅凭a无法将总体准确率提高到50%以上。有限测试集可能偏离50%，这是抽样波动，不是反例。

加入z后信息条件变了。z与标签约95%一致，所以文本模型只用z就能很好预测原域。不能一边允许文本读z，一边引用“b独立于y”证明它应只有50%。模型名称不是信息条件，实际字段才是。

2 一步梯度手算

Fw=-1.2，sigmoid(-1.2)约0.231475。标签y=0，p-y约0.231475。交互特征为-1.2，所以交互权重梯度的未正则化单样本贡献约-0.27777。梯度下降减去负数，因此交互权重增加；分数变得更负，预测y=1的概率下降，朝正确方向移动。

若学习率0.12且暂不计正则与其他样本，权重从1变为约1.033332。真实代码使用全批平均并加λw，所以不能把单样本数值当作整个训练步的实际更新。

3 配对差值

A错误来自共同错误1题与B独对1题，共2/10；B错误来自共同错误1题与A独对2题，共3/10。A-B为-0.1，即A低10个百分点。逐例差中有两项-1、一项+1、其余0，平均同样为-0.1。

共同错误虽然在差值中抵消，却必须留在各模型错误率分母中。若删去它们，就改变了评价总体；严重情况下，两个都很差的模型也会因为只看分歧子集而显得很好。分歧分析与总体质量是两个互补指标。

4 置乱标签

原标签保持率回答模型在配对被打乱后是否继续输出原答案，不等于新任务准确率。新查询b=-1与a=+1不同，因此新标签为0。一个真正响应新问题的模型应该改变答案。

在本合成任务里a已知，可以计算新标签；真实图片配自由文本时通常没有这种免费标签，应人工标注或仅报告敏感性。把无效标签导致的降分称为“证明跨模态能力”是典型过度解释。

5 线性模型的表达限制

四个角上的相等任务不能由一条直线分开。两个正类不等式相加要求c>0，两个负类不等式相加要求c<0，因此矛盾。乘积特征把关系显式编码后即可线性分开无噪声点。

这只否定原始二维特征上的线性分界，不否定拼接后经过非线性MLP的表达能力。深度网络是否实际学到关系还取决于数据、优化和捷径；表达存在与训练成功也不是同一命题。

6 缺失模态与单模态基线

将v设为0是在测试时干预已训练模型，可能造成分布外输入；vision或text基线从训练开始就只适应对应信息条件。两种实验回答不同问题。缺图性能差，不能直接推出图像不可替代；也可能是模型不会处理缺失标记。

本课缺文本同时将b和z设为0，这删除了决定相等关系所需的查询。任务从信息上变得含糊，所以准确率接近机会水平不一定是模型缺陷。评价指标必须与可用信息共同解释。

7 三个故障的诊断

故障A将真实潜变量a送入特征，绕过视觉噪声，使用了推理时本不应获得的真值。检查features输入字段和数据字典能发现；只看训练测试分开并不能阻止字段级泄漏。

故障B破坏重组任务标签，应由置乱重标单测发现。即使模型输出完全正确，错误标签也会制造低分，所以评价代码需要和训练代码同样严格的测试。

故障C让测试分布统计影响训练预处理。在普通归纳式评估中，这是不符合协议的信息使用；若研究者明确研究传导式适应，则可以允许，但必须单列设置并给所有方法相同权限。是否用到标签不是唯一的泄漏判断标准。

8 区间和种子解释

本课先在同一测试例上平均三种子的错误差，然后bootstrap测试例。区间描述固定训练数据和这三次训练平均后的测试样本不确定性；它没有完整覆盖重新抽训练集、选择超参数、换真实领域等变化。

三种子不是三份独立现实数据，八个域也不是八个独立数据集，因为域间共享同一批潜变量和样本。若要更广泛的结论，需要额外生成训练数据、引入新任务和真实数据来源，并根据实际相关结构选择统计单位。

9 实测核对口径

随包results.json中的主差值为randomized_interaction减interaction在shortcut_flip域的错误率，负数表示随机化更好。概率阈值固定为0.5，三种子全保留，15个模型权重均保存并重载验证。请以JSON中的精确值为准；PDF表格仅四舍五入显示。

如果重跑后略有浮点差异，先核对Python、NumPy、BLAS与种子，不要立即改测试容差。若差异改变结论，应保留两个版本并追查；不应把新结果硬改成与讲义一致。时间差异通常不影响科学结论，但预算报告仍需记录。

10 新实验没有唯一标准数值答案

提高视觉噪声通常会让仅靠真实视觉交互更困难，但具体域间差值必须实际运行得到。若预测未成立，应检查随机样本、模型权重、组别错误与提示依赖，而不是只增大噪声直到出现期待结果。

合格报告必须保存原协议、所有运行和反例。可以修改假设继续研究，但要把后续探索与原先的验证区分开。把失败预测改写成“原本就这样认为”，会破坏实验最有价值的可反驳性。

11 审查反馈示例

不合格结论：“证明多模态随机化训练实现了真正理解，解决了分布偏移和公平性。”这超出了一个合成任务、给定表示与固定手工交互的证据范围。

可接受结论：“在本合成相等判断任务中，随机化已知提示字段减少了相同交互模型在预定提示反转域上的错误。结果保留原域取舍与合成测量噪声组差异，没有证明自然图文或其他干扰字段上的泛化。”

更完整的报告还应说明下一步：增加非线性拼接模型作为容量对照，在不使用已知干扰位置的条件下测试干预方法，或换一份真实且获授权的图文任务重新定义标签保持变换。不要把这几项尚未做的计划写成已经验证的结果。