098 | 参考答案与结果解读

1. 参数和数据记账

隐藏层有4w个输入权重、w个偏置；输出层有w个权重、1个偏置，因此N=6w+1。五个宽度对应25、49、97、193、385个参数。每次更新使用1024条相同训练样本，500次更新共512000次呈现；独立训练信息量没有自动扩大500倍。

训练、验证、测试通过独立种子生成。不同生成种子不等于严格证明永不相撞，不过连续输入下完全重复的概率极小；测试代码还检查样本数组不相同。实验固定了同一批数据，五次种子重复衡量的是训练初始化差异，不是数据抽样差异。

2. 手算斜率

两点(100,0.08)、(200,0.06)给出b≈−0.415，模型翻倍时误差乘0.75。两个点拟合两个参数没有剩余自由度检验曲率。若想评价模型形式，至少需要额外规模点和真正留出的规模；更多点仍不能保证跨架构外推。

实际实验用四个规模的五种子均值拟合log MSE，而非把25条单次结果混在一起。两种拟合的权重和噪声假设不同。预测时必须把对数结果指数化，不能直接把线性预测当成MSE。

3. 留出误差应该怎样写

请以outputs/metrics.json为本次重跑的精确数字源，其中predicted_mse最后一项是留出预测，mean_test_mse最后一项是留出实测均值。heldout_relative_error为预测减实测再除实测；正值说明预测悲观，负值说明预测乐观。下面的“实测摘要”来自已执行实验，时间变化不要求逐位相同。

4. 为什么区间窄也不能放心

1000次bootstrap只重抽5个种子。全部训练都共享数据与模型形式，故共享的数据偏差、优化协议不足、幂律失配不会因重抽种子消失。图中带子不是生产任务的风险界限。要估计训练数据变化，需要生成或收集多个独立训练集并重新训练；仅重抽测试误差不能替代这一步。

5. 诊断顺序与可接受结论

先检查损失和数据是否有限，再看训练轨迹及训练验证差距，最后看残差和留出预测。大网络最后还在明显下降时，可提出更长训练的新实验；不能用“理论上大模型更强”抹去当前实际结果。若曲线接近噪声底，应考虑带底噪的模型，但少量点难以稳定估计三个参数。

答案允许留出预测失败。研究报告若诚实保留失败并说明适用区间，比选择性删除不合预期的规模更合格。本实验只能支持同一合成分布、同一训练协议与小网络家族的观察；没有测量GPU、语言能力或真实产品收益。

6. 本次实测摘要

宽度	参数	平均测试MSE	局部拟合预测
4	25	0.036290	0.030082
8	49	0.016362	0.020838
16	97	0.013311	0.014356
32	193	0.011230	0.009863
64	385	0.011144	0.006767

局部斜率为−0.5456，留出相对误差−39.28%。预测约0.00677，已经低于生成噪声方差0.01；实测约0.01114。这是一次有意义的外推失败：真实误差接近底噪时，忽略底噪的对数直线继续下降。种子带也未包含实测点，说明仅重抽初始化无法修复模型形式失配。不要把这个负面结果改写成成功预测。