099｜参考答案与结果解读

1. 两块归一化反例

分数0和log9、值0和10：全局权重为0.1与0.9，输出为9。各块只有一个元素，分别softmax后都是1；若再平均则输出5，错误。在线合并第二块时m'=log9，r=1/9，l'=1/9+1=10/9，a'=10，所以a'/l'=9。关键是恢复全局分母，而不是拼接已经归一化的局部结果。

2. 存储账

长度512、float64的一个密集分数矩阵有$512^2\times8=2097152$字节，即2 MiB；32乘32分数块为8192字节，即8 KiB。这是单个分数缓冲的256倍差距，不是完整程序的峰值内存节省倍数。程序仍保存Q/K/V和最终输出，还会产生softmax与矩阵乘法临时对象。

3. 正确性与CPU速度

随机测试、非整除长度、极端分数和均匀权重测试都应通过。测试使用float64和1e−12量级容差，而不是逐位一致。实测最大差见metrics.json。分块依然遍历所有连接；本讲Python实现常因小矩阵和循环开销比密集矩阵更慢。只要报告如实，这不是实验失败。

timings.csv包含4个长度×2种方法×9次重复=72条记录。每条tokens_per_second只是本次n个查询除以前向时间，不能替换成真实服务每秒生成token数。没有请求到达、排队或增量缓存，自然也没有服务SLO测量。

4. 检索结果与反例

全部12个全局检索位置都应成功，局部窗口在四种长度的末尾目标均可见；长度64的中间位置32也位于最后32个位置[32,63]内，因此5/12成功。其他长度的中间位置不在窗口内。全局输出随长度增长略降，因为分母中的干扰位置数量增加。将目标分数从12降至1时，即使可见，512长度的目标权重也约为exp(1)/(exp(1)+511)，远小于0.5。连接存在是必要的信息通路，不是准确检索的充分条件。

5. 因果与双向的区别

密集与分块正确性对照使用双向全连接；不能拿因果局部输出与双向参考作相等断言。若扩展在线算法处理掩码，需要跳过全掩蔽块或安全维护初始状态，否则负无穷减负无穷会出现NaN。还需要为因果掩码增加独立测试。

6. 合格报告示例

“在CPU单线程float64前向计算中，分块算法与密集参考在数值容差内一致；分数块理论存储显著更小，实际运行时间见逐次计时。局部窗口在本合成单层任务中无法读取窗口外目标。实验未测GPU、反向传播或语言模型真实长文本能力。”这个表述同时包含结果、边界与不能外推的部分。