100 | 参考答案与结果解读

1. 对称量化

4位qmax=7，尺度1/7；整数码−6、−1、3、7；还原约−0.857143、−0.142857、0.428571、1。最大误差约0.042857，小于s/2约0.071429。最大值量化使用本张量最大绝对值，因此此例没有裁剪。若另选更小范围，超界误差不受s/2限制。

全零张量取尺度1、码值0，精确还原零。对2位方案，整数−1、0、1经偏移成为无符号码0、1、2；码3不用。packbits的尾部填充必须在unpack时按元素数与位数截断。

2. 参数载荷

128个权重、34个float32偏置；浮点载荷648字节。量化含两个float32尺度共8字节，偏置136字节；所以8位272、4位208、2位176字节。相对648字节的压缩比分别约2.38、3.12、3.68倍，明显小于4、8、16倍，因为偏置和尺度没有按相同比例压缩。

这些是实际.bin字节，但完整部署还要保存形状等元数据与激活裁剪阈值。不要把原始载荷称为整个模型文件格式的最终大小，更不能称为运行时峰值内存。

3. 切片与选择

精确本次准确率见quality.csv；三个种子的样本数相同，各分组准确率可以直接取种子均值。若比较一个配置和教师，应先在同一种子下做差，保持配对。总体准确率是按组样本数加权的结果，不是常见与尾部准确率简单平均。尾部样本较少，其准确率的单样本步长更大。

选择裁剪百分位应使用训练之外的校准/验证数据，并保留最终测试集不参与选择。若校准集缺少尾部，应收集代表性校准数据并记录比例，或预注册压力测试；不能在最终测试上不断调整范围直到分数好看。

4. 计时结论

输入到两个浮点线性层的权重均已解码成float32，因此矩阵形状和浮点内核相同。权重文件较小不保证本实验前向更快。w4a4_fake还执行裁剪、舍入与还原，出现额外延迟符合计算路径。加载与解码被排除在计时外，若关心启动速度，必须追加独立测量。

5. 蒸馏与剪枝

软目标用温度展开类别概率，学生同时拟合硬标签与教师分布。教师错误可能被传递，最终仍以独立真实标签评价。学生必须在结构或运行路径上更省资源，才有部署成本优势。非结构零权重若仍由密集内核计算，不自动加速；删通道才直接改变矩阵形状，但必须重新检查质量。

6. 本次实测质量摘要

下表按三个训练种子取算术均值，各组样本数固定。这里只比较分类质量，不把压缩比当作加速比。

配置	总体准确率均值	常见组均值	尾部组均值	实际参数载荷字节
float32	96.53%	98.97%	87.64%	648
w8	97.00%	98.62%	91.12%	272
w4	88.69%	92.88%	73.49%	208
w2	57.78%	60.18%	49.03%	176
w4a4_fake	86.86%	91.07%	71.56%	208

2位配置虽然参数载荷最小，但总体与尾部准确率明显退化，不能称为无损压缩。4位激活模拟也应独立检查：量化位置和裁剪范围改变质量，不能只根据权重位数预测效果。每个种子的原始数值和样本logit仍保留在quality.csv与predictions.npz。