100 | 实验手册

1. 协议与数据

目标：比较float32、w8、w4、w2、w4a4_fake五个配置的准确率、分组退化、参数载荷与真实CPU前向时间。三个种子各训练一个教师，700步Adam；1800训练、400校准、1200测试；约20%尾部工况。校准上限固定为隐藏ReLU激活99.5百分位，先定协议，后读测试结果。

在本讲目录安装requirements.txt，运行python experiment.py与python tests.py，或顺序执行Notebook。实验无外部数据和模型下载。保留原outputs，扩展实验另存目录。

2. 手算与编码练习

用4位对称量化处理−0.9、−0.1、0.4、1.0，计算尺度、整数码、还原值、最大误差。对照s/2误差界，说明只在未裁剪时成立。再使用全零张量，确认实现不会除零。

查看pack/unpack，解释位序与码值偏移。用长度不能整除字节的整数序列测试尾部补零。解码时必须知道原形状，不能把填充比特误当作额外权重。

3. 质量审计

从predictions.npz读取每个配置的两个logit，取argmax重算准确率。按data.npz中的test_group拆分常见与尾部工况，核对quality.csv的n与accuracy。不要只看五个配置总体平均分。

每个种子分别计算压缩配置减教师准确率的差，再汇总平均。这里三种子共享同一测试集，不代表三个独立数据集；描述不确定性时保留这个限制。找出总体退化最小与尾部退化最小是否同一配置。

4. 存储与运行不是一回事

直接查看每个.bin的真实字节数，独立重算float32 648字节、w8 272字节、w4 208字节、w2 176字节。w4a4_fake权重载荷仍为208字节，激活阈值另记。列出未包含的形状元数据、容器和运行时开销。

计时统计共有3×5×2×21=630条。按配置和batch汇总中位数，同时保留种子与重复。说明为什么所有配置使用float32矩阵乘法时，参数文件缩小不能证明整数推理提速。

5. 研究设计练习

若你想选择最佳裁剪百分位，应在哪个划分上选择？若校准集没有尾部工况，应该补什么实验？若量化后的错误集中在小logit间隔样本，如何用保存的预测验证？写出方案，不修改测试集来让结果更好。

6. 提交与验收

提交一页质量—成本报告、位打包往返测试、逐分组准确率和延迟摘要。6项自动测试全部通过；不得将模拟量化说成整数内核，不得将参数载荷等同完整运行内存。蒸馏和剪枝只需推导与研究方案，本讲没有要求伪造对应训练结果。