101 | 实验手册

1. 任务与最重要的限制

任务是检查容量模型的逻辑、负载重放和统计口径。这里没有多卡、GPU或生产服务；所有服务时间是预设参数，只有模拟程序的运行时是CPU墙钟实测。报告标题、图注和结论都须保留“模拟”或“模型”标记。

安装requirements.txt后，在本讲目录运行python experiment.py、python tests.py，或执行Notebook。程序生成48次模拟、8640条逐请求记录、负载数组、队列轨迹和并行公式表。

2. 单请求手算

请求在2秒到达，提示10个token，输出3个token。容量1、没有其他请求。计算预填充0.002+10×0.0001=0.003秒；每步解码0.0008+0.00015=0.00095秒。求首token时间、完成时间、TTFT和总延迟，再与simulate函数比较。

第二个请求若在2.001秒到达，需要等第一个完成。手算它的queue_wait，检查“到达”与“开始”的区别。不要将等待时间从总延迟中删除。

3. 固定负载比较

从workloads.npz选择rate60、seed11，核对四种策略接收完全相同的180个请求。检查每个请求只完成一次，没有finish早于first_token、没有start早于arrival。容量1下continuous=True和False应完全一致。

重算每组p50、p95、1秒超时比例与排空吞吐。吞吐的分母从首个到达到最后完成，不是仅用到达窗口。解释若只除以到达窗口会产生什么偏差。

4. 看队列和长尾

用queue_trace.csv复画队列。说明队列不包含活跃请求，下降阶段可能只是到达停止后的排空。比较static4和continuous4：短回答释放的空位是否及时使用？接纳长提示为什么又可能暂停旧请求解码？

把模拟阈值1秒改成0.5秒时，输出另存新目录。阈值只改变是否达标，不会改变已经模拟的请求完成时间。不要把重算阈值叫成系统性能改进。

5. 并行公式检查

在parallel_model中令workers=1，通信应为0，加速比与效率均为1。把有效带宽减半，观察多卡加速怎样变化；再把启动延迟增加10倍，讨论许多小通信阶段为何敏感。所有变化仍是解析模型，不是设备测量。

6. 提交与验收

交付假设参数表、单请求手算、相同负载配对证据、p95与超时比例、队列图及至少四个模型遗漏项。6项测试全部通过。禁止将模拟器运行秒数当成服务秒数，禁止把有限排空吞吐称为稳态生产容量。