102 | 参考答案与结果解读

1. 质量门槛与失败配置

本次9个模型中，w8_s23与w8_s37总体准确率约84.33%与84.58%，尾部约52.12%与54.44%，均未达到90%/80%门槛。w8_s11约95.83%/87.26%通过质量门槛。这说明同一宽度的训练结果有差异，不能只挑最佳种子并声称训练流程稳定。

其余宽度32和64的六个模型达到本次质量门槛。延迟是否达标应以当前运行的summary.csv为准，因为墙钟时间会变化。在首次记录中54个配置有42个同时达标；这不是未来运行必须复现的固定数量。质量数据在相同软件与CPU算法下可重算一致，时间排序和前沿成员不要求逐位一致。

2. 参数与负载计数

参数量为2w+w+2w+2=5w+2，float32字节分别168、648、1288。运行时还包含激活、输入输出、库与对象；训练另有梯度和优化器状态，因此不是进程峰值内存。

54=9模型×3批量×2负载；270=54×5次重复；24840=9×2×5×(256+16+4)。tail重放有256个ID但只有163个不同样本；完整测试尾部259条。重放ID是性能负载，不是额外独立质量测试数据。

3. 延迟与吞吐

批耗时0.2毫秒、批量64时，摊销计算份额约3.125微秒，但批内请求从调用到返回仍经历0.2毫秒。凑批与排队没有被测量。总重放计时还包括Python循环和测量记录，故不应要求它等于内层前向时间之和。

p95按请求数加权：每条批耗时重复该批n次后统计。每个配置5次重放得到1280个请求时长条目；这些条目共享批事件，不是1280次独立服务观测。图中“配置p95的中位数”也不是所有请求混合后的p95。

4. Pareto手算

A在字节、时间、准确率三项都不差于B，且都严格更好，因此B被A支配。C比A更快、更准确，但占更多字节，两者不能相互支配。前沿保留A、C，并不自动告诉你应选择谁；最后取舍取决于明确的资源目标。

本实验先按总体、尾部和批响应门槛过滤，再在同一负载内求前沿。尾部准确率没有作为前沿第四维；如果业务需要持续优化尾部，应修改预先定义的目标并重新报告。前沿依赖实测时间，微小噪声可改变成员，不应宣称永久优胜。

5. 一页报告的边界

可以写“固定合成任务下，比较9个CPU模型、两种负载与三种批量；保留失败种子，按预设质量与批响应限制筛选，报告参数账、重放时间和非支配配置”。不可以写“该配置满足生产SLO、节省多少电费、真实设备安全可靠”，因为实验没有测这些对象。

若后续反复用这份测试集选择超参数，需要新的外部确认集。若声称在线性能，需要真实到达、排队、凑批、网络和失败测量。若声称训练流程稳定，需要更多种子与预先定义的成功概率标准，而非单个幸运模型。