102 | 实验手册

1. 在运行前固定协议

总体准确率至少90%，尾部至少80%，无排队批响应p95不超过2毫秒。候选宽度8/32/64、种子11/23/37、批量1/16/64；训练700步Adam、学习率0.015；两条固定256请求负载，每种配置重复5次。不要看到结果后降低门槛。

在本讲目录安装requirements.txt，运行python experiment.py与python tests.py；或顺序执行Notebook。数据、权重与预测均由程序生成并保存，无外部模型与网络服务。CPU单线程，不需要GPU。

2. 独立重算质量与参数账

从predictions.npz读取每个模型的两个logit，argmax后与data.npz标签比较，分别重算总体、常见和尾部准确率。检查尾部样本数259，确认总体是按样本数加权的结果。

手算参数量5w+2与float32字节数：宽度8为168字节，32为648，64为1288。用parameters.npz的数组nbytes求和验证。列出参数账没有包含的至少四类运行资源。

3. 核对可重放负载

mixed保存256个不同测试样本ID；tail有放回抽取256个ID，本次只有163个不同样本。五次重放不把它变成1280条独立质量样本。核对所有配置复用相同负载顺序。

计算54个配置、270次总重放、24840条批计时的来源。对某个配置，将每条批耗时重复n次，再求p95，和summary.csv比较。不要直接把批耗时除以n当作延迟。

4. 约束与前沿

独立实现eligible，检查恰好达到阈值也算通过。列出质量失败的模型，解释为什么它们无论多快都不能进入当前可行集合。然后仅在同一负载的合格配置内，重算准确率最大、时间最小、参数最小的非支配集合。

构造三个手算方案：A为10字节/1秒/90%，B为20字节/2秒/80%，C为30字节/0.5秒/95%。指出B被谁支配，A和C为何不能相互支配。说明尾部质量在本实验前沿里是门槛而非第四个优化维度。

5. 反例与研究扩展

若把batch64前向耗时除以64并宣传用户延迟，你漏了什么？若使用当前测试集反复选择宽度和学习率，最终还需要什么数据？若希望声称生产SLO，你必须补哪些到达、凑批、排队和失败记录？

扩展实验另存目录，保留原协议。可以增加更多训练种子，测试某个宽度的达标概率；也可以用另一CPU复测排序稳定性。不要将重放速度换算为货币成本，除非另外提供真实计费边界和利用率依据。

6. 提交与验收

交付一页研究报告与完整重算脚本：协议、质量分组、计时边界、可行配置、前沿及限制。6项测试全部通过。报告必须写明真实CPU测量、无在线队列、参数字节非峰值内存、合成任务非真实设备安全结论。一个未达标配置也是必须保留的有效结果。